



저작자표시-비영리-변경금지 2.0 대한민국

이용자는 아래의 조건을 따르는 경우에 한하여 자유롭게

- 이 저작물을 복제, 배포, 전송, 전시, 공연 및 방송할 수 있습니다.

다음과 같은 조건을 따라야 합니다:



저작자표시. 귀하는 원저작자를 표시하여야 합니다.



비영리. 귀하는 이 저작물을 영리 목적으로 이용할 수 없습니다.



변경금지. 귀하는 이 저작물을 개작, 변형 또는 가공할 수 없습니다.

- 귀하는, 이 저작물의 재이용이나 배포의 경우, 이 저작물에 적용된 이용허락조건을 명확하게 나타내어야 합니다.
- 저작권자로부터 별도의 허가를 받으면 이러한 조건들은 적용되지 않습니다.

저작권법에 따른 이용자의 권리는 위의 내용에 의하여 영향을 받지 않습니다.

이것은 [이용허락규약\(Legal Code\)](#)을 이해하기 쉽게 요약한 것입니다.

[Disclaimer](#)

공학박사학위논문

UAV 영상을 활용한
GeoAI 기반 정밀 환경공간정보 구축



2024 년 1 월

국립창원대학교 대학원
스마트환경에너지공학과정
박 건 응

공학박사학위논문

UAV 영상을 활용한
GeoAI 기반 정밀 환경공간정보 구축

Construction of Precision Environmental Spatial Information
Based on Geospatial Artificial Intelligence and Unmanned
Aerial Vehicle Imagery

지도교수 박 경 훈

이 논문을 공학박사학위논문으로 제출함

2024 년 1 월

국립창원대학교 대학원
스마트환경에너지공학과정
박 건 응

박건웅의 공학박사학위논문을 인준함

심사위원장 문 병 현 (인)

심사위원 이 홍 규 (인)

심사위원 박 중 관 (인)

심사위원 김 경 태 (인)

심사위원 박 경 훈 (인)

2024 년 1 월

국립창원대학교 대학원



목 차

I. 서 론	1
1. 연구 배경 및 목적	1
2. 연구범위 및 연구수행과정	5
1) 연구범위	5
2) 연구수행과정	10
II. 환경공간정보 구축 이론	13
1. 환경공간정보 재현	13
2. UAV 및 GeoAI 기반 원격탐사	16
1) UAV 원격탐사 특징	16
2) GeoAI 기법	31
III. 토지피복 및 수목 공간정보 구축 방법	38
1. UAV 영상 수집 및 전처리	38
1) UAV 비행 및 데이터 수집	38
2) UAV 영상 및 기초 분석 데이터 제작	42
2. GeoAI 모델 선정 및 학습 데이터 구축	46
1) 토지피복 분류	46
2) 수목 탐지 및 흉고직경 측정	52

3. GeoAI 모델 적용 및 환경공간정보 구축	57
1) 토지피복 분류 모델 학습 및 비교	57
2) 수목 탐지 및 흉고직경 예측 모델 학습	59
IV. 토지피복 분류 및 모델 성능 평가	61
1. UAV 영상 분석 및 학습 데이터 구축	62
1) UAV 영상 및 기초 분석 데이터	62
2) 토지피복 항목별 UAV 영상 특성 및 분류 기여도	69
2. 분류 모델 학습 및 공간적 일반화 성능 비교	83
1) 객체 기반 영상 분석 및 딥러닝 기반 의미론적 분할 기법 모델 학습	83
2) 검증 지역에 대한 분류 정확도 비교	92
V. 개별 수목 탐지 및 속성정보 추출	99
1. 수목의 형태 특성 활용 학습 데이터 구축	100
1) UAV 영상 및 기초 분석 데이터	100
2) 객체 기반 영상 분석 및 유역 분할 기법 적용	105
2. 탐지 모델 학습 및 속성정보 추출	111
1) 딥러닝 기반 객체 분할 기법 모델 학습	111
2) 수목 형태 정보 산출 및 흉고직경 예측	117

VI. 결 론	127
1. 결과 요약 및 결론	127
2. 연구의 한계 및 향후 과제	130
부 록	132
참고문헌	135
ABSTRACT	156



표 목 차

TABLE 1. Summary of content scope in the study	6
TABLE 2. RS application example for a UAV with an RGB camera	22
TABLE 3. RS application example for a UAV with an multi-spectral camera	25
TABLE 4. RS application example for a UAV with an hyper-spectral camera	28
TABLE 5. RS application example for a UAV with an thermal infrared (TIR) camera	29
TABLE 6. RS application example for a UAV with LiDAR	30
TABLE 7. Specifications of UAV and Sensor	41
TABLE 8. Confusion matrix for the initial RF	77
TABLE 9. Results of land cover classification area ratio for the training site	90
TABLE 10. Accuracy of land cover classification in validation site	95
TABLE 11. Confusion matrix for Tree area classification based on UAV-LiDAR data	107
TABLE 12. Results of accuracy for individual tree detection based on Mask R-CNN	116
TABLE 13. Results of observed DBH and calculated tree	

information	117
TABLE 14. DBH predictions results using regression models ·	124
TABLE A1. Confusion Matrix of OBIA-RF prediction result for land cover in validation site	132
TABLE A2. Confusion Matrix of OBIA-ANN prediction result for land cover in validation site	133
TABLE A3. Confusion Matrix of U-Net prediction result for land cover in validation site	134




그림 목 차

FIGURE 1. Study area for land cover classification	8
FIGURE 2. Study area for individual tree detection	9
FIGURE 3. Study process	10
FIGURE 4. Representation approach of spatial information ..	14
FIGURE 5. Example of representing spatial information for forest inventory	15
FIGURE 6. Components of UAV	17
FIGURE 7. The accuracy of measurement methods in relation to the object/area size	18
FIGURE 8. Difference of Perspective and Orthogonal projection	20
FIGURE 9. Spectral reflectance characteristics of vegetation	24
FIGURE 10. Typical hyper-spectral imaging approaches	26
FIGURE 11. Diagram of Random Forest	32
FIGURE 12. Diagram of Artificial Neural Network	33
FIGURE 13. Procedure of Object-based Image Analysis	35
FIGURE 14. An example of different visual perception between semantic and instance segmentation	37
FIGURE 15. Spectral signatures of different urban land cover types acquired with field spectrometer	38

FIGURE 16. Random points for preliminary analysis	50
FIGURE 17. Separating training and validation site	51
FIGURE 18. Concept of watershed	54
FIGURE 19. The Mask R-CNN framework for instance segmentation	55
FIGURE 20. Random points for comparison of classification	58
FIGURE 21. Formula and diagram of IoU	59
FIGURE 22. Results of UAV imagery for land cover classification	62
FIGURE 23. Image segmentation results	68
FIGURE 24. Characteristics of the training data used for the variable importance	70
FIGURE 25. Most important 40 variables out of the 126 assessed	73
FIGURE 26. Result of applying the initial RF to the study area	75
FIGURE 27. Example of sidewalk block types in the target site	80
FIGURE 28. Result of digitizing land cover in training site	82
FIGURE 29. Accuracy trend of OBIA-RF by hyper-parameter	84
FIGURE 30. Accuracy trend of OBIA-ANN by hyper-parameter	86

FIGURE 31. Accuracy trend of U-Net by hyper-parameter ..	87
FIGURE 32. Results of land cover classification in training site	89
FIGURE 33. Results of land cover classification in validation site	92
FIGURE 34. Result of UAV-LiDAR flight for individual tree detection	100
FIGURE 35. Segmentation for classification of tree area	103
FIGURE 36. The result of tree crown area digitization	104
FIGURE 37. Accuracy trend of OBIA-RF by hyper-parameter for tree classification	106
FIGURE 38. Examples of misclassification for tree area classification	108
FIGURE 39. Watershed segmentation feature based on tree shape	108
FIGURE 40. Examples of misseparation of tree areas into individual trees using based on watershed segmentation	109
FIGURE 41. Result of separating tree areas into individual tree areas using watershed segmentation based on UAV-LiDAR	110
FIGURE 42. Training and validation loss of Mask R-CNN for individual tree detection	112
FIGURE 43. Results of individual tree detection based on Mask R-CNN	113

FIGURE 44. Details of individual tree detection based on Mask R-CNN	115
FIGURE 45. The relationship between observed DBH and calculated tree information	121
FIGURE 46. Scatterplot for verification of DBH predictions based on UAV-LiDAR	125



I. 서 론

1. 연구 배경 및 목적

현대 사회의 많은 것들이 공간과 밀접한 관계를 맺고 있으며, 대상의 위치나 주변 공간과의 관계는 문제에 대한 이해도를 높이고, 최종적으로 문제 해결을 위한 의사결정을 지원한다. 1990년대부터 정부는 사회 현안 해결을 위해 국가 차원의 공간정보정책을 추진하였고, 다양한 분야에서 공간정보 생산·유통·활용이 증가 및 확대되었다[1]. 또한, 최상위 국가공간계획인 국토종합계획에서 국토와 환경의 통합 관리 정책을 추진하면서 환경에 대한 공간정보 중요성이 증가하고 있다[2]. 이는 환경공간정보 제작을 위한 기반 기술의 정밀화 및 과학화 등을 이끌었다. 물환경, 자연환경, 대기·기후 등 다양한 환경 관련 자료들이 환경공간정보로 제작되고 있으며[3], 정책 수립 과정에서 과학적 근거 또는 분석을 위한 기초자료로 광범위하게 활용하고 있다[4][5][6][7][8][9].

환경정책기본법에 의거하여 지속가능한 환경의 관리와 보전을 위해 다양한 주체, 즉 환경관리주체가 책임과 의무를 지고 있다. 이들 각각은 자신의 역할과 책임에 따라 서로 다른 규모(Scale)의 환경공간정보를 제작하고 있으며, 이를 근거로 정책 또는 계획이 수립되고 있다. 정부는 전국토를 범위로 접근하며, 토지피복지도, 국토환경성평가지도 등 환경공간정보를 제작 및 보급하고, 국가 차원의 환경보전을 위한 종합계획을 수립하고 있다. 반면에 시·군·구, 사업자, 전문기관 등과 같이 지역의 환경관리주체는 상위 계획을 기반으로 하되, 각 관할 구역의 상황과 지역적 특성을 반영한 지역·국지적 규모의 환경공간정보를 제작하고, 정책의 근거 또는 분석을 위한 기초자료로 사용하고 있다.

정부 제공의 환경공간정보는 국토 전체를 대상으로 하므로 현실 세계를 최대한 반영하였다고 하더라도, 지역·국지적 규모 수준에서 필요한 정보를 모두 포함하기에는 한계가 존재한다[10]. 이는 지역의 환경관리주체가 정부 제공의 환경공간정보에는 부재한 특정 환경정보를 직접 조사하고, 공간정보로 제작해야 함을 의미한다. 그러나 부재한 환경공간정보의 제작은 현장 기반 조사의 제한성, 시간과 비용의 증가가 수반되어 환경 분석 및 정책 수립의 어려움으로 이어진다 [11][12][13][14][15]. 이에 따라, 지역·국지적 규모를 대상으로 부재한 환경 정보에 대해서 효율적으로 조사하고, 환경공간정보를 제작할 수 있는 방안에 대한 필요성이 커지고 있다[16][17].

환경 데이터는 목적에 따라 가공되어 다양한 형태의 환경공간정보로 제작되며, 이는 공간정보의 재현, 데이터 수집, 공간정보 제작 방법론에 따라 달라진다. 첫 번째는 환경정보를 공간정보로 재현하는 방식의 선정이다. 공간정보는 복잡한 현실 세계를 표현하기 위해서 인간이 세상을 바라보는 관점에 따라 현실 세계를 함축 및 요약하는 과정을 거쳐 제작된다. 대표적인 공간정보 재현 방식은 인간의 관점에 따라서 공간 내에서 특정 객체만 다루는 것과 공간 전체를 다루는 것으로 구분할 수 있으며, 이는 이산적 객체 관점(Discrete Object View)과 연속적 필드 관점(Continuous Field View)으로 정의될 수 있다[18]. 이산적 객체 관점은 현실 세계를 경계선이 명확한 객체만 재현하고, 그 외 공간은 빈 공간으로 바라본다. 연속적 필드 관점은 빈 공간 없이 공간상의 모든 위치에서 속성정보로 현실 세계를 표현한다. 이러한 재현 방식은 목적과 조사되는 환경정보의 특징에 따라 결정되며, 데이터 수집 및 정보 도출 기법 선정 및 활용에도 영향을 준다[19].

두 가지 공간정보 재현 방식에 따른 제작 방안을 고려하기 위해 주요 환경 정책 및 법령에 따라 주목받는 환경정보를 대상으로 사례연구를 진행하였다. 연속적 필드 관점의 경우 토지피복 정보를 대상으로 진행하였다. 토지피복 정보는 물환경[20][21], 기후/대기[22][23], 자연환경[24][25] 등 다양한 분야에서 가장 범용적으로 이용되고 있다. 하지만 기초자료의 일관성, 적시성 등을 갖추지 못해 기존 정부에서 제공하는 자료의 활용에 한계가 있는 환경공간정보이다. 이산적 객체 관점에서는 토지피복 정보에서 더 세부적으로 접근하여 개별 수목 정보를 대상으로 진행하였다. 수목은 이산화탄소 흡수 및 저장 등의 생태계 서비스 제공을 통해 환경 개선에 중요한 역할을 하며, 탄소중립 정책에 의해 탄소 저장 및 흡수원으로써 주목받고 있다[14][26][27]. 하지만 기존의 현장 조사 방식은 노동집약적이고, 시간 및 비용적으로 조사 및 정보 구축에 한계가 있다. 이러한 두 가지 사례를 기반으로 공간정보 재현 방식과 환경정보 특성을 고려해 환경공간정보를 제작하는 방안을 모색하였다.

환경공간정보의 구축은 환경과 관련된 공간 데이터 수집이 필요하다. 사람이 현장에서 직접 측정하는 것이 가장 정밀한 정보를 얻을 수 있지만, 넓은 지역을 모두 조사하기에는 한계가 있다. 원격탐사 플랫폼을 이용하면 사람이 직접 가지 않고도 넓은 지역을 조사할 수 있다. 국가적 규모는 위성과 항공기가 여전히 좋은 수단이지만, 지역·국지적 규모에서는 무인항공기(UAV, Unmanned Aerial Vehicle)가 위성과 항공기를 경제적으로 대체 및 보완할 수 있다[28][29][30][31]. UAV는 수 cm 급 공간해상도의 상세한 영상을 취득할 수 있고, 다양한 센서를 통해 기하학적 및 다중분광 영상 등 유연한 데이터 수집이 가능하다. 이에 따라 UAV의 원격탐사 접목 및 공간정보 구축에 대한 동기가

부여되고 있으며[32][33][34][35][36], 본 연구에서도 UAV를 이용한 환경 공간정보 구축 방안을 모색하였다.

다음으로 수집된 공간 데이터는 환경공간정보로 제작되어야 한다. 원격탐사 플랫폼으로 수집된 데이터는 주로 이미지 형태이며, 정보가 내재되어 있지 명시적으로 표출되지 않는다[18]. 인지 과정에서 이미지의 픽셀들은 그룹화되어 객체로 인식되고, 벡터라이징, 속성 편집 등의 명시적인 기록을 통해 공간정보로 제작된다. 규모 범위가 넓을수록, 상세한 공간정보를 제작할수록, 그 과정은 인간에게 노동집약적인 반복 작업이며 시간과 비용이 증가한다. 반면에 GeoAI(Geospatial Artificial Intelligence)는 공간 데이터로부터 특정 인지 문제를 학습하고, 인간보다 훨씬 빠른 연산과 반복 작업이 가능하다[37][38][39]. 그러나 UAV 기반 고해상도 영상은 하나의 물체를 표현하는데 수많은 픽셀이 배경 및 형태 정보를 표현하므로 복잡한 구조의 데이터가 생성된다 [40][41][42][43]. 이는 데이터 해석 및 분석의 어려움으로 이어지므로 적합한 영상 분석 방안이 필요하다. 따라서, 본 연구는 고해상도 영상 분석에 적합한 것으로 보고되는 객체 기반 영상 분석(OBIA, Object-Based Image Analysis)[44]과 딥러닝(Deep Learning)[45]과 같은 GeoAI 기법을 적용 및 비교하고자 하였다.

본 연구의 목적은 지역·국지적 규모에서 기존 환경공간정보 조사 및 제작 방법이 갖고 있는 한계를 완화하기 위해 두 가지 공간정보 재현 관점에서 사례연구를 통해 UAV 영상을 활용한 GeoAI 기반 환경공간정보 제작 방안을 제시하는 것이다. 이를 통해서 부재한 환경정보 데이터를 제작하기 위한 기초자료 제작 방안을 제시하고, 환경 분석 및 정책 수립의 효율성 증대에 기여하고자 한다.

2. 연구범위 및 연구수행과정

1) 연구범위

가. 내용적 범위

본 연구는 토지피복과 수목 단위의 도시녹지 정보에 대한 사례 연구를 통해 환경공간정보 제작 방안을 모색하였다. 이를 위해서 토지피복과 수목 정보에 대한 특성을 고려해 데이터 수집 수단인 UAV와 센서를 선정하고, 공간정보 재현에 필요한 GeoAI 기법을 선정 및 활용하였다. 환경정보, 공간정보, UAV 기반 데이터 수집, GeoAI 방법론의 네 가지 측면에서 환경공간정보 구축 방법론을 고찰하였으며, 이에 대한 내용적 범위를 요약하여 표 1에 제시하였다.

본 연구는 토지피복과 수목 정보의 특징에 따라 두 가지 공간정보 재현 관점에서 방법론을 제시하고자 하였다. 토지피복은 위치마다 도시의 복잡한 물리적 특성을 가진 여러 대상을 몇 개의 토지피복 그룹으로 분류하여 표현한다. 수목의 경우 개별 수목의 위치와 함께 탄소의 흡수·저장량 산정에 필요한 흉고직경, 수고 등을 속성정보로 구축한다. 따라서 연속적 필드 관점에서는 토지피복 정보의 구축 방법론을 설계하였고, 이산적 객체 관점에서는 개별 수목의 공간정보를 구축 방법론을 설계하였다. 다음으로 UAV 및 GeoAI를 접목하여 방법론을 설계하고 환경공간정보 구축에 대한 분석을 진행하였다. 토지피복의 경우 도시의 복잡한 물리적 특성 정보를 수집해야 하므로 다중분광, 열적외 카메라 등을 탑재한 UAV로 다양한 물리적 특성을 표출하는 데이터를 수집했다. 수목은 개별 수목에 대한 구조 정보를 구축해야 하므로 UAV-LiDAR를 통해 정밀한 3차원 위치 데이터를 수집했다. 그리고 고해상도 UAV 영상 분석에 적합한 GeoAI 기법인 객체 기반 영상 분석과 딥러닝 기법을 적용하였다.

TABLE 1. Summary of content scope in the study (continue)

Environmental information		Spatial information
Land Cover	Importance of information: · Utilization in various areas for environmental simulation, prediction, analysis of current status and changes	Representation of spatial information: · Continuous field view using discrete data model · Assuming that the real world is a series of continuous maps or layers without any gaps across all locations.
	Necessary attributes: · Precise land cover information · Classifying regions with homogeneous characteristics	Traditional construction methods and limitations: · Human field survey and vectorizing for precise information · Labor-intensive with increased time and cost
Individual Tree	Importance of information: · Due to carbon neutrality policies, the importance of carbon storage and absorption has increased.	Representation of spatial information: · Discrete object view using 2D data model (area) · Assuming the empty world except objects with clear boundaries.
	Necessary attributes: · 3D Structures such as crown area, height, and diameter at breast height (DBH) for estimating carbon storage and absorption	Traditional construction methods and limitations: · Human field survey · Difficulty to define Boundaries Between Trees · Challenges in constructing spatial information
Similarity	· High-precision information, difficult for governments to provide	· Constructing spatial information with clear boundaries as Vector data

TABLE 1. Summary of content scope in the study

Collection of UAV-based data		Methodology of GeoAI
Land Cover	UAV types: · Fixed-wing UAV for longer flight times to cover large areas	Analyzing the value of each UAV's spectral and geometric Images as training data for classifying land cover items · Data characteristics for the UAV imagery for land cover items · Contribution of UAV imagery for classification using OBIA-RF
	Sensor types: · Multispectral, Thermal Infrared, RGB Cameras for collecting complex physical properties of urban land cover from various spectral and geometric Images	Comparing which GeoAI models are effective for classification: · Application of OBIA with RF and ANN algorithms and DL-based semantic segmentation algorithms (U-Net) · Separating training and validation site
Individual Tree	UAV types: · Rotary-wing UAV for stable flight attitude control	Making training data for individual tree detection: · Applying OBIA with physical shape features to distinguish individual trees in areas with ambiguous boundaries for making training data
	Sensor types: · LiDAR sensor with RGB camera collecting precise 3D positioning data with spectral images	Constructing Individual Tree area and 3D structure attributes: · Applying DL-based instance segmentation algorithm (Mask R-CNN) for direct individual tree detection in UAV Images · Calculating crown area and height from tree detection results · Predicting DBH using regression algorithms
Similarity	· Collecting high-resolution spectral and geometric data on environmental information using UAV and sensor features	· Applying OBIA and DL techniques, suitable for high-resolution imagery, in GeoAI · Selecting GeoAI models through analysis of previous research

가. 공간적 범위

본 연구는 토지피복, 수목 사례에 따라서 별도의 연구 대상지를 선정하여 연구를 진행하였다. 먼저 토지피복 정보 분류는 그림 1에 제시한 것과 같이 도시지역에서 다양한 토지피복 유형이 존재하고 있는 경상남도 창원시 창원대학교 일대를 중심으로 수행하였다. 도시 환경과 같은 복잡한 물리·공간적인 요소가 분포하고 있는 지역은 토지피복 분류에 대한 어려움으로 이어지며, 이는 분광 정보의 복잡성 문제로 잘 알려져 있다[46]. 도시 환경에서는 분광 정보의 특징만으로는 이 문제를 효과적으로 처리할 수 없지만, 더 다양한 특징을 사용하여 이러한 문제를 완화시킬 수 있다. UAV는 다양한 센서를 장착할 수 있으므로 다양한 특성을 가진 데이터를 생성할 수 있다. 다만, 어떤 영상과 기법이 도시지역에서 토지피복 분류에 효과적인지에 관한 연구가 필요하다.




FIGURE 1. Study area for land cover classification

도시녹지에서 수목은 그림 2에 제시한 것과 같이 다양한 수목과 분포 유형이 존재하는 창원대학교의 공대 일대를 중심으로 수행하였다. 이 지역은 수목들이 서로 떨어져 있어 밀집도가 낮은 지역, 수목들의 밀집도가 높아 수목 간에 경계가 모호한 지역, 그리고 밀집도가 높고 수목 간의 높이 차이가 다양한 지역을 포함하고 있다. 또한, 다양한 수종의 가로수가 분포하고 있는 지역에 대해서 연구를 수행하였다. 도시녹지는 공간적, 환경적, 그리고 생태적 가치를 지니고 있다. 특히, 수목은 도시의 미세먼지 및 이산화탄소 같은 대기오염 물질 감소, 도시열섬 현상 완화, 그리고 생태계 서비스 제공을 통해 도시 환경을 개선하는데 중요한 역할을 한다[14][47]. 이러한 다양한 가치를 효과적으로 조사 및 관리하여 도시계획, 환경영향평가 등에 반영하기 위해서 개별 수목에 대한 위치, 구조 정보 등을 조사하는 방법에 관한 연구가 필요하다.



FIGURE 2. Study area for individual tree detection

2) 연구수행과정

본 연구의 연구수행과정은 이론적 고찰 및 방법론 설계, UAV 영상 수집 및 전처리, GeoAI를 활용한 학습 데이터 제작, 그리고 GeoAI를 활용한 환경공간정보 구축 순으로 4단계로 구성된다. 그리고 4단계에 따른 세부 연구내용과 함께 연구수행과정을 그림 3에 제시하였다.

1. Literature Review and Methodology Design

- Components of Environmental Spatial Information
- Feature of Remote Sensing with UAVs
- Application of GeoAI for high-resolution imagery analysis



2. Collecting and Preprocessing UAV imagery

Land Cover : Various Spectral and Geometric images

Individual Tree : Precise Geometric data with spectral images



3. Making Training Data with GeoAI

Land Cover : Evaluating the value of each UAV's Images as training data

- Analyzing the characteristics of UAV imagery for each land cover category
- Analyzing the Contribution in UAV imagery for classification using OBIA with RF

Individual Tree : Separating Individual Tree area using Physical Shape Features

- Extracting Tree area from Urban Area using OBIA
- Separating Individual Tree area using Watershed segmentation



4. Applying GeoAI for Environmental Spatial Information

Land Cover : Comparing which GeoAI models are effective for classification

- Training OBIA using classification algorithms and DL-based semantic segmentation
- Comparing the accuracy of the models at the validation site

Individual Tree : Constructing Individual Tree area and 3D structure attributes

- Training and evaluating DL-based instance segmentation algorithm
- Predicting DBH from attributes calculated using detection results, with regression algorithms

FIGURE 3. Study process

연구수행과정은 이론적 고찰 및 방법론 설계, UAV 영상 수집 및 전처리, GeoAI를 활용한 학습 데이터 제작, GeoAI 적용을 통한 환경공간정보 구축으로 총 4 단계의 과정을 통해서 진행되었다. 첫 번째 단계는 2장 및 3장에서 기술하였고, 다음 단계인 UAV 영상 수집 및 전처리부터 GeoAI 적용을 통한 환경공간정보 구축까지의 내용은 토지피복과 개별 수목 정보로 구분하여 4장 및 5장에서 각 사례연구 결과로 제시하였다.

이론적 고찰 및 방법론 설계 단계는 환경공간정보 구축에 대한 방법론을 설계하기 위한 단계이다. 환경공간정보의 구성요소, UAV를 활용한 원격탐사의 특징, 그리고 고해상도 영상 분석을 위한 GeoAI의 적용 방법에 대해 이론적 고찰을 진행하였다. 이를 통해 이론적 토대를 마련하고 환경공간정보 구축을 위한 방법론을 설계하였다.

두 번째 단계부터는 토지피복과 수목에 대한 사례연구 단계이다. 두 번째 단계는 이론적 고찰 및 방법론 설계에서 도출된 토지피복과 개별 수목 정보에 대한 기초 데이터 수집을 진행한다. 토지피복과 개별 수목 정보 구축에 적합한 다양한 분광 및 기하학적 영상을 수집하였다. UAV에 장착된 다중분광, 열적외 카메라, RGB 카메라, LiDAR 센서를 통해 수집되며, GeoAI를 사용하여 분석될 학습 데이터를 만드는 기초 자료로 활용하였다.

세 번째 단계는 GeoAI를 이용해서 학습 데이터의 분석 및 제작을 진행하였다. 토지피복의 경우 UAV 영상을 통해 수집된 다양한 물리적 특성을 바탕으로 분류를 진행한다. 그러나 어떤 UAV 영상이 도시 지역의 각 토지피복 분류 항목에 대해서 어떤 특성을 보이고, 분류에서는

어떤 기여도를 가지는지 분석이 필요하다. 이를 위해서 객체 기반 영상 분석 및 랜덤 포레스트 모델을 사용하여 진행하였다. 개별 수목의 경우 수목 간의 모호한 경계를 구분하기 위해서 GeoAI를 통해서 학습 데이터를 구축하고자 하였다. 먼저 객체 기반 영상 분석 기법을 사용해서 도시지역에서 수목 영역을 추출하였다. 그 후 유역 분할 기법을 기반으로 물리적 구조 특성을 이용해서 개별 나무 영역을 분리하였다.

마지막 단계에서는 환경공간정보 구축을 위한 GeoAI 적용 단계이다. 토지피복의 경우 토지피복 분류에 적절한 GeoAI 모델을 모색하고자 하였다. 연구 대상지를 학습 지역과 검증 지역으로 분할하여 진행하였다. 동일한 학습 지역을 대상으로 객체 기반 영상 분석 기법과 딥러닝 기반 의미론적 분할 기법의 모델 학습을 진행하였다. 다음으로 학습이 전혀 진행되지 않았던 검증 지역에서 토지피복 분류를 진행하고 정확도를 비교하였다. 개별 수목의 경우 탐지를 위해서 딥러닝 기반 객체 분할 기법의 모델을 적용해 학습을 진행하고 정확도 평가를 진행하였다. 다음으로 탄소 흡수·저장량 산정에 필요한 수목 구조 정보를 구축하기 위해서 개별 수목 영역 탐지 결과를 통해 여러 수목 구조 정보를 산출하고, 이를 기반으로 여러 회귀모델을 적용해 흉고직경을 추정하고자 하였다.

연구수행과정을 통해, 본 연구는 UAV 및 GeoAI 기술의 접목을 통해 환경공간정보의 자동 구축 방안을 제시하고, 이를 통해 지속 가능한 환경공간정보 모니터링 방법을 제시하고자 하였다. 연구 결과는 토지피복과 수목에 국한되지 않고, 다양한 환경 데이터로부터 공간정보를 생성하는 방법론으로 확장될 수 있을 것으로 기대된다.

II. 환경공간정보 구축 이론

1. 환경공간정보 재현

공간과 관련된 문제는 사물 또는 현상에 대한 위치나 주변 공간과의 관계를 통해서 문제에 대한 이해를 돕고, 최종적으로는 문제 해결을 위한 의사결정을 지원하는 역할을 한다. 예를 들어 낙동강 지류 하천 구간 내에서 농경지 개간과 농업시설 집단화된 하천에서 수질오염도가 증가하여 원인을 분석하고 관리하기 위해 수행된 낙동수계관리위원회의 환경기초조사사업이 있다^[48]. 공간에 대한 이해를 위해서 하천구간 내의 토지이용 변화, 토지이용 변화에 따른 수질 오염에 미치는 영향 등 다양한 공간적 요소를 고려해서 원인 분석이 진행되었다. 그리고 문제 해결을 위한 의사결정을 위해 UAV를 활용해 하천구간 내의 농경지 현황자료, 법적관리지역 지정현황, 토지소유정보 등과 같이 해당 지역에 대한 공간 데이터베이스를 구축 및 가공한 뒤 무단 경작의 의심되는 지역을 추정하는 공간정보를 제공하여 하천구간 내의 관리 방안을 제시하였다. 앞서 제시한 예시와 같이 환경 문제의 해결을 위해서 다양한 유형의 공간정보 제작이 필요해지고 있다.

공간정보는 자연적 대상이든, 인공적인 대상이든 공간상에 존재하는 사물과 현상에 대해서 특정한 목적과 맥락에 따라서 선정 및 가공된 데이터를 의미한다. 공간적 대상을 공간정보로 구축하는 것은 관찰된 대상의 기하학적 위치를 결정하고, 관찰된 사실, 상황, 사물, 그리고 설명 등과 같은 현상에 대한 정성적, 정량적 정보를 수집하여 도면, 수치, 그리고 텍스트 등으로 표현하는 것을 의미한다. 그러나 현실

세계는 매우 복잡하므로 디지털화된 데이터로 표현하기 위해서는 현실 세계를 요약하고 함축해야 한다.

현실 세계를 요약 및 함축하여 공간 데이터로 재현하기 위해서 인간이 세상을 바라보는 관점이 작용하며, 다양한 공간정보 재현 관점이 있지만 그림 4에 제시한 바와 같이 두 가지 관점으로 구분할 수 있다[7]. 공간 내에서 특정 객체의 재현에만 집중할 것인지 또는 공간 전체에 대한 재현에 집중할 것인지에 따라서 구분할 수 있으며, 이는 이산적 객체 관점과 연속적 필드 관점으로 정의될 수 있다. 이산적 객체 관점은 뚜렷한 경계를 가지는 객체만을 재현하고, 그 외의 공간은 빈공간으로 바라보는 관점이다. 연속적 필드 관점은 공간상의 모든 위치에서 빈 공간이 없이 속성정보를 이용하여 현실 세계를 표현하는 관점이다.




FIGURE 4. Representation approach of spatial information

이산적 객체 관점은 차원성으로 구분되어 점, 선, 면적으로 표현된다. 최근에는 디지털 트윈 기술의 개발로 3차원으로 표현되기도 한다. 차원에

따라 표현되므로 벡터 데이터 모델과 강한 연관성을 가지고 있으며, 그림 4의 예시와 같이 도로, 건물 등을 필요한 차원에 따라 재현된다. 연속적 필드 관점은 공간적 변화 양상에 따라 이산적 유형과 연속적 유형으로 구분된다. 모든 지점에 대해 연속 또는 이산적 수치로 속성 정보를 표현하는 래스터 데이터 모델과 강한 연관성을 지니고 있다. 그림 4의 예시와 같이 이산적 유형에서는 토지피복, 연속적 유형에서는 수치 지표 모델이 있으며, 강수량 등을 표현하는데도 사용한다. 각 공간정보 재현 관점에 연관성이 강한 데이터 모델이 있지만 하나의 대상에 대해서도 목적에 따라서 이산적 객체 또는 연속적인 필드 관점에서 표현할 수 있다. 그림 5에 제시한 예시와 같이 산림 정보 구축에서 개별 수목 정보가 필요할 때는 이산적 객체 관점을, 산림의 유형 등을 표현하기 위해서 연속적 필드를 사용할 수 있다[49].




FIGURE 5. Example of representing spatial information for forest inventory (Mozgeris, 2009)[49]

2. UAV 및 GeoAI 기반 원격탐사

1) UAV 원격탐사 특징

가. UAV 개요 및 데이터 분석

UAV는 조종사가 직접 탑승하지 않은 비행체를 의미한다. 영어 명칭은 기술의 발전과 함께 다양한 용어가 사용되어왔다. 초기에는 드론(Drone)이나 원격조종비행체(RPV, Remote Piloted Vehicle)라는 용어가 주로 사용되었으며, 1990년대부터는 무인항공기시스템(UAS, Unmanned Aerial System)으로 용어가 사용되고 있다. 그 이외에도 유럽이나 기관에 따라 RPAV(Remote Piloted Air/Aerial Vehicle), RPAS(Remote Piloted Aircraft System) 등 다양한 명칭으로 불리고 있다. 현재 국내에서는 UAV 및 UAS 용어가 주로 사용되고 있다. 하지만 의미에 명확한 구분을 두고 있지 않고, 혼용해서 사용하고 있으므로 본 연구에서는 UAV로 용어를 통칭하였다.

UAV에 관한 전체 시스템은 그림 5에 제시한 바와 같이 무인비행부, 지상조종부, 영상처리부로 구성된다. 무인비행부는 비행을 위한 비행기체와 데이터 수집을 위한 센서로 구성된다. 비행기체는 크기, 형태, 용도 등에 따라 다양하지만 일반적으로 고정익(Fixed wing)과 회전익(Rotary wing) 기체로 구분할 수 있다. 고정익 기체는 비행기와 유사한 형태를 가지며, 회전익 기체보다 긴 거리에 대한 비행에 유리하다. 회전익 기체는 회전하는 날개인 로터를 가지고 있는 기체이며, 정지 비행이 가능하여 복잡한 도시 내에서도 많이 활용되고 있다. 센서는 카메라와 같은 2차원 영상 센서부터 라이다와 같은 3차원 센서까지 다양한 센서가 사용되고 있다. 지상조종부는 UAV의 움직임과 데이터

수집을 위한 센서를 조종하는 역할을 하며, 조종자와 조종기로 구성된다. 지상의 조종자는 UAV를 원격 조종할 수 있다. 무선 신호를 통해 UAV를 실시간으로 비행경로, 속도, 고도 등을 직접 조절해 정밀한 비행 제어나 돌발 상황에 빠르게 대응할 수 있다. 또한, UAV는 비행 전 프로그램을 통해 사전에 입력된 경로를 따라 자동 또는 반자동으로 비행할 수 있다. 이러한 비행 모드는 대규모 지역을 모니터링하거나 장시간 비행이 필요한 작업에 사용되고 있다. 영상처리부는 비행기체를 운용하기 위한 소프트웨어와 카메라 센서로부터 취득한 이미지 데이터에 투영법을 적용하여 정사영상을 제작하기 위한 소프트웨어로 구성되어 있다.




FIGURE 6. Components of UAV

UAV는 방재, 감시 등 다양한 분야에서 적용되고 있다. 특히, UAV는 학술적 성과와 관련 시장의 가파른 성장에 의해 최근 몇 년 동안 원격탐사(RS, Remote Sensing) 분야에서 계속 확장되고 있다[50]. 이는 데이터 수집과 사용되는 센서가 위성과 같은 기존 원격탐사 플랫폼보다 더 유연하게 적용할 수 있는 것이 특징이기 때문이다. 그림 7은 Elsenbeiss, (2009)[51]의 원격탐사 플랫폼별 측정범위 및 정확도를 범주화한 것으로, UAV는 위성 및 항공 기반 플랫폼과 지상 기반 플랫폼 사이의 전이 구간에 해당한다. UAV는 기존의 위성, 항공 및 지상 기반 플랫폼의 기술을 복합적으로 활용하고 있으므로 원격탐사 데이터 처리 및 분석 방법은 적용 분야에 따라 매우 다양하게 변주될 수 있다.




FIGURE 7. The accuracy of measurement methods in relation to the object/area size. (Elsenbeiss, 2009)[51]

UAV 내부의 하드웨어 및 소프트웨어의 발전에 따라 위치 정확성이 요구되는 사진측량에 필요한 정보를 손쉽게 취득할 수 있게 되었다[52][53][54]. 이는 UAV를 통해서 사진측량에 필요한 정밀한 위치 좌표와 함께 원격탐사에 필요한 데이터 수집 임무를 손쉽게 할 수 있게 되었다. 데이터 수집 측면에서 국가적 규모의 경우 여전히 위성과 항공기가 좋은 수단이지만, 지역 및 국지적 규모에서는 UAV는 기존 원격탐사 플랫폼보다 유연한 비행으로 원활한 데이터 수집이 가능하다. 또한, 기존의 다른 원격탐사 플랫폼보다 경량화 및 저가 센서를 장착 또는 교체할 수 있으므로 데이터의 제작 과정에서 필요한 비용을 절감할 수 있다.

UAV에서 주로 수집되는 데이터는 그림 8에 제시한 것과 같이 이미지 데이터로 3차원 세상에 존재하는 객체점들이 모두 하나의 중심점을 지나 2차원 평면에 투영된다. 그러나 이미지 처리를 통해서 객체 점들의 기하학적 위치 관계를 산출하고, 객체 점들이 평면에서 수직방향으로 투영되는 정사영상 제작과 함께 DSM 등 기하학적인 정보를 기존 원격탐사 플랫폼보다 원활하게 접근할 수 있다. 예를 들어, 위성영상과 같은 기존 원격탐사 플랫폼에서 이미지 분류 방법은 대부분 분광 정보를 다루는 2차원 이미지 특징 추출에 초점을 맞추지만, UAV 기반 이미지를 분류할 때는 이미지 정합 과정에서 추가로 제작할 수 있는 디지털 표면 모델(DSM, Digital Surface Model)을 통합해 기하학적인 정보를 추가하여 분류 정확도를 향상시킬 수 있다[55][56].

UAV는 저고도 비행을 통해서 상당히 넓은 영역을 수 cm 급의 공간해상도로 표현하는 초고해상도 영상을 활용한 관측이 가능하다. 관측된 물체에 대해 매우 상세한 정보를 쉽게 획득할 수 있으므로

정확한 기하학적 및 의미론적 분석이 진행될 수 있다. 하지만 공간 해상도의 증가가 데이터 해석 측면에서 항상 동일한 수준의 개선을 가져오는 것은 아니며, 데이터 구조의 복잡성의 증가와 연관되어 있다 [57][58][59][60]. 공간해상도가 높을수록 하나의 물체를 표현하는데 더 많은 픽셀이 필요하며, 이러한 수 많은 픽셀들이 각각의 물체와 연관된 이미지 구조와 배경 정보를 포함하기 때문이다. 일반적으로 UAV 기반 고해상도 영상은 픽셀 수가 수천만 개 이상인 경우가 많다. 이는 해당 공간에 대한 풍부한 정보를 뜻하기도 하지만 데이터의 복잡성 증가로 이어지므로 일반적인 원격탐사 분야에서 분류 정확도가 크게 떨어질 수 있다. 따라서, UAV 기반 고해상도 영상 분석의 경우 데이터의 복잡성을 처리할 수 있는 방안을 고려해야 한다.




FIGURE 8. Difference of Perspective and Orthogonal projection

앞서 서술한 내용을 정리하자면 UAV를 통한 데이터 수집은 (1) 초고해상도 이미지, (2) 기하학적 및 다중분광 데이터의 높은 가용성, (3) 다차원 데이터 분석을 위한 통합 센서 데이터라는 뚜렷한 특징이 나타날 가능성이 높다[61]. 이는 높은 공간해상도의 데이터, 다양한 데이터셋과의 융합으로 이려져 새로운 적용 분야 및 보다 타깃화된 분석에 적용할 수 있는 기반으로 활용할 수 있다.

나. UAV 센서 개요 및 적용 분야

일반적으로 UAV는 RGB 카메라가 장착되어 사용되고 있지만, 분석하는 목적에 따라서 다중분광, 초분광, 열화상 카메라, 경량 LiDAR(Light Detection and Ranging) 등 UAV 플랫폼에 적용할 수 있는 소형 또는 저가형 버전 센서들을 사용할 수 있다. 센서는 UAV 데이터의 특성과도 연결되므로 UAV에서 사용되는 다양한 센서들의 특성을 이해하면 원격탐사 분석에서 보다 좋은 결과를 도출할 수 있다. 다음 내용부터는 UAV에 탑재하여 데이터 수집이 가능한 RGB, 다중분광, 초분광, 열화상 카메라와 LiDAR에 대한 내용을 기술하였다.

첫 번째로, RGB 카메라는 일상생활에서 흔히 사용하는 카메라와 마찬가지로 빨강(Red), 녹색(Green), 파랑(Blue) 세 가지 색상 채널로 구성되며, 원격탐사 분야에서 가장 일반적으로 사용되는 센서 중 하나이다. UAV 센서 중에서도 가장 접근하기 쉬운 센서로 엔터테인먼트 및 방송, 영화와 같은 다른 대중적인 용도로도 많이 활용하고 있다. RGB 카메라의 장점은 다양한 수준의 비용, 해상도, 높은 가용성, 다양한 플랫폼에 쉽게 통합되는 점, 비디오 제공 등이 있다. 단점으로는 많은 상용화 제품에서 렌즈의 기하학적 왜곡 보정을 위한 해법이 함께 제공되지 않으며, RGB 카메라는 낮은 분광해상도와 함께 색상 정보만 제공하므로 특정 분야에서 필요한 파장대별 분광 정보, 표면 온도 등의 추가 정보를 얻기 어렵다. 따라서 접근이 매우 쉬운 장점이 있지만 식생 상태, 토양 습도, 열 특성과 같은 고급 분석에는 한계가 있다.

RGB 카메라는 표 2에 제시한 것과 같이 UAV 기반 원격탐사 분야에서 시각적 분석, 사진측량 매핑, 토지이용, 객체 탐지, 추적 등에

적용되고 있다. 제시한 선행연구를 살펴보면 RGB 카메라를 사용하는 UAV 기반 원격탐사 분야는 고해상도 이미지를 통해 제작된 정사영상을 활용해서 시설물 점검과 같이 시각적 분석을 목적으로 주로 사용되고 있다. 그리고 높이 값을 나타내는 DSM을 이용해 농작물 모니터링, 개별 수목 탐지 등 기존 RS 플랫폼에서 진행하기 어려운 객체에 대해서 분석이 진행되며 적용 분야가 확장되고 있다.

TABLE 2. RS application example for a UAV with an RGB camera

Applications	Basic data	Reference
Topographic Surveying	Orthophoto map, DSM	[62][63] [64][65]
Building detection	Orthophoto map, DSM	[66]
Coastal garbage monitoring	images	[67]
River change detection	Orthophoto map, DSM	[68]
Facility inspection	images	[69]
Surface velocity measurement	images	[70]
Forest damage monitoring	Orthophoto map, DSM	[71][72]
Individual tree and information Extraction	Orthophoto map, DSM, DEM	[73]
Crop monitoring	Orthophoto map, DSM, DEM	[74][75][76]
3D modeling	3D model, DSM, DEM	[77][78]

두 번째로, 다중분광 카메라는 일반적으로 식생에 대한 특성이 잘 드러나는 적색(Red) 및 근적외선(NIR) 대역의 분광 정보를 매우 높은 공간해상도로 얻을 수 있는 센서이다. 이러한 장점으로 다른 UAV 센서 제품군에 비교해서 RGB 카메라와 함께 가장 일반적으로 사용되는 센서 중 하나이다. RGB 카메라도 3개의 밴드를 이용해서 식생 분석을 위한 식생지수를 제공할 수 있지만^[79], 식물의 엽록소 수준에 대한 분광 감도가 낮아 정교한 분석에 한계가 있다. 그러나 다중분광 카메라는 RGB 카메라보다 분광해상도가 높으므로 식물의 건강 상태에 대한 정량화나 질병 탐지 등 보다 정교한 분석에서 활용되고 있다.

다중분광 카메라는 그림 9와 같이 엽록소의 빛에 대한 흡수와 반사 특성을 이용해 Red, NIR, 그리고 Rededge 밴드와 같은 식생과 관련된 물리적 특성에 대한 특정 파장 대역을 수집해서 NDVI(Normalized Difference Vegetation Index), GNDVI(Green Normalized Difference Vegetation Index), SAVI(Soil Adjust Vegetation index), NDRE(Normalized Difference Red-Edge)와 같은 다양한 식생지수를 산출해 활용할 수 있다^[80]. 이러한 다중분광 카메라는 사진측량 기법을 통해서 쉽게 처리할 수 있고, 정사영상과 DSM을 제작할 수 있다. 다만, RGB 카메라와 달리 다중분광 카메라는 RGB 파장 대역 외에도 파장 대역을 수집하기 위한 하드웨어 추가로 인해 일반적으로 더 높은 비용이 발생한다. 또한, 주로 식생 및 농업 전문가를 위한 제품들이 대부분으로 사용이 가능한 제품의 종류가 RGB 카메라에 비해 훨씬 적다. 이로 인해서 이미지 데이터 전처리부터 정사영상 등 원활한 처리를 위한 소프트웨어는 특정 다중분광 센서 모델에 제한되어 있지만, 점점 데이터가 표준화되고 처리하기 쉬워지는 추세에 있다.




FIGURE 9. Spectral reflectance characteristics of vegetation

UAV 기반 다중분광 카메라는 표 3에 제시한 것과 같이 기존 원격 탐사 분야에서 다중분광 영상을 기반으로 수행하던 작업을 수행할 수도 있다. 또한, 낮은 고도의 비행을 통해 수집된 데이터는 기존 원격탐사 분야에서는 일반적으로 얻을 수 없는 훨씬 더 높은 해상도의 데이터를 얻을 수 있다. 이를 통해 기존 원격탐사에서 주로 수행하던 토지피복/이용 분류, 변화 탐지 외에도, 다중분광 카메라는 높은 수준의 공간 해상도를 이용해 잎 수준의 질병 평가, 유해 조류(Algae) 번식 연구와 같이 농업 및 수질 평가에서 더 자세한 공간적인 분포를 볼 수 있는 새로운 적용 분야에 대한 연구가 진행되고 있다.

TABLE 3. RS application example for a UAV with an multi-spectral camera

Applications	Basic data	Reference
Weed mapping	Multispectral orthophoto,	[81]
Nitrogen estimation	Multispectral orthophoto,	[82]
Biomess estimation	Multispectral orthophoto, Vegetation index, Texture metrics	[83]
Crop monitoring	Multispectral orthophoto,	[84]
Water Quality	Multispectral orthophoto, Vegetation index	[85]
Algal bloom monitoring	Multispectral orthophoto, Vegetation index	[86]
aquatic plants detection	Multispectral orthophoto, Vegetation index	[87]
Land cover/use mapping	Multispectral orthophoto, Vegetation index, DEM	[88][89]
Forest monitoring	Multispectral orthophoto, Vegetation index	[90]
Forest burn severity monitoring	Satelite images, Multispectral orthophoto	[91]
Tree disease detection	Multispectral orthophoto, Vegetation index	[92]

세 번째는 초분광 카메라로 수십 또는 수백개의 분광 파장 대역에 대해서 정보를 수집하는 센서를 의미한다. 일반적으로 전체 분광 파장 대역에서 몇 개의 파장 대역만 선택해서 수집하는 파장 대역의 개수가 10개 미만으로 구성된 다중분광 카메라와 차이점이 있다. 초분광 카메라는 그림 10과 같이 일반적으로 4가지 형태로 각 파장대역을 수집하고 있지만[93], UAV에 장착되는 대부분의 경량 초분광 카메라는 그림 10의 B와 같이 물체에서 반사되어 나오는 광의 세기를 선형으로 분광 정보를 취득하고 있다[94][95]. 또한, UAV에 장착이 가능한 경량 초분광 카메라는 보통 5-10mm 대역폭에 대한 분광해상도를 가지고 있다.




FIGURE 10. Typical hyper-spectral imaging approaches (Wang et al., 2017)[92]

초분광 카메라는 많은 양의 정보를 수집하기 때문에 의심할 여지 없이 환경 모니터링, 농업, 지질학 등 다양한 원격탐사 분야에서 매우 유용하지만, 다중분광 카메라와 비교할 때 초분광 센서에는 몇 가지 한계점이 있다[61][96]. (1) 높은 분광해상도는 공간해상도를 희생시키며, 일반적으로 동등한 페이로드 수준의 RGB 카메라보다 공간해상도가 상대적으로 많이 낮다. (2) 높은 분광해상도로 인해 필요한 정보 외에도 과도한 데이터 수집으로 인해 데이터의 복잡성이 증가하며, 이는 처리와 분석에 더 많은 시간과 노력이 필요해진다. (3) 높은 분광해상도를 얻기 위해서 구성되는 하드웨어는 경제성 측면에서 다른 UAV 센서에 비해 높은 초기 투자 비용이 필요하며, 유지 관리와 데이터 처리 소프트웨어 등 비용이 추가적으로 발생한다. (4) 마지막으로 초분광 카메라는 일반적으로 사용하는 다중분광 카메라보다 무겁고 크기가 크고, 더 많은 전력을 소비할 수 있으므로 드론의 비행시간에 영향을 주어 작업 시간에 대한 제한으로 이어질 수 있다.

한계점 (1)의 경우 비행 계획에 따라서 촬영 범위를 희생하면 획득한 이미지의 공간해상도가 2-5cm 수준에 도달할 수 있기 때문에 극복할 수 있는 문제이다. 하지만 한계점 (4)와 관련되어 넓은 지역에 대한 분광 정보를 취득해야할 경우 작업 시간이 비약적으로 증가할 수 있다. 하지만 이러한 몇 가지 단점이 존재하더라도 초분광 정보는 DSM과 같은 데이터와 같이 다른 데이터와 결합하여 훨씬 더 높은 공간/시간 해상도로 식물 질병 조사, 농업, 도시 환경 등 보다 정확한 분류 및 모니터링에 사용할 수 있다(표 4).

TABLE 4. RS application example for a UAV with an hyper-spectral camera

Applications	Basic data	Reference
Crop disease detection	Hyperspectral orthophoto	[97]
Tree species classification	Lidar point cloud, hyperspectral orthophoto	[98]
Vegetation classification	Hyperspectral orthophoto	[99]
Tree disease detection	Hyperspectral orthophoto	[100]
Land cover classification	Hyperspectral orthophoto	[101]
Water quality prediction	Hyperspectral orthophoto	[102]
Water depth measurement	Hyperspectral orthophoto	[103]

네 번째로, 열화상 카메라는 중적외선 범위의 파장 대역을 수집해 자연적인 열방출을 전자적으로 측정하여 이미지로 제공하는 패시브 센서이다. 열화상 카메라는 UAV에 장착되어 사용되면서 항공 열화상을 제공하여 다양한 물체의 표면 온도 및 열 방출 측정에 광범위하게 활용된다. 여기서 중요한 점은 육안으로 볼 수 없는 온도 정보를 이미지 형태로 제공한다는 것이다.

UAV 탑재 센서의 경우, 대기 영향을 무시할 수 있고, 실험실 수준의 보정이 더 용이하며, 이론적으로 더 정확한 온도 측정이 가능하다[104]. 다만 UAV 특성상 제한된 페이로드를 고려할 때 경량 열화상 카메라에서는 일반적으로 냉각식 감지기가 제공되지 않아, 캡처 속도, 공간 해상도, 감도가 낮아질 수 있다. 이는 신호 대비 잡음비 감소를 보상하는 한편, 열화상 센서의 기능에 제약을 가할 수 있다. 그럼에도 불구하고, 낮은 비행 고도와 쉬운 운용상의 특징으로 UAV 탑재 센서

데이터의 시간적, 공간적 해상도가 더 높기 때문에 작은 물체를 정확하게 정량화할 수 있다.

열화상 카메라와 다른 스펙트럼 범위의 센서(예: 가시광선 대역 및 다중분광 대역)를 통합을 통해서 다양한 농업 및 환경 분야에 적용 및 활용할 수 있다(표 5). 시중에서 판매되는 여러 열화상 카메라들은 사람, 화재, 파이프 누수 감지와 같은 작은 물체를 정량적으로 평가하기도 하며, 산림 모니터링, 식생 스트레스 감지, 식물 표현형 분석 등의 잠재력을 평가하고 테스트하는 데 사용되고 있다.

TABLE 5. RS application example for a UAV with an thermal infrared (TIR) camera

Applications	Basic data	Reference
Crop monitoring	RGB orthophoto, TIR orthophoto	[105]
Human body detection	TIR images	[106]
Human and fire detection	TIR images	[107]
Water stress detection	RGB orthophoto, TIR orthophoto	[108]
Leak detection	TIR orthophoto	[109]
Micro climate analysis	TIR orthophoto, Multispectral orthophoto	[110][111]

마지막으로, LiDAR 센서는 빛의 속도를 이용하여 물체와의 거리를 측정하는 센서이다. 이러한 시스템은 스스로 에너지를 방출하고, 반사된 신호를 수신하여 정보를 수집하기 때문에 액티브 센서로 분류된다. 따라서 태양과 같은 외부 광원을 통해서 오는 빛의 반사를 측정하여 생성하는 RGB, 다중분광 카메라와 같은 패시브 센서와는

다른 특성을 가진다. 측정 원리는 특정 대상이나 표면에 레이저를 발사하고, 반사된 빛의 신호가 센서로 돌아오는 시간을 측정함으로써 위치 정보를 획득한다. 이러한 과정을 통해 LiDAR는 물체의 거리, 형상, 표면 특성 등의 3차원 모델에 대한 세부 정보를 수집할 수 있다. 또한, 반사 특성을 이용해 나무 수관을 부분적으로 관통하여 지상의 표면 정보를 얻을 수 있어 수목이 밀집되고, 지상 표면이 잘 보이지 않는 지역의 경우 사진을 이용한 사진측량보다 유리한 장점이 있다[112].

이러한 LiDAR 센서는 UAV에 장착되어 정밀한 기하학적인 데이터 수집을 위한 수단으로 사용되고 있으며, 산림, 문화 유산, 건축 정보 모델링, 안전 등에서 널리 사용되고 있다(표 6). 그리고 이미지 기반 사진측량에 비해 높은 신뢰성을 가지고 있고, 여러 번의 반사를 통해 나무 아래의 정보도 취득할 수 있는 장점이 있다.

TABLE 6. RS application example for a UAV with LiDAR

Applications	Basic data	Reference
Forest monitoring	Point Cloud	[113][114][115]
Disaster monitoring	Point Cloud	[116]
Survey for the ground and topographical model	Point Cloud, RGB	[117][118][119]
Inspection of infrastructure	Point Cloud	[120][121]
Building information modeling (BIM)	Point Cloud	[122]

2) GeoAI 기법

가. 기존 원격탐사 플랫폼의 GeoAI 적용 기법

위성과 같은 기존 원격탐사 플랫폼에서는 공간해상도가 30m 이상인 낮은 해상도로 인해서 분류 대상에서 다양한 비율로 반사되는 빛들이 혼합되어 하나의 픽셀로 표현된다. 그래서 픽셀 기반 분류(Pixel-based Classification)은 하나의 픽셀을 입력자료로 사용하여 기존 원격탐사 데이터 분석에서 널리 사용되어 왔다. 이 방법은 크게 무감독분류와 감독분류로 나눌 수 있다. 무감독분류는 클러스터링이라고도 불리며, 정답 값을 정의하지 않고 비슷한 유형의 그룹으로 분류하는 기법이다. 반면, 감독분류는 사용자가 분류 항목과 각 항목에 대한 정보를 입력하여 픽셀을 기반으로 정답 값을 예측하기 위해 사용한다. 본 연구에서는 일반적으로 기존 원격탐사에서 많이 활용되고 있는 감독분류에 대해서 정리하였다.

감독분류는 초기에 최대우도법, 베이지안 결정 모형 등과 같이 단순한 분류기를 통해서 원격탐사 데이터 처리에 사용됐다[123][124]. 그 후 기계학습 기반 분류기가 더 좋은 성능을 보이는 것으로 입증되면서 원격탐사 데이터 분석에서 널리 사용되고 있다. 본 연구에서는 최근 원격탐사에서 많이 사용되고 있는 RF(Random Forest), ANN(Artificial Neural Network)에 대해서 정리하였다[125]. RF는 그림 11에 제시한 바와 같이 다수의 의사결정 나무를 결합하여 예측하는 기계학습 모델이다. 각각의 나무가 학습 데이터의 서로 다른 부분 집합에 대해 학습하고, 최종적으로 이들의 예측을 결합하여 보다 정확한 예측을 도출하는 앙상블 방법이다. RF는 배깅(Bootstrap

Aggregating) 기법을 사용해서 각각의 의사결정 나무를 각각의 데이터셋에 대해서 독립적으로 학습된다. 최종적으로 각 나무의 예측은 투표 또는 평균을 통해 결합해 최종 예측 결과를 출력한다. 하나의 의사결정 나무는 비교적 단순한 모델이므로 학습 데이터의 노이즈나 이상치에 민감할 수 있지만 수백 개 이상의 나무를 결합해 노이즈에 대한 민감도가 상쇄되고, 안정적인 결과를 도출할 수 있다. RF의 다른 중요한 특징은 변수 중요도를 평가할 수 있다는 것이다. RF는 각 변수가 예측에 얼마나 중요한지 평가할 수 있으며, 이를 통해서 입력 데이터의 중요한 특성을 파악할 수 있다.




FIGURE 11. Diagram of Random Forest

ANN은 그림 12에 제시한 바와 같이 인간의 신경계 구조와 원리를 모방하여 개발된 기계학습 모델이다. 이 모델은 인간의 뇌에서 뉴런들이 서로 신호를 주고받는 방식을 기반으로 하며, 뉴런들은 특정 임계값을 초과할 때에 신호를 전송하는 방식으로 작동한다. ANN에서 뉴런에

해당하는 각 노드는 입력 신호의 합에 대해서 비선형 함수를 사용해 출력값을 생성한다. 비선형 함수는 활성화 함수로 신경망의 복잡한 패턴을 학습하고 모델링하는 것에 사용된다. ANN의 기본 구조는 입력층, 은닉층, 출력층의 세 가지 주요 층으로 구성된다. 입력층은 원시 데이터를 받아들이고 신경망으로 전달하는 역할을 한다. 은닉층은 입력층과 출력층 사이에 위치하며, 복잡한 데이터에 대해서 패턴과 관계를 생성하는 역할을 한다. 입력 데이터가 가중치와 결합되고, 활성화 함수를 통해 변형되며 뉴런과 같이 노드 간에 신호를 주고받게 된다. 은닉층은 모델의 학습 능력을 결정하며, 여러 층으로 구성될 수 있다. 마지막으로 출력층은 신경망의 최종 결과를 제공하는 역할을 한다. 목적에 따라 다양한 형태를 취할 수 있으며, 대표적으로 분류 또는 회귀에 대한 예측값을 생성한다. ANN은 가중치와 편향 매개변수를 학습해서 입력 데이터에서 원하는 출력값을 예측한다. 그리고 학습 과정은 오류 역전파 알고리즘과 경사하강법을 사용하여 매개변수를 조정하고 모델의 예측 오류를 최소화하는 방식을 사용한다.




FIGURE 12. Diagram of Artificial Neural Network

나. 고해상도 원격탐사 플랫폼의 GeoAI 적용 기법

고해상도 영상은 하나의 물체를 표현하는데 수 많은 픽셀들이 이미지 구조와 배경 정보를 표현하면서 분광 특성의 복잡성이 증가하므로 기존의 개별 픽셀을 기반으로 분류할 경우 정확도가 떨어질 수 있다[126]. 다만 UAV를 통해 수집된 원격탐사 데이터는 기존 원격탐사 플랫폼인 항공기 및 위성에서 사용하는 원격탐사 센서와 크게 다르지 않다. 하지만 상기 언급한 바와 같이 UAV를 기반으로 수집된 데이터는 기존 플랫폼에 비해 매우 높은 공간해상도를 가지고 있어 효과적으로 원격탐사 데이터를 분석할 수 있는 방안이 필요하다.

객체 기반 영상 분석은 기본 분석 단위를 개별 픽셀 대신 객체를 기반으로 분석이 수행된다(그림 13). 이러한 객체 기반 영상 분석은 영상분할과 특징 추출 및 분류로 진행되는 두 단계로 진행된다. 영상분할은 영상 내에서 의미 있는 객체를 형성하기 위해 동질적인 픽셀들을 더 커다란 연속적인 영역으로 그룹화하여 하나의 객체로 만든다. 각 객체는 분류의 기본 단위로 사용되고, 각 분류에 대한 경계를 생성하기 때문에 영상분할은 객체 기반 영상 분석에서 가장 기본적이고 중요한 단계로 인식된다[127]. 이로 인해 객체를 기반으로 한 특징 추출 및 분류 정확도는 영상분할의 품질에 따라 결정될 수 있다[128]. 영상분할을 통해 제작된 객체에서 통계적, 지리적, 형태학적 특성들을 추출하여 분류를 위한 학습 데이터로 사용할 수 있다. 객체 기반 영상 분석은 영상분할을 통해 생성된 객체를 통해 고해상도 영상의 복잡성을 처리할 수 있다. 또한, 객체를 통해서 지리적, 형태학적 특성들을 추가로 활용할 수 있게 되면서 기존 픽셀 기반 분류보다 더 다양한 변수를 통해 원격탐사 데이터를 분석할 수 있으며, 하나의

객체를 마치 하나의 픽셀처럼 간주하여 분석하기 때문에 데이터를 분류하기 위해 기존 픽셀 기반에서 사용하는 분류기들을 사용할 수 있는 장점이 있다. 다만, 적절한 영상분할을 하기 위해 필요한 매개변수를 찾기 위해서는 시행착오법을 통해 진행할 수 밖에 없어 분석 과정의 복잡성이 증대하고, 객체가 적절하게 분할되었는지와 같은 분할 수준에 대한 결정이 어려운 문제가 존재하고 있다.




FIGURE 13. Procedure of Object-based Image Analysis

딥러닝(Deep Learning)은 합성곱 신경망(CNN, Convolutional neural networks)을 통해서 이미지 분류, 물체 감지 등 다양한 컴퓨터 비전 분야에서 획기적인 발전을 이루었다. 또한, 이는 원격탐사 분야에서도 빠르게 적용되어 매우 강력한 수단으로 자리를 잡고 있다. 기존의 원격탐사에서 많이 사용되고 있는 RF, SVM, ANN 등과 같은 기계학습 분류기들은 기본적으로 1차원 형태의 데이터를 입력으로 사용한다. 이에 따라 2차원 데이터 형태의 이미지는 입력으로 사용하기 위해서 이미지 정보를 1줄로 펼쳐서 입력값으로 사용해야 하므로 이미지의 공간적/위상(지역적) 정보가 손실되게 된다. 반면에 합성곱 신경망은 이미지를 2차원 형태 그대로 입력값으로 받으므로 공간적/지역적 정보를 유지하여 특성(Feature)들의 계층을 구축할 수 있다. 또한, 합성곱과 풀링 과정을 반복 적용해 이미지에서 추상화된 정보를 추출하여 이미지의 위치, 밝기, 방향 등 다양한 형태의 변화에도 인식할 수 있다.

원격탐사 분야에서 딥러닝을 이용한 영상분류는 시각적 장면에 있는 객체가 무엇인지, 객체가 어디에 있는지 인식해야 한다. 따라서 딥러닝에서 영상분할은 각 픽셀을 특정 개체로 분류하여 영상이 의미를 가지는 영역으로 분할시키는 것을 목표로 하여 픽셀 수준의 분류가 진행되며[129], 딥러닝은 의미론적 분할(Semantic Segmentation)과 객체 분할(Instance Segmentation)이 주로 사용되고 있다(그림 14). 의미론적 분할은 이미지의 각 픽셀에 레이블을 할당하는 것으로, 같은 종류의 객체에 속하는 모든 픽셀이 같은 레이블로 분류된다. 이러한 방식은 영상 내에서 개별 객체의 정확한 경계를 파악하는 것에 초점을 맞추고 있다. 객체 분할은 의미론적 분할에서 한 단계

더 나아가, 영상 내에서 동일한 클래스에 속하는 개별 객체를 구분한다. 즉, 영상 내의 개별 객체에 대해 레이블을 할당하게 되며, 객체의 정확한 윤곽뿐만 아니라 서로 다른 객체도 구분한다.




FIGURE 14. An example of different visual perception between semantic and instance segmentation (Feng et al. 2019)[127]

Ⅲ. 토지피복 및 수목 공간정보 구축 방법

1. UAV 영상 수집 및 전처리

1) UAV 비행 및 데이터 수집

가. 수집 데이터 선정

2장에서 전술된 UAV 기반 원격탐사에 대한 이론적 고찰을 바탕으로 본 연구에서 환경공간정보로 구축하고자 하는 토지피복과 수목에 대한 UAV 기반 데이터 수집 방법을 고찰하였다. 도시 환경은 다양한 불투수면, 식생, 수역, 나지 등을 포함한 다양한 토지피복 유형이 분포하며, 그림 11에 제시한 것과 같이 복잡한 분광 특성을 가지고 있다[130]. 토지피복에서는 동일한 지붕으로 분류가 될 수 있지만 빨간색, 검정색과 같은 색상 차이 외에도 지붕 재료에 의해서도 다른 분광 특성을 보이므로 이를 효과적으로 분류할 수 있는 데이터 수집이 필요하다. Herold et al. (2002)[130]은 위성영상을 통해 가시광선과 근적외선 파장 대역이 도시의 토지피복 분류에 효과적일 수 있음을 보고하였다.




FIGURE 15. Spectral signatures of different urban land cover types acquired with field spectrometer (Herold et al. 2002)[130]

UAV를 이용한 토지피복 분류에서도 탑재 센서를 통해 다양한 물리적 특성을 표출하는 데이터를 수집하는 것이 중요할 것으로 판단된다. 다중분광 카메라를 이용해 가시광선 및 근적외선 파장 대역 영상을 수집할 수 있으며, 영상 조합을 통해 식생지수도 활용할 수 있다. 또한, 피복별로 열용량이 다르므로 열적외 카메라를 이용할 수 있다[131]. UAV는 이미지 접합 과정에서 DSM과 같은 기하학적 특성을 보유한 영상을 제작할 수 있다. UAV는 위성영상보다 고해상도 영상을 제작하므로 UAV 기반 분광 및 기하학적 영상이 토지피복 분류에 기여할 수 있는지 분석이 필요하다.

수목 조사는 주로 산림을 대상으로 수행되고 있으며, 대부분 현지 조사에 의존하므로 표본점 위주로만 그 활용이 제한된다[132][133]. 이를 보완하기 위해 개별 수목 영역의 탐지는 위성영상 또는 항공 사진의 분광정보를 이용하거나, 항공 LiDAR를 이용하는 방법이 사용되었다[134][135][136]. 항공 LiDAR를 사용했을 때는 평균 90% 이상의 정확도로 수목 개체수를 추정하였다. 그리고 UAV에서도 RGB 카메라를 통해 RGB 영상과 DSM 영상을 제작하여 산림을 대상으로 50%의 수목 개체수 추출율을 보고하였다[137]. 수목의 개체 수를 추정하기 위해서는 수목의 구조 특성을 정밀하게 표현할 수 있는 3차원 위치정보 수집이 필요할 것으로 판단된다. 수목 단위의 도시녹지는 도시의 다양한 토지 피복에서 개별 수목 영역을 추출하는 것도 중요하지만, 수목의 생태적 가치를 평가할 수 있는 흉고직경, 수고와 같이 수목의 구조를 속성 정보로 구축하는 것이 중요하다. 따라서 안정적 비행이 가능한 회전익 UAV와 함께 정밀한 3차원으로 위치정보를 수집할 수 있는 LiDAR 센서를 사용을 검토해야 할 것으로 판단된다.

나. UAV 및 센서 활용 데이터 수집

토지피복과 수목에 대한 데이터를 수집하기 위해 사용한 UAV 및 센서 장비는 표 7에 제시하였다. 복잡한 물리적 특성을 가지는 토지 피복을 분류하기 위해서는 다양한 물리적 특징을 표출하는 UAV 영상 수집이 필요하다. 따라서 다중분광, 열적외, RGB 카메라를 탑재한 고정익 UAV를 통해서 영상을 수집하였다. 수목의 경우 수고, 수관면적, 흉고직경과 같이 수목의 구조를 속성정보로 구축해야 하므로 정밀한 3차원 위치정보가 필요하다. 따라서 안정적인 비행이 가능한 회전익 UAV에 LiDAR 센서를 탑재하여 포인트 클라우드 및 RGB 이미지를 취득하여 활용하였다.

UAV 비행 및 촬영은 토지피복의 경우 구름이 없고 맑은 날인 2021년 6월 21에 진행하였다. 비행 조건은 Duet-T 카메라를 사용할 때는 열적외 카메라의 GSD(Ground Sample Distance)를 20cm/px로 설정하였고, RedEdge-MX 카메라를 사용 시에는 GSD를 13cm/px 조건으로 비행을 진행하였다. 그리고 촬영 이미지의 종 및 횡 중복도는 75%가 되도록 비행 경로를 설정하였다. 수목 정보의 경우 종 및 횡 중복도는 70%로 설정하고 LiDAR 포인트 클라우드 밀도가 591 point/m²로 비행을 진행하였다. 비행 일시는 2023년 8월 18일에 진행하였다. UAV 영상의 위치 정확도 보정은 창원대학교에서 총 25개의 지상기준점을 취득하여 토지피복 대상지에 활용하였고, 그중 6개는 수목 대상지에서 활용하였다.

TABLE 7. Specifications of UAV and Sensor

Category		Features	Image
Land Cover Mapping			
UAV	Name	eBee X	
	Type	Fixed wing UAV	
	Weight	Approx. 1.4 kg	
	Wingspan	116 cm	
	Max. flight time	90 min	
Sensor (1)	Name	RedEdge-MX	
	Type	multispectral camera	
	Specific band	Blue (475±20 nm)	
		Green (560±20 nm)	
		Red (668±10 nm)	
		Rededge (717±10 nm)	
		NIR (840 ± 40 nm)	
Image Res.	1,280 x 960 px		
Sensor (2)	Name	Duet-T	
	Type	TIR and RGB camera	
	RGB Res.	5,472 x 3,648 px	
	Thermal Res.	640 x 512 px	
	Individual Tree Detection		
UAV	Name	Matrice 300 RTK	
	Type	Rotary wing UAV	
	Weight	Approx. 6.3 kg	
	Size	89.5 cm	
	Max. flight time	55 min	
Sensor	Name	Zenmuse L1	
	Type	LiDAR sensor and RGB camera	
	Ranging Acc.	3 cm @ 100m	
	Max. return supported	3	
	RGB Res.	5472 x 3078 px	

2) UAV 영상 및 기초 분석 데이터 제작

가. 정사영상 제작 및 전처리

수집한 UAV 이미지는 Pix4D Mapper S/W를 이용하여 정사영상으로 제작하였다. RedEdge-MX에서 취득된 이미지는 각 분광 파장대별로 Red, Green, Blue, Rededge, NIR 정사영상을 제작하였다. RGB 이미지의 경우 RGB 정사영상과 함께, 지형의 특성을 나타내는 DSM(Digital Surface Model), DTM(Digital Terrain Model) 영상을 제작하였다. 마지막으로 열적외 센서에서 취득된 이미지는 LST(Land Surface Temperature) 영상을 제작하였다. 또한, LiDAR를 취득된 포인트 클라우드는 DJI Terra S/W를 통해서 전처리를 하고, ArcGIS pro S/W를 통해서 노이즈를 제거한 후에 지상 포인트 분류를 통해서 DSM과 DTM을 제작하였다.

토지피복 분류를 위해 다중분광 영상을 기반으로 ArcGIS pro S/W의 Raster calculate tool을 통해 식생과 비식생을 구분하는데 효과적인 식생지수인 NDVI와 SAVI를 제작하였다.

NDVI는 녹색 식물의 양을 측정하기 위해 널리 사용되는 대표적인 식생지수이다(식 1). 이 지수는 Red 및 NIR 파장 대역을 사용하며, -1에서 1사이 값으로 값이 클수록 식생이 더 조밀하고 건강함을 나타내는 지수이다. 또한 엽록소가 광합성을 위해 Red 파장 대역은 흡수하고 NIR 파장 대역은 반사하기 때문에 광합성 및 바이오매스 생산과 상관관계가 있는 엽록소 함량에 민감하다. 식생 지역과 비식생 지역을 구분하는데 효과적으로 사용될 수 있으며, 다양한 공간 및 시간 해상도로 토지피복 분류를 위해 Landsat, Sentinel, MODIS 등 다양한

위성에서 광범위하게 사용 가능한 지수이다. 다만 토양 배경 반사율, 대기 영향, 바이오매스 밀도가 높은 지역의 포화도 등의 영향을 많이 받는 한계점도 존재한다.

$$NDVI = \frac{NIR - Red}{NIR + Red} \quad (1)$$

SAVI는 토양 배경 반사율의 영향을 고려한 수정된 NDVI 버전이다(식 2). 토양 밝기 보정 계수(L)을 사용하여 토양 변화가 식생지수 값에 미치는 영향을 줄인다. Landsat 위성영상으로부터 파생된 SAVI는 대부분의 토지피복 유형을 수용하기 위해 토양 밝기 보정 계수(L)을 0.5로 정의하고 있으며, Red와 NIR 값 사이의 비율로 계산한다[138]. 범위는 -1에서 1까지이며, NDVI와 비슷한 값의 범위를 가지고 있으며, 토양 밝기 보정계수로 인해 식생이 희박하거나 혼합된 지역에서 식생을 더 정확하게 추정할 수 있다.

$$SAVI = \frac{NIR - Red}{NIR + Red + L} \times (1 + L) \quad (2)$$

수목의 경우 RGB 영상을 통해 제작할 수 있는 ExG(Excess Green Vegetation Index)를 제작하여 활용하였다. ExG는 RGB 영상에서 Green 파장을 Red 및 Blue 파장과 대비하여 식물과 토양을 구분할 수 있는 식생지수이다(식 3). RGB 영상은 공간해상도는 매우 우수한 반면, 분광해상도는 낮아 식생의 특성을 확인하는데는 NDVI 또는 SAVI와 같은 지수에 비해 불리하지만 UAV에서 대부분 사용하고 있는 RGB 카메라를 통해서 제작할 수 있다는 장점이 있다.

$$ExG = (2 \times Green) - (Red + Blue) \quad (3)$$

지상의 물체에 대한 구조적인 특성을 반영하기 위해서 지형 및 지물의

특성을 나타내는 DSM과 DEM을 사용하여 nDSM 영상을 제작하였으며, 토지피복과 수목 정보 구축 모두에 사용하였다(식 4). nDSM은 DSM과 DTM의 차연산을 통해 지면에 의한 높이 영향을 제외하여 지물에 대한 높이 값만을 표시한다.

$$nDSM = DSM - DTM \quad (4)$$

제작된 정사영상들은 선행연구를 참고하여 분할 및 분류 단계에서 잠재적인 이상 값의 영향을 줄이고, 동일한 가중치로 반영되기 위해 수치형 데이터의 상대적 크기를 제거하였다[139]. ArcGIS pro S/W의 Raster calculator tool을 통해서 모든 영상의 범위를 0에서 255까지 8bit 범위로 선형 밴드로 정규화하여 활용하였다.

마지막으로 모든 영상의 공간해상도를 동일하게 리샘플링하였다. 다만 각 연구 주제에 따라서 비행조건이 상이하고, 목적이 다르므로 각 주제에 해당하는 공간해상도로 조정하였다. 토지피복 매핑의 경우 조경을 위해 식재되어 있는 도로 사이의 조경식생까지 인식하기 위해 식생의 특성을 효과적으로 파악할 수 있는 다중분광 영상을 기준으로 GSD를 15cm/px로 통일하였다. 수목 탐지의 경우 수목의 잎과 나무에 대해서 효과적으로 판단할 수 있도록 GSD를 4cm/px로 리샘플링하여 사용하였다.

나. 영상분할

본 연구에서는 모든 사례연구에서 객체 기반 영상 분석 기법을 사용하였다. 객체 기반 영상 분석은 고해상도 영상의 복잡성을 처리하고자 영상분할을 통해서 픽셀이 아닌 객체를 분류 단위로 사용한다. 따라서 객체 기반 영상 분석을 진행하기 위해서는 영상분할이 필수적으로 진행되어야 한다. 영상 분할은 미세한 픽셀 단위가 아니라 더 커다란 연속적인 영역으로 모든 데이터의 특징들을 유지하기 위해 래스터 데이터 내의 영역을 일반화한다. 각 객체는 분류 항목에 대한 경계를 생성하기 때문에 객체 기반 영상 분석의 신뢰성은 적절한 영상 분할로 결정되며, 분할 결과에 따라 분류 정확도가 달라질 수 있다[140].

본 연구에서는 ArcGIS pro S/W에서 제공하는 영상분할 도구를 사용하였다. 영상분할 도구는 총 3가지의 파라미터를 이용하여 픽셀들을 묶어 객체로 생성한다. 픽셀들을 클러스터링하기 위해 평균 이동 알고리즘(Mean Shift Algorithm)이 사용된다. 도구에서는 분광 값과 공간적 근접성에 대한 평활화(Smoothing) 가중치로 분광 세부 묘사(Spectral detail)와 공간 세부 묘사(Spatial detail)가 1부터 20 사이의 값으로 제공된다. 그리고 객체가 과도하게 세분화되는 것을 방지하기 위한 최소 객체 크기(Minimum segment Size) 파라미터가 제공된다. 입력된 가중치 값과 영상분할 결과 사이의 관계는 명확히 설명되기 어려우므로 시행착오를 통해 적절한 기준이나 방법을 찾아야 한다[141]. 본 연구에서는 먼저 분광 세부 묘사를 10에서 20까지 순차적으로 변환하며 판독하고, 다음으로 공간 세부 묘사를 변화시키며 객체 생성을 판독하였다. 마지막으로 최소 객체 크기를 조정하여 매우 작은 객체를 인접 객체와 병합시켜 최종 가중치를 선정하였다.

2. GeoAI 모델 선정 및 학습 데이터 구축

1) 토지피복 분류

가. GeoAI 모델 선정

고해상도 위성 또는 항공 영상을 기반으로 객체 기반 영상 분석 기법을 적용하여 벼 재배면적을 추정하거나 건물 변화 탐지 연구가 수행되었다[142][143]. 객체 기반 영상 분석 기법은 영상분할을 통해 생성된 객체에 대해 GeoAI 모델이 적용되어 토지피복 분류 작업을 수행한다. Cooner et al. (2016)[144]은 WorldView-1과 Quickbird-2 위성영상과 ANN 및 기타 기계학습 모델을 사용해 지진 피해지역을 탐지하였다. Noi and Kappas (2017)[145]은 원격탐사 기반 이미지 분류 연구에서 활용되고 있는 기계학습 모델 종류를 분석하였고 RF와 ANN 등이 주로 활용되고 있음을 밝혔다. 따라서 객체 기반 영상 분석 기법의 영상 분류기로써 ANN, RF 등을 고려할 수 있을 것으로 판단된다.

송아람과 김용일 (2017)[146]은 항공 초분광영상을 기반으로 딥러닝 기법인 CNN을 적용하여 농작물 및 건물 용도 분류 연구를 수행하여 96%의 정확도를 달성하였으며, 딥러닝 기법이 향후 환경주제도, 토지피복도의 제작 및 갱신에 활용될 수 있을 것으로 제안하였다. 서기환 등 (2019)[147]은 25cm 항공정사영상을 기반으로 딥러닝 기반 의미론적 분할 모델인 U-Net, DeepLab 등의 모델을 사용하여 건물 탐지 연구를 수행하였고, Deep U-Net 모델을 최적 모델로 선정하여 학습 정확도 97.8%를 달성하였다. 실증을 통해서 고해상도 영상을 기반으로 딥러닝 기반 의미론적 분할 모델이 토지피복 분류 자동화에 대한 가능성을 제시하였다. 따라서 토지피복 분류에서 딥러닝 기반

의미론적 분할 모델인 U-Net 모델 적용을 고려할 수 있을 것으로 판단된다.

종합적으로 정리하면 고해상도 영상을 기반으로 토지피복 정보 분류를 위해 객체 기반 영상 분석과 딥러닝 기법이 적용되고 있다. 본 연구에서는 객체 기반 영상 분석 기법의 경우 선행연구를 통해 고해상도 영상 기반 토지피복 분류에서 주로 활용되고 있는 RF와 ANN 모델을 객체에 대한 분류기로써 사용해 비교하고자 한다. 또한, 딥러닝 기반 의미론적 분할의 경우 토지피복 분류 모델에서 우수한 성능을 보였던 U-Net 모델을 통해서 검토를 진행하고자 하였다.

GeoAI 모델은 학습에 사용되는 데이터에 따라 성능이 변화할 수 있으며, 비정보성 데이터가 많을수록 모델의 성능이 저하될 수 있다^[148]. 따라서 토지피복 분류 모델 기법을 비교하기에 앞서 UAV를 통해 수집되는 분광 및 기하학적인 영상이 토지피복 분류에 대해 가지는 특성을 분석하는 것이 필요하다. 그러나 기본적으로 기계학습 모델들은 어떤 근거로 결과가 도출되었는지 알 수 없는 블랙박스 모형이기 때문에 독립변수와 종속변수의 설명력을 확보하기 어렵다. 그러나 RF의 경우 변수 중요도라는 척도를 통해 어떤 변수가 예측 성능에 중요한 역할을 하는지 추정할 수 있다. 변수 중요도는 각 변수가 모델의 예측에 얼마나 많은 영향을 미치는지를 나타낸다. 따라서 본 연구는 사전분석 단계로 RF 모델을 사용해 주요 변수들이 전체 모델의 예측력에 어떻게 기여하는지 평가하고자 하였다.

나. 분류 항목 선정

UAV 영상에서 토지피복을 분류하기 위해서 UAV 영상에서 수집되는 분광 및 기하학적인 영상과 같이 물리적인 특성을 기반으로 분류가 가능한 분류 항목을 먼저 검토하였다. 다음으로 기존 환경부에서 제공하는 토지피복도의 분류체계와 연계성을 가질 수 있는 분류 항목을 검토하였다. 이를 기반으로 건물, 산림, 초지, 도로, 나지, 수역을 기초 분류 항목으로 선정하였다. 기초 분류 항목은 환경부 제공의 세분류 토지피복도에서 제공하는 44개의 항목보다 작다. 상업시설, 공공이용 시설지역 등과 같이 토지이용 또는 지목을 포함하는 다른 세분류 항목은 환경부에서 갱신하고 있다. 이에 대한 정보는 중첩분석을 통해서 얻을 수 있을 것으로 판단하였다. 그리고 본 연구는 기존 토지피복도에서는 할 수 없는 최신 및 갱신 문제를 해결하고, 작은 면적의 요소까지도 고려하면서 기존 토지피복도에서 반영이 안 된 항목에 대해서 분석을 진행하고자 하였다.

마지막으로 도시환경 분석 활용과 확장 가능성을 고려할 수 있도록 기존 분류체계에서 제시하지 못하는 항목을 검토하였다. 대기질, 기후 등을 고려해서 도로를 차가 다니는 도로와 사람이 다니는 도로로 세분화하였으며, 조경식생과 자연식생이 구분될 수 있는지 가설을 세우고 산림과 가로수, 초지와 가로 녹지로 세분화하였다. 최종적으로 분류 항목은 건물, 차도, 인도, 산림, 초지, 가로수, 가로녹지, 나지, 수역으로 총 9개로 설정하여 진행하였다.

다. UAV 영상의 분류 특성 분석 및 학습 데이터 제작

토지피복 매핑에서는 사전분석 단계와 토지피복 분류 기법 비교 단계로 나누어 연구를 진행하였다. UAV 영상은 Red, Green, Blue, Rededge, NIR, NDVI, SAVI, nDSM으로 총 9개의 영상을 활용하였다. 사전분석 단계에서는 객체 기반 영상 분석에 RF 모델을 사용하여 토지피복 매핑에서 어떤 영상과 변수들이 중요한 역할을 하는지, 자연적인 식생과 조경을 위해 식재된 식생을 효과적으로 분류할 수 있는지 확인하고자 변수 중요도를 산출하였다.

사전분석 단계에서 토지피복을 분류하기 위해 UAV 기반 영상으로부터 객체에 할당된 값들은 count, area, mean, max, range, STD(standard deviation), sum, variety, majority, minority, median, PCT(percentile), NMS(nearby mean STD)이다. 이를 통해 하나의 객체에 각 영상별로 14개씩 통계 값을 계산하여 총 126개의 변수를 구축하였다. 본 연구에서 토지피복과 가로녹지를 분류하고자 하나 산림과 가로수, 초지와 가로녹지의 분광 특성이 비슷한 특성을 보일 수 있다. 그러나 산림과 초지는 주위의 객체들이 분광특성이 비슷한 산림 또는 초지인 것에 반해 가로수 및 가로녹지는 도로, 인도, 건물 등 식생이 아닌 토지피복이 함께 존재하고 있어 주위의 분광 특성과 많은 편차가 발생한다. 따라서 각 객체로부터 3m 내에 있는 객체들의 mean 값을 표준편차로 계산하여 가로수와 가로녹지를 분류할 수 있도록 NMS 변수를 추가하였다. 학습 자료는 연구 대상지 전체의 특성을 반영할 수 있도록 연구대상지 전체에서 수역을 제외한 8개의 항목에 대해 1000-5000개 범위의 객체를 구축하였다. 수역의 경우 하천 내의 식생이 하천 부근을 대부분 덮어 165개의 객체만 선택하였다. 이러한

학습 객체는 토지피복 등급 사이의 분포와 연구 지역을 특징짓는 다양한 색상의 음영을 고려하면서 화면 해석을 통해 수작업으로 선택하였다.

변수중요도 분석과 함께 각 UAV 영상에서 나타난 특성과 같이 토지피복 분류 예측 성능에 영향을 끼치는지 확인하기 위해 학습된 초기 모델을 연구대상지 전체에 적용하여 토지피복 정보를 제작하였다. 또한, 그림 16에 제시한 바와 같이 ArcGIS pro S/W에서 제공하는 Create Random Points tool을 사용해 생성된 무작위 500개 검증 포인트를 통해서 정확도를 평가하였다. 정확도 평가는 혼동행렬 (Confusion Matrix)을 통해 산출하는 생산자정확도(PA, Producer's accuracy) 및 사용자정확도(UA, User's accuracy), 전체정확도(OA, Overall accuracy)를 각각 산출하여 평가하였다. 이를 통해서 UAV 영상의 특성과 분류 항목에 대해서 고찰하였다.




FIGURE 16. Random points for preliminary analysis

추후 결과에서 제시되겠지만 사전분석 단계의 결과를 토대로 가로수와 산림을 통합하고, 초지와 가로녹지를 통합하여 최종적으로 건물, 차도, 인도, 나무, 초지, 나지, 그리고 수역까지 총 7가지 항목으로 선정하였다. 이를 기반으로 토지피복 분류 모델의 성능을 비교하고자 하였다. 동일한 학습 자료에 대해서 토지피복 분류 기법을 비교하고, 학습이 전혀되지 않은 검증 지역에 대해서 모델을 적용해 정확도를 비교하고자 하였다. 이를 위해서 그림 17에 제시한 바와 같이 연구 대상지의 40%에 해당하는 공과대학 일대를 학습 지역으로 설정하였다. 토지피복 정보를 학습 지역에 대해 벡터라이징을 하여 학습 데이터로 사용하였고, 나머지 60%는 검증 지역으로 설정하여 각 모델에 대한 공간적인 일반화 성능을 비교하고자 하였다.




FIGURE 17. Separating training and validation site

2) 수목 탐지 및 흉고직경 측정

가. GeoAI 모델 선정

수목은 광합성을 통한 성장 과정에서 탄소를 흡수 및 저장하며, 기후변화에 대응하기 위해서는 탄소 흡수·저장량을 정량화하는 것이 중요하다. 이산화탄소의 주요 흡수원인 산림을 대상으로 연구가 진행되었고, 최근 탄소중립 정책에 따라 도시에서도 고려되지 못했던 도시녹지까지 확대되고 있다[27][149][150]. 산림 부문의 탄소 흡수 기능 연구는 산림 수종에 대해 줄기밀도와 생체량(Biomass) 확장계수 등을 이용한 임목 축적량 변화로부터 탄소 흡수량을 산정하고 있다[151][152]. 반면 도시녹지의 경우 임목축적량 자료가 없고, 개체별로 식재 관리되므로 수종별 개체수를 조사하고 탄소 흡수·저장량을 산정해야 한다. 도시 수목의 탄소 흡수·저장량 추정 방법은 흉고직경과 수고를 독립 변수로 하는 수종별 상대생장식을 기반으로 유도된 개체당 탄소 흡수·저장량 산정식이 이용되고 있다[14][132][153].

흉고직경, 수고, 개체수 등과 같이 탄소 흡수·저장량 산정 변수 정보를 효율적으로 취득하기 위해 주로 면적이 크고 지형적인 특성상 접근이 쉽지 않은 산림을 대상으로 원격탐사 기반 연구가 진행되었다. Kanda et al. (2004)[154]는 고해상도 항공기 영상을 기반으로 산림에서 태양 빛에 의해 수목 상부는 밝고, 수목 사이는 어두운 그림자가 생기는 패턴을 발견하였다. 영상의 밝기 정보를 기반으로 유역 분할(Watershed Segmentation) 기법을 통해 개별 수목으로 분할하고 약 80~90%의 정확도 달성하였으며, 고해상도 항공기 영상 기반 개별 수목 분할 절차를 제안했다. 장안진 등 (2006)[135]은 항공기 LiDAR 데이터의

3차원 높이 정보를 기반으로 수목의 구조 특성을 이용해 유역 분할 기법을 적용하였으며, 이를 통해 면적당 산림 수목의 개체수와 수고를 추정하였다. 현장조사 대비 정확도 평가에서 개체수의 경우 결정계수(R^2) 0.77, 수고는 결정계수 0.83으로 3차원 높이 정보 기반의 유역 분할 기법이 개별 수목 조사에 대한 효용성이 있음을 확인하였다. 김성용 등 (2021)[155]은 UAV 및 유역 분할 기법을 이용하여 잣나무림을 대상으로 수고 및 흉고직경을 추정하였다. 수관면적과 흉고직경의 상관성이 $p < 0.01$ 의 상관관계를 보이고, 결정계수가 0.7705로 분석되어 수관면적이 커질수록 흉고직경이 증가하는 추세를 확인하였다. UAV 기반 개별 수목의 수관면적 추출이 탄소 흡수·저장의 주요 변수인 흉고직경 정보 수집에 효과적인 대안이 될 수 있음을 확인하였다.

전술된 선행연구들과 같이 개별 수목에 대한 정보 수집은 주로 유역 분할 기법이 사용되고 있다. 유역(Watershed)은 그림 18에 제시한 바와 같이 강우가 산의 능선과 같이 지형적인 분수계를 따라 하천의 어느 한 지점으로 모이는 집수 영역을 말한다. 일반적으로 지형적인 분수계가 유역의 경계선이 된다. 유역 분할 기법은 이러한 아이디어를 각 픽셀의 값이 빛의 양을 나타내는 회색조(Grey-scale) 영상에 적용한 것이다. 회색조 영상의 픽셀값을 높이로 해석하여 위상학적 표면으로 가정하면 2곳 이상의 집수 영역으로 모일 확률이 같은 곳이 분수계가 된다. 이러한 집수 영역과 분수계를 찾아 각 영역을 나누는 것이 유역 분할 기법이다. 영상분석에서 유역 분할 기법의 용도는 항목별로 분류된 이미지에서 객체를 분리하기 위해 주로 사용되고 있다[156]. 빛의 명암 특성을 이용한 유역 분할 기법은 수목의 밀도가 높아 그림자 지역이 뚜렷한 산림에서는 유용할 수 있다. 하지만 도시에서 수목은 건물, 거리,

보행자, 차량 등 다양한 주변 지형지물이 주위에 존재하고, 수목의 밀도가 높지 않아 빛의 명암 특성을 이용하기에 한계가 있다. 따라서 수목 영역만 추출한 뒤 3차원 높이 정보를 기반으로 유역 분할 기법을 적용하는 것이 적합할 것으로 판단된다.




FIGURE 18. Concept of watershed

최근 수목 정보 수집을 위해 딥러닝 기법이 제안되었으며, 개별 수목의 위치를 탐색하기 위한 방법론으로서 활용성이 확인되었다[157][158]. 특히, Mask R-CNN은 객체 분할에서 가장 많이 사용되는 모델이며[159], 그림 19에 제시한 바와 같이 2단계 구조로 객체를 추출한다. 먼저 객체가 존재할 가능성이 높은 영역을 식별한 다음, ROI(Region of Interest) Align을 통해 이 영역을 표준화하고, 각 객체에 대한 분류와 픽셀 수준 매핑을 한다. 객체 분할에서 우수한 성능을 보이고 있는 Mask R-CNN은 도시지역에서 개별 수목 영역 탐지를 위한 방법론으로 제안되었다. Yang et al. (2022)[160]은 Google Earth 이미지를 기반으로 Mask R-CNN을 개별 수목 영역 탐지에 적용하였고, 80% 이상의 수목 탐지율과 90%의 정확도로 수목의 영역을 묘사했다. 이를 통해 Mask R-CNN 모델이 개별 수목 영역 탐지에 효용성이 있음을 확인했다. Ocer et al. (2020)[161]은 UAV 기반 RGB 이미지를 취득하고, 다중

스케일 이미지를 통해 개별 수목 탐지를 연구하였다. 그 결과, Mask R-CNN이 이미지 규모와 수목 크기의 변화에도 탐지 정확도를 유지하는 것을 확인하였다. 선행연구들에서는 RGB 영상만 활용하여 개별 수목을 탐지하였다. UAV-LiDAR를 활용하게 되면 RGB 영상뿐 아니라 3차원 높이 정보도 활용할 수 있으므로 UAV-LiDAR 데이터를 기반으로 Mask R-CNN 모델의 활용성에 대한 평가가 필요할 것으로 판단된다.




FIGURE 19. The Mask R-CNN framework for instance segmentation

딥러닝 기반 객체 분할 기법이 수목 탐지에 효과적임을 확인할 수 있지만 실제 수목 탐지 적용에는 여전히 한계가 있다[162]. 밀집된 수목이 분포하는 경우 잎과 가지가 매우 가까이 붙어있으므로 수목 간의 경계가 매우 모호하다. 이러한 특징은 딥러닝 모델 학습에 필요한 정답 값을 알려주는 라벨(label) 작성을 매우 어렵게 만들고 비용을 증가시킨다. 시간과 비용의 제약으로 인해서 대규모 학습 데이터를 수작업으로 제작하는 것은 매우 어려운 일이며, 소량의 학습 데이터는 과적합 위험을 증가시킨다[163]. 따라서 효율적인 학습 데이터의 제작 방안이 필요하며, 기존 개별 수목 탐지에서 활용되고 있는 유역 분할 기법이 학습 데이터 제작에 활용될 수 있을 것으로 판단된다.

나. 학습 데이터 제작

개별 수목 영역을 탐지하기 위한 학습 데이터를 제작하기 위해서 객체 기반 영상 분석과 유역 분할 기법을 접목하여 학습 데이터를 제작하였다. 사용한 UAV 영상은 RGB 영상을 기반으로 제작된 ExG 영상과 포인트 클라우드로부터 제작된 nDSM 영상을 사용하였다. 이를 통해 제작된 영상 분할 결과를 바탕으로 토지피복 분류 결과에서 수목에 관해 우수한 성능을 보였던 RF 모델을 분류기로 사용하였다. RF 모델 학습을 위해 Zonal statistics as table tool을 통해 각 객체에 min, max, mean, median, PCT10(percentile 10), PCT25(percentile 25), PCT75(percentile 75), PCT90(percentile 90)로 학습 변수를 제작하고, area 및 length와 같은 형태 변수를 추가해 총 18개의 변수를 활용하였다. 추출된 수목 영역을 바탕으로 nDSM 영상을 기반으로 유역 분할 기법을 적용하여 수목 간의 경계를 분할하였다.

유역 분할 작업에서 nDSM 영상은 수목의 세부적인 윤곽과 형태만 필요하므로 픽셀에서 가파르게 변화하는 패턴을 제거할 필요가 있다. Focal Statistics tool을 사용하여 nDSM 영상의 스무딩을 진행해 보정하였다. nDSM 영상의 3차원 높이 정보를 통해 유역 분할을 진행하기 때문에 수목 간의 경계가 분수계가 될 수 있도록 Raster calculator tool에서 수목 영역에 대해 -1을 곱해서 수목의 영역에서 가장 높은 지점이 가장 낮은 값을 가지도록 가공하여 유역 분할을 진행하였다. 생성된 개별 유역 분할 결과를 통해 화면판독 및 현장 조사를 통해 오류를 보정하여 개별 수목 영역을 탐지하기 위한 학습 데이터를 제작하였다. 또한, 103개의 수목에 대해서 흉고직경을 현장측정을 진행해 개별 수목 영역에 대한 흉고직경 추정 학습 자료를 구축하였다.

3. GeoAI 모델 적용 및 환경공간정보 구축

1) 토지피복 분류 모델 학습 및 비교

UAV 영상을 활용해서 토지피복 분류를 위한 GeoAI 적용에서 객체 기반 영상 분석과 딥러닝 기반 의미론적 분할 기법을 적용하여 비교하였다. 객체 기반 영상 분석에서 적용한 분류기는 RF와 ANN이다. 그리고 객체 기반 영상 분석 모델의 학습을 위해서 영상분할을 통해 제작된 객체 내에 각 영상에 대한 min, max, mean, median, PCT10, PCT25, PCT75, PCT90으로 8개의 입력 변수를 할당해 72개의 통계 값을 구축하였고, 객체의 형태 정보로 길이와 면적 값을 추가로 할당하여 총 74개의 입력 변수를 활용하였다. RF는 적절한 분류 모델을 찾기 위해서 n estimator와 max depth를 조정하여 분류 정확도를 비교하고, 최적의 하이퍼파라미터를 선정하였다. ANN은 1개의 입력층, 2개의 은닉층, 1개의 드롭아웃층, 1개의 출력층으로 구성된 모델을 사용하였다. 74개의 입력 데이터를 받아들이기 위해 74개의 노드로 입력층을 구성하였다. 은닉층 구간에서는 입력 데이터에서 특징을 추출하기 위해 256개 노드로 구성된 첫 번째 층과 특징의 추상화 및 요약을 위해 62개 노드로 구성된 두 번째 은닉층을 구성하였다. 학습 데이터에 대한 과적합을 방지하고자 두 개의 은닉층 사이에 드롭아웃층을 추가하였다. 또한, 과적합을 방지하기 위한 추가 장치로 정확도가 더 이상 증가하지 않을 때 학습을 중단하는 조기 종료 기능을 활용하였다.

딥러닝 기반 의미론적 분할에서는 모델의 구조 내의 얇은 층에서 추출한 저수준 특징과 깊은 층에서 추출한 고수준 특징을 스킵 커넥션을 통해 효과적으로 결합해 토지피복 분류 성능이 우수한 U-Net 모델을

사용하였다. 학습 데이터의 제작은 ArcGIS pro S/W의 Label objects for deep learning tool을 사용하였다. 학습 영상의 크기는 연구 대상지 내의 건물이 식별이 가능하도록 512 x 512 픽셀 크기(약 77m)로 영상을 제작하였다. 딥러닝 모델은 많은 학습 데이터가 존재해야 모델의 성능을 기대할 수 있으므로 한정된 학습 데이터의 경우 학습 데이터의 증강을 통해 한정된 데이터의 한계를 해결할 수 있다. 학습 데이터 증강은 학습 지역에 대한 UAV 영상을 0°, 90°, 180°, 270°로 회전시켜 진행하였다. 이를 통해서 총 17,694개의 학습 데이터를 제작하여 U-Net 모델을 학습하였다.

토지피복도에 대한 정확도 검증은 그림 20과 같이 ArcGIS pro S/W의 Create Random Points tool을 사용해 생성된 무작위의 5000개 검증 포인트를 통해 진행하였다. 분류 모델 간의 성능 비교는 혼동 행렬을 통해 OA와 Kappa를 산출해 전체 분류 정확도를 비교하였고, 각 분류 항목의 경우 PA와 UA를 통해서 비교하였다.




FIGURE 20. Random points for comparison of classification

2) 수목 탐지 및 흉고직경 예측 모델 학습

가. 개별 수목 탐지 모델 학습

딥러닝 기반 객체 분할 기법에서 우수한 성능을 보이는 Mask R-CNN 모델을 적용하였다. 객체 기반 영상 분석 및 영상 분할 기법의 접목을 통해 제작된 개별 수목 영역 결과를 기반으로 학습 데이터를 제작하였다. 학습 데이터로 사용되는 이미지를 제작하기 위해 영상의 해상도와 수목의 크기를 고려하여 512 x 512 픽셀(약 20m) 크기의 영상을 잘라서 학습 데이터를 제작하였다. 이를 통해 총 6,892개의 학습 데이터를 제작하고 모델 학습을 진행하였다. 객체 탐지에 대한 정확도는 그림 21에 제시한 것과 같이 IoU(Intersection Over Union)을 사용하여 평가하였다. IoU는 0에서 1사이의 값을 가지며 실제 객체 영역과 예측한 객체 영역이 중복되는 영역의 크기를 통해 평가한다. IoU가 특정 임계값을 넘으면 예측한 객체가 신뢰성이 있다고 판단하며, 일반적으로 IoU 50% 및 75%를 기준으로 성능 평가가 진행된다. 성능 평가 지표는 IoU를 바탕으로 정밀도(Precision), 재현율(Recall), F1 점수 등을 산출하여 활용하였다. 또한, 정밀도와 재현율을 바탕으로 제작된 정밀도-재현율 곡선(Precision-Recall curve)을 통해서 평균 정밀도(Average Precision, AP)를 산출하여 사용하였다.




FIGURE 21. Formula and diagram of IoU

나. 구조 정보 산출 및 흉고직경 추정

수목의 경우 개별 수목 탐지를 통해 수고와 수관면적을 산출할 수 있다. 하지만 수목의 생장 파악, 탄소 저장량 산정 등에 핵심적인 자료인 흉고직경 예측이 필요하다. 따라서 103개의 수목에 대해서 흉고직경을 측정하고 이를 기반으로 예측을 수행하였다. 독립변수로는 수고, 수관면적, 수관고 표준편차를 사용하였다. 수관고 표준편차를 변수로 사용한 이유는 연구 대상지 내에 다양한 수목이 존재하고 있으므로 수목의 형태에 대한 특징을 표현하기 위한 변수로 사용하였다. 그리고 Linear Regression, Random Forest Regression, k-NN (k-Nearest Neighbor) Regression, 그리고 Support Vector Regression 모델을 적용하여 흉고직경을 예측하여 정확도를 비교하였다. Linear Regression은 독립변수와 종속변수 간의 선형 관계를 추정하며, 가장 간단하고 이해하기 쉬운 모델로 변수들 간의 관계가 직선적일 때 유용하다. Random Forest Regression은 여러 개의 의사결정 나무를 사용하여 예측을 수행하는 앙상블 기법으로 과적합을 방지하고 복잡한 비선형 관계를 잘 포착할 수 있는 특징이 있다. k-NN Regression은 예측하고자 하는 데이터 포인트와 가장 유사한 k개의 이웃 데이터 포인트를 찾아 그 평균값으로 예측을 수행하며, 데이터의 지역적 특성을 반영할 수 있다. Support Vector Regression은 주어진 데이터 포인트들을 고차원 공간에 매핑하고, 이 공간에서 최적의 선형 평면을 찾아 예측을 수행하며, 이상치에 강하고 고차원 데이터에서 잘 작동한다. 이러한 각각의 다른 특징을 가진 네 가지 회귀모델을 비교하여 흉고직경 추정에 적합한 회귀모델을 모색하였다.

IV. 토지피복 분류 및 모델 성능 평가

앞서 1장 및 2장에서 전술한 바와 같이 토지피복 정보는 기후 시뮬레이션, 생태계 조사, 물순환 및 환경성 평가 등에 많은 분야에서 필수적인 정보로 활용되고 있다^{[164][165][166][167][168]}. 환경부에서 제공하는 기존의 토지피복 정보는 사용하는 위성영상 및 항공사진의 갱신주기 불일치, 미반영 항목 등과 같은 근본적인 문제 외에도 작업자가 육안 관독을 통해 디지털라이징을 진행하므로 갱신주기가 길어 최신 현황을 반영하지 못한다. 토지피복 정보의 제작 기준에서 분류에 대한 최소 면적 기준이 존재하여 작은 면적의 토지피복 정보는 포함되지 못한다는 한계점도 있다.


본 장에서는 이러한 문제점을 해결하기 위해서 UAV 및 GeoAI를 적용하여 빈 공간 없이 대상지 내 모든 위치에서 토지피복 정보의 자동 분류 가능성을 실증하였다. UAV를 기반으로 제작된 여러 분광 및 기하학적 정사영상이 어느 토지피복 항목에서 분류를 위해 어떤 기여를 할 수 있는지 분석하였다. 그 결과를 바탕으로 토지피복 분류 항목을 선정하고, 모델 비교 및 선정을 위해 연구 대상지 일부를 벡터라이징 하여 학습 데이터로 활용하였다. 마지막으로 토지피복 분류에 적합한 모델을 선정하기 위해 고해상도 영상 분석에 적합한 객체 기반 영상 분석 기법과 딥러닝 기반 의미론적 분할 기법을 적용하여 토지피복 정보를 자동 분류하고 결과를 제시하였다.

1. UAV 영상 분석 및 학습 데이터 구축

1) UAV 영상 및 기초 분석 데이터


가. UAV 영상 제작

고정익 UAV 비행 및 촬영으로 Duet-T 센서에서 RGB 및 LST 이미지를 수집하였으며, 각각 1,132장의 이미지를 취득하였다. 그리고 Rededge-MX 센서로부터 파장대별로 Red, Green, Blue, Rededge, NIR 5가지의 이미지를 수집하였으며, 총 5,925장의 이미지를 취득하였다. 수집한 이미지를 접합하여 정사영상으로 제작하고, 전처리한 결과는 그림 22에 제시하였으며 토지피복 분류를 위해서 총 9개의 영상을 제작하였다. 영상지도의 기하보정 결과는 Duet-T 센서 기반 영상은 평균 제공근 편차(RMSE, Root Mean Square Error)가 x방향 0.033m, y방향 0.048m로 나타났으며, Rededge-MX 센서 기반 영상은 RMSE가 x방향 0.056m, y방향 0.054m로 나타났다.




(a) Blue

FIGURE 22. Results of UAV imagery for land cover classification (continue)




(b) Green




(c) LST

FIGURE 22. Results of UAV imagery for land cover classification (continue)




(d) NIR




(e) Red

FIGURE 22. Results of UAV imagery for land cover classification (continue)




(f) Rededge




(g) nDSM

FIGURE 22. Results of UAV imagery for land cover classification (continue)



(h) NDVI



(i) SAVI

FIGURE 22. Results of UAV imagery for land cover classification

나. 영상분할

본 연구에서 고해상도 UAV 영상에 적용하고자 하는 기법 중 하나인 객체 기반 영상 분석은 픽셀들을 그룹화해 하나의 분류 단위로 변환하는 영상분할 단계가 필요하며, 그 과정은 그림 23에 제시하였다. 먼저 분광 값에 대한 평활화를 조정하고자 분광 세부 묘사의 값을 조절하였다. 분광 세부 묘사 10에서는 도로와 초지의 경계가 생성되지 않고 병합되는 경향이 나타났으며, 분광 세부 묘사 15에서는 일부 지역에서 도로와 인도, 나지가 구분되지 않는 구간이 존재하였다. 분광적인 민감도를 가장 높인 분광 세부 묘사 20에서는 객체가 같은 토지피복 내에서도 매우 세밀하게 경계가 구분되는 경향이 나타났다. 이러한 경우 토지피복 간 경계는 뚜렷하지만, 객체의 크기가 매우 작으므로 영상의 노이즈에 민감해질 수 있다. 따라서 분광 세부 묘사 20부터 1씩 감소시키며, 공간 세부 묘사의 값을 증가시키며 육안판독으로 인도, 차도, 나지의 경계가 뚜렷한 조건을 탐색하였다. 그 결과, 세부 조정을 통해 분광 세부 묘사 18 및 공간 세부 묘사 10 조건에서 각 토지피복 별로 경계가 뚜렷하면서 객체가 과도하게 세밀하게 형성되지 않는 것을 확인하였다.

마지막으로 최소 객체 크기를 통해서 매우 작은 객체들이 생기지 않도록 증가를 시켰으며, 40으로 하였을 때 객체의 크기가 매우 작게 세분화되지 않고 적절한 크기로 구분되는 것으로 판단하였으며, 차도가운데에 분리선 대신 존재하는 가로녹지의 경계가 명확해져 가중치를 40으로 선정하였다. 따라서, 객체기반 토지피복 분류를 위해 최종적으로 분광 세부 묘사 18, 공간 세부 묘사 10, 그리고 최소 객체 크기 40으로 가중치를 선정하여 영상분할을 하였다.




FIGURE 23. Image segmentation results

2) 토지피복 항목별 UAV 영상 특성 및 분류 기여도

가. UAV 영상의 데이터 특성

공간적인 일반화 성능 평가 및 기법 비교를 하기 전에 사전단계로서 토지피복 분류를 진행했을 때 어떤 UAV 영상과 변수들이 중요한 역할을 하는지 객체 기반 영상 분석 및 RF 모델을 이용해서 변수 중요도 분석을 진행하였다. 기존 환경부 토지피복 정보의 도로 항목을 차도와 인도로 구분하고, 식생은 자연적인 식생과 조경을 위해 식재된 식생을 효과적으로 분류할 수 있는지 가능성을 보고자 하였다.

우선 정확한 예측을 할 수 있는 인공지능 모델을 구축하기 위해서는 기본적으로 학습 데이터의 분포를 이해하는 것이 매우 중요하다. 총 9개의 분류 항목에 대해서 학습에 사용한 객체들에 대해 나타난 특성을 그림 24에 제시하였다. nDSM 영상은 지형의 영향을 제외한 지물에 대한 높이 값을 나타내므로 높이 값에 따라서 항목들이 구분되었다. 높이 값이 있는 건물, 산림, 가로수가 높이 값이 없는 차도, 인도, 초지, 가로녹지, 나지, 수역과 뚜렷하게 구분되었다. NDVI 및 SAVI는 산림, 가로수, 초지, 가로녹지와 같은 식생을 나타내는 항목에서 건물, 차도, 인도, 나지, 수역과 같은 비식생 항목을 뚜렷하게 구분하였다. NDVI에서는 가로수, 산림, 초지는 박스 플롯의 범위가 겹쳐 구분이 어려웠지만 가로녹지는 구간이 다르게 분포하여 구분이 가능할 것으로 나타났다. 가로녹지의 경우 건초지나 흙이 드러난 부분으로 인해 박스 플롯의 범위가 넓게 형성되고, 초지보다는 낮은 값의 구간에 박스가 형성되는 것으로 판단된다. SAVI는 토양 빛에 의한 보정으로 가로녹지의 박스 범위가 초지에 비해 매우 좁게 분포하였다.

LST는 수역이 가장 낮은 값을 가지며 다른 항목과 뚜렷하게 구분되었으며, 다른 영상에 비해서 차도, 인도, 나지 구분에 가장 유리하게 활용될 수 있을 것으로 나타났다. Red, Green, Blue 영상은 나지 항목이 높게 나오고 차도, 인도는 상대적으로 낮게 분포하면서 차도, 인도, 나지를 구분하는데 일부 기여가 가능할 것으로 판단된다. 마지막으로 Rededge와 NIR 영상은 수역 구분에서만 유리했고, 단일 파장 대역 영역 영상이 아닌 식생지수와 같이 타 파장과 함께 사용될 때 효용성이 커질 것으로 판단된다.




FIGURE 24. Characteristics of the training data used for the variable importance (continue)




FIGURE 24. Characteristics of the training data used for the variable importance

나. UAV 영상의 토지피복 분류 기여도

UAV 영상이 토지피복 분류 예측 성능에 미치는 상대적인 영향을 분석하기 위해서 객체 기반 영상 분석을 통해 RF 모델을 학습하고, 학습 변수에 대한 중요도를 분석하여 그림 25에 제시하였다. 126개 학습 변수 중에서 중요도가 0.6%를 초과하는 40위 변수까지 표현하였다. X축에는 각 영상의 명칭과 함께 중요도가 높게 평가된 변수를 괄호 안에 표시하였다.

영상에 따른 변수 중요도를 살펴보면 40위 내에 nDSM(8개), NDVI(7개), LST(7개), SAVI(6개), Blue(6개), Green(4개), Red(1개), Rededge(1개)으로 나타났다. 1위부터 12위까지 nDSM과 NDVI가 차지하고 있어 가장 중요한 변수로 평가되었고, 13위부터는 다양한 영상과 통계 값이 함께 존재하고 있다. 데이터 특성과 연관하여 살펴볼 때 nDSM은 높이 값을 가지는 건물과 산림과 가로수와 같은 수목을 구분하는 것에 주요하게 사용된 것으로 판단된다. RF의 변수 중요도가 불순도를 기준으로 평가하기 때문에 높이 값이 존재하는 건물 및 수목 외의 분류 항목과 명확하게 차이가 나므로 불순도가 가장 낮게 평가되면서 중요도가 높게 산출된 것으로 판단된다. 식생지수인 NDVI는 데이터 특성에서 식생과 비식생의 그룹 간에 데이터 값의 차이가 명확했다. 따라서 RF 모델의 학습 과정에서 불순도가 낮게 산출되면서 중요한 변수로 평가된 것으로 판단된다. 다만 같은 식생지수 그룹이면서 토양층에 대해 보정한 식생지수인 SAVI의 경우 NDVI보다 식생에 대한 감도가 높아 불순도가 조금 높게 평가되면서 NDVI 영상보다 변수 중요도가 낮게 산출된 것으로 판단된다.




FIGURE 25. Most important 40 variables out of the 126 assessed

변수 중요도의 16위부터 33위 사이에 LST가 분포하고 있으며, 학습 데이터 특성에서도 나타났듯이 건물, 차도, 인도 그룹과 산림, 초지, 가로수, 가로녹지 그룹, 수역 그룹을 구분하는데 주요하게 사용되었을 것으로 판단된다. 선행연구를 살펴보면 대부분 다중분광 영상과 NDVI와 같은 식생지수를 이용해 토지피복 분류에 주로 사용되어 왔지만^{[169][170][171]}, 도시지역의 토지피복 분류에는 LST 영상이 효과적으로 사용될 수 있음을 시사한다. LST는 태양 복사 에너지의 영향을 많이 받기 때문에 시기에 따라 절대 값의 차이가 날 수 있는 한계점도 존재한다. 하지만 전처리 과정에서 데이터 값의 범위를 0-255까지 전처리하면서 상대적인 차이를 통해 분류를 진행하게 되므로 상대적인 차이를 통해 분류할 수 있는 시기를 선정하는 것일 중요할 것으로 판단된다. 따라서 피복에 따라 열에너지 축적에 따른 차이가 두드러지는 오후 12시에서 3시 사이에 촬영하는 것이 좋을 것으로 판단된다.

Blue 영상도 변수 중요도에서 높은 순위를 차지하였는데, 데이터 특성 분석과 결부하면 차도, 인도, 나지를 구분하는데 유효하게 작용했을 것으로 판단된다. 변수 중요도에서 통계값을 살펴보면 median(6개), PCT(6개), mean(6개), NMS(5개), min(5개), majority(5개), max(4개), minority(3개) 순으로 개수가 분포하고 있어 주로 사분위수의 통계값이 중요한 영향을 가지는 것으로 나타났다. 이를 통해 변수들의 복잡성을 낮추고 단순화하기 위해서 본 분석에서는 사분위수 통계 값을 학습 변수로 사용하는 것이 좋을 것으로 판단된다. 또한, 주변의 특성을 고려할 수 있도록 추가한 변수인 NMS를 사용한 변수들은 Red, Green, Blue, Rededge, nDSM 영상이 유효한 것으로 나타났다. RF 모델은 기본적으로 어떤 메커니즘을 통해 결과가 산출되는지 알 수

없는 블랙박스 모형이므로 정확한 결론은 내릴 수 없다. 하지만 데이터 특성 분석에서 뚜렷한 특징을 보이지 않았던 Red, Green, Blue, Rededge 영상들이 NMS 변수를 통해 높게 중요하게 평가된 것으로 보아 기하학적이거나 형상적으로 판단할 때 이러한 영상들이 분류 문제에서 기여할 수 있을 것으로 판단된다.

다음으로 학습된 모델을 사용해 연구대상지 전체에 대해 토지피복을 예측하고, 전술된 UAV 영상별 데이터 특성과 변수 중요도를 함께 고찰하여 실제 토지피복 분류에서도 UAV 영상 특성이 반영되어 예측되는지 확인하였다. 전체 연구대상지에 대해서 9가지 항목에 대해 토지피복 분류를 실행한 결과는 그림 26에 제시하였다. 학습된 모델을 사용해 연구대상지 전체에 대해서 토지피복을 예측하였을 때 토지피복별 면적비율이 산림(19.2%), 차도(16.8%), 가로녹지(16.6%), 가로수(14.8%), 인도(13.5%), 건물(11.5%), 초지(5.3%), 나지(2.2%), 수역(0.1%) 순으로 나타났다.




FIGURE 26. Result of applying the initial RF to the study area

실제 토지피복 분류에서도 UAV 영상 특성이 반영되어 예측되는지 확인하고자 500개의 검증 포인트를 이용해서 정확도를 검증하여 표 8에 혼동행렬로 제시하였다. 표에서 세로축은 검증 포인트의 토지피복 항목이고, 세로축은 예측된 토지피복 항목이다. 혼동행렬을 통해서 실제 토지피복 항목이 예측 모델에 의해서 어떤 토지피복으로 분류되는지를 확인함으로써 항목별로 분류 정확도를 확인할 수 있으며, 이는 PA로 표현된다. 그리고 예측 모델이 분류한 토지피복이 실제 토지피복으로 분류를 잘하는지를 확인할 수 있는 신뢰도를 확인할 수 있으며, 이는 UA로 표현되어 분석할 수 있다. PA와 UA는 각 항목에 대한 정확도와 신뢰도를 확인할 수 있다면 OA는 전체 토지피복 분류 항목에 대해서 예측 모델이 실제로 토지피복 분류를 정확하게 하는지 분석할 수 있는 지표이다. 그러나 OA는 정확도만 확인할 수 있고, 정확도와 신뢰성을 모두 가지는지는 표현하지 못하므로 전체 토지피복 분류 항목에 대한 신뢰도 지표로 Kappa Coefficient를 산출하여 제시하였다.

500개의 무작위 검증 포인트를 통해서 분류 정확도를 평가한 결과, OA는 76.0%, Kappa는 0.728로 나타났다. 항목별로 살펴보면 건물은 PA와 UA가 각각 95.8%와 93.9%로 모두 정확도가 매우 높게 나타났다. 이는 데이터 특성과 결부하였을 때 지형의 영향 없이 지물의 높이 값만을 나타내는 nDSM과 비식생 지역은 값이 매우 낮게 나타나는 식생지수인 NDVI와 SAVI에 의해 영향을 받아 정확도가 높게 나타난 것으로 판단된다.

TABLE 8. Confusion matrix for the initial RF

Classification	Reference data								
	Building	Car-road	Pedestrian	Forest	Grass	Street tree	Street grass	Bare soil	Water
Building	46	2	1	0	0	0	0	0	0
Car road	0	38	3	0	0	0	0	2	0
Pedestrian	1	10	72	0	1	0	2	24	0
Forest	0	0	0	43	2	4	0	0	0
Grass	0	0	0	2	48	0	12	0	0
Street tree	0	0	1	11	0	45	0	0	0
Street grass	1	4	1	0	20	2	35	8	1
Bare soil	0	0	1	0	0	0	0	18	0
Water	0	0	1	0	0	0	1	2	35
PA (%)	95.8	70.4	90.0	76.8	67.6	88.2	70.0	33.3	97.2
UA (%)	93.9	88.4	65.5	87.8	77.4	78.9	48.6	94.7	89.7
OA (%)	76.0			Kappa				0.728	

건물 이외에도 nDSM과 NDVI와 SAVI 같은 식생지수에 영향을 많이 받을 것으로 예상되는 산림과 가로수를 살펴보면 산림은 PA와 UA가 76.8%, 87.8%로 나타났고 가로수는 88.2%, 78.9%로 나타났다. 혼동행렬을 살펴보면 산림은 56개 검증 포인트 중에서 43개는 산림으로 분류되었지만, 그중 20%인 11개는 가로수로 오분류되는 것을 확인할 수 있다. 가로수도 마찬가지로 오분류 시 주로 산림으로 예측되는 것으로 나타났으며, 이는 화면관독을 통해서 이러한 경향이 나타났다. 본 연구의 가설로 산림과 가로수로 세분화되는 것은 한계가 있는 것으로 판단된다. 하지만 산림과 가로수 항목을 통합하여 수목이라는 항목으로 바라보면 PA와 UA가 96.3%와 97.2%로 매우 높은 수준이므로 산림과 가로수 세분화 가설을 폐기하고 수목으로 통합해 토지피복 분류를 진행해야 할 것으로 판단된다. 이는 초지와 가로녹지에서도 비슷한 경향이 나타났다. 가로녹지와 초지도 일부 지역에서는 초지가 잘 구분되고 있으나 대부분의 지역에서는 가로녹지로 분류되었다. 따라서 가로녹지와 초지의 경우도 초지로 통합하여 분류해야 할 것으로 판단된다.

nDSM과 식생지수를 사용하여 토지피복 분류를 사용한 선행연구들을 살펴보면 건물과 수목의 분류 정확도를 확보하기 위해 nDSM과 식생지수 영상을 사용하고 있으며[172][173][174], Vanhuysse et al. (2017)[175]은 입력 데이터로 nDSM을 사용했을 때 분류 결과의 양적 및 질적 분석에서 건물을 포함하여 여러 항목에 대한 개선을 보고하였다. 본 연구에서도 선행연구의 결과와 마찬가지로 건물에 대한 정확도가 높게 나타났다. 본 장에서는 연속적인 필드 관점에서 빈 공간없이 모든 위치에 대해 토지피복 분류를 진행하였지만, 추후 건물 또는

수목에 대한 특정 객체에 대한 공간정보만 구축할 경우 nDSM과 식생지수를 활용한다면 건물 또는 수목에 대한 객체를 효과적으로 분류하여 추출할 수 있을 것으로 판단된다.

수역의 경우 대상지 내에서 매우 작은 면적을 차지하고 있어 학습 데이터의 비율이 가장 적음에도 불구하고, 수역도 PA와 UA가 각각 97.2%와 89.7%로 높게 나타났다. 수역의 경우 물이 분포하고 있는 지역이므로 적외선 영역대의 파장을 흡수하는 특징을 가지고 있으며, 본 연구에서 사용한 LST, NIR와 같이 적외선 영역대에서 수집한 영상들이 수역을 분류하는데 큰 영향을 주었을 것으로 판단된다[176].

차도 항목에 대해서 살펴보면 PA가 75.9%, UA가 85.4%로 나타났다. UA보다 PA가 낮은 경향을 보였는데 화면판독을 살펴보면 그림자가 존재하는 지역에서 차도가 인도로 분류되는 경향이 있는 것으로 나타났다. 데이터 특성 분석 결과와 함께 살펴보면 차도와 인도를 구분하는 데 가장 주요하게 사용될 수 있는 영상은 LST이다. LST는 동일한 토지피복일지라도 그림자로 인해 동일한 일사량을 받지 못하면 지표면 온도에서 차이가 나게되며, 이는 오분류로 이어질 수 있다. 그 외에도 차도 분류에 기여할 수 있는 영상에서도 반사율이 떨어지므로 오분류 확률이 더 커질 수 있을 것으로 판단된다. 그림자는 원격탐사에서 정보 추출의 정확성을 저해시키는 주요 문제 중 하나로 추가 연구를 통해 그림자 감지 및 그림자 보정에 대한 연구가 필요할 것으로 판단된다[177][178].

인도는 PA가 82.5%, UA가 64.7%로 UA가 PA에 비해 매우 낮게 평가되었다. 혼동행렬을 살펴보면 나지를 인도로 과대 예측하는 것으로

나타났다. 이는 대상지 내의 인도를 구성하고 있는 블록이 그림 16과 같이 베이지색, 붉은색, 초록색, 회색 등 다양한 색상을 골고루 포함하면서 분광 특성이 비슷한 나지를 인도로 오분류하는 경향이 나타나는 것으로 판단된다. 이에 따라 나지 중 44%가 인도로 분류되면서 나지의 PA가 33.3%로 매우 낮게 평가되었다. 본 연구에서는 기존 환경부 토지피복의 도로 항목을 차도와 인도로 세분화하였다. 혼동행렬 및 화면판독을 통해서 살펴보았을 때, 차도의 그림자 지역을 인도로 오분류되는 것을 확인하였으나 대체로 차도와 인도는 서로 구분되어 분류될 수 있는 것으로 나타나 기존 토지피복 항목보다 세분화하여 차도와 인도로 분류할 수 있을 것으로 판단된다.




FIGURE 27. Example of sidewalk block types in the target site

종합적으로 토지피복 분류 항목에 대해서 정리를 하자면 본 연구에서 식생의 경우 위치에 따라 산림과 가로수, 초지와 가로녹지의 주변 환경은 다르므로 기존 환경부 토지피복 항목 내의 산림과 초지를 세분화하였다. 그 결과, 식생의 위치에 따라서 산림과 가로수, 초지와

가로녹지로 세분화하는 것에는 한계가 있는 것으로 분석되었다. 따라서 식생의 경우 분류 항목을 수목과 초지로 통합하여 선정하는 것이 적절할 것으로 판단된다. 추후 수목에서 산림을 추가적으로 구분할 경우 산림은 수목이 일정 규모 이상으로 밀집되어 있는 것이므로 공간적인 분석을 통해 수목이 일정 면적 이상일 경우 산림으로 분류하는 것이 타당할 것으로 판단된다. 그리고 도로 항목을 세분화하였을 때 차도와 인도는 세분화가 가능한 것으로 판단되며, 분광 특성이 비슷한 나지가 인도가 오분류되는 것을 개선하는 것에 중점을 두어야 할 것으로 판단된다.

사전분석 결과를 통해 건물, 차도, 인도, 수목, 초지, 나지, 인도로 9개에서 총 7개의 분류 항목으로 연구를 진행하였다. 토지피복 기법을 비교하기 위해서 동일한 지역에 대한 학습 데이터 구축이 필요하다. 따라서 연구 대상지의 40%에 대해서 토지피복 정보를 육안판독을 통해 벡터라이징하였고 그 결과는 그림 28에 제시하였다. 그리고 사전분석의 혼동행렬 결과에서 나지가 초지로 분류되는 것을 확인하였다. 화면판독을 했을 때 나지 내에 초지가 밀집도가 매우 낮지만 분포하는 것을 확인하였고, 초지 분포로 인해 나지의 정확도 하락을 최소화하고자 NDVI 영상과 SAVI 영상을 참조하여 벡터라이징을 실시하였다. 이러한 현상은 블록 사이에 식생이 자라나는 인도에서도 관찰할 수 있는 현상이며, 다른 토지피복 항목에서도 발생할 수 있다. UAV를 이용해서 고정밀 환경공간정보를 구축하고자 할 때 고해상도 영상으로 인해 작은 식생 하나의 특성까지 표현된다. 따라서 화면판독 및 벡터라이징을 통해 학습 데이터를 구축할 때는 일반적으로 사용하는 RGB 영상 외에도 다양한 참고 영상을 활용해야 할 것으로 판단된다.




FIGURE 28. Result of digitizing land cover in training site

2. 분류 모델 학습 및 공간적 일반화 성능 비교


1) 객체 기반 영상 분석 및 딥러닝 기반 의미론적 분할 기법 모델 학습

고해상도 UAV 영상을 기반으로 토지피복의 자동 분류를 위해 여러 GeoAI 기법을 적용할 수 있다. 본 연구에서는 객체 기반 영상 분석 기법과 딥러닝 기반 의미론적 분할 기법을 적용하였다. 객체 기반 영상 분석 기법은 3장에서 전술한 바와 같이 RF 모델(OBIA-RF)와 ANN 모델(OBIA-ANN)을 적용하였다. 그리고 딥러닝 기반 의미론적 분할 기법은 U-Net 모델을 적용하였다. 토지피복 분류 모델의 성능을 비교하기 위해서 동일한 지역에 벡터라이징된 토지피복 정보를 바탕으로 각 인공지능 모델의 학습을 진행하였다.

인공지능 모델 학습 과정에서 대부분의 모델은 연구자나 기술자들이 정의해야하는 모델의 외부 구성 변수가 있으며, 이러한 변수를 하이퍼파라미터(hyperparameter)라고 한다. 적절한 하이퍼파라미터를 결정하는 방법은 하이퍼파라미터를 변경하며 모델 성능 시험을 여러 번 시행하여 결정해야 한다. 따라서, 본 연구는 UAV 영상을 기반으로 제작된 학습 데이터를 통해 토지피복을 분류에서 적절한 성능을 발휘하는 인공지능 모델을 탐색하기 위해 OBIA-RF, OBIA-ANN, U-Net 모델의 하이퍼파라미터를 변경하며, 이에 따른 정확도를 비교하였다.


첫 번째로, OBIA-RF의 하이퍼파라미터를 탐색한 결과를 그래프로 제작하여 그림 29에 제시하였다. OBIA-RF 모델에서 탐색한 하이퍼파라미터는 n estimator와 max depth이며, 이를 변경하면서 모델을 학습하였다. 그에 따른 모델의 성능 평가 및 비교는 전체 분류 정확도를

통해서 진행하였다. OBIA-RF의 하이퍼파라미터 탐색 범위는 n estimator의 경우 10에서 300까지 비교하였고, max depth의 경우 10에서 100까지 탐색하였다. 먼저 n estimator를 분석한 결과인 그림 29 (a)를 살펴보면 n estimator가 10에서 60까지는 소폭 증가하는 경향이 나타났다. n estimator 60부터는 정확도의 변동이 미세하게 발생하였다. 그림 29 (b)의 max depth는 20까지 정확도가 소폭 증가하였고, 20 이후부터는 정확도가 눈에 띄는 변화 없이 미세하게 변화하였다. 각 하이퍼파라미터를 조합하여 정확도를 비교하였을 때, 학습 정확도에서 0.893, 검증 정확도에서 0.851로 가장 높은 정확도를 나타낸 n estimator 200 및 max depth 40으로 분석되었다. 이 결과를 활용하여 OBIA-RF 모델의 하이퍼파라미터를 정의하여 학습하였으며, 토지피복 분류에 대한 인공지능 모델 비교 분석을 진행하였다.



(a) Training accuracy according to n estimator


FIGURE 29. Accuracy trend of OBIA-RF by hyper-parameter (continue)




(b) Training accuracy according to max depth

FIGURE 29. Accuracy trend of OBIA-RF by hyper-parameter

두 번째로, OBIA-ANN의 하이퍼파라미터를 탐색한 결과를 그래프로 제작하여 그림 30에 제시하였다. 모델의 성능 평가 및 비교는 에포크 (epochs)에 따른 손실 함수의 값(Loss)과 전체 분류 정확도를 통해서 진행하였다. 에포크 8까지는 손실 함수의 값이 빠르게 감소하는 경향이 나타났고, 그 이후부터는 감소 폭이 감소하였다. OBIA-ANN 학습 결과, 손실 함수의 값이 더 이상 감소하지 않는 에포크 104까지 학습하였다. 최종적으로 학습 정확도는 0.850, 검증 정확도는 0.843이고, 손실 함수의 값의 경우 학습 데이터에서 0.439, 검증 데이터에서 0.425로 나타났다. 그리고 그래프에서 검증 데이터가 더 좋은 성능을 나타내는 것을 확인할 수 있다. 이는 OBIA-ANN 구조에서 과대 적합을 막기 위해 dropout을 사용하면서 학습 과정에서는 반영되지만, 검증 과정에서는 반영되지 않으면서 나타난 것이다.




(a) Training loss according to epochs



(b) Training accuracy according to epochs


FIGURE 30. Accuracy trend of OBIA-ANN by hyper-parameter

마지막으로 U-Net 모델의 하이퍼파라미터 탐색 결과를 그래프로 제작하여 그림 31에 제시하였다. 모델의 성능 평가 및 비교는 에포크에 따른 손실 함수의 값과 분류 정확도를 통해서 진행하였다. 에포크의 숫자가 작을 때는 손실 함수의 값이 가파르게 감소하다가 에포크 숫자가 증가할수록 점차 감소 폭이 줄어드는 경향을 보였고, OBIA-ANN에 비해 꾸준히 손실 함수의 값이 감소하는 차이점이 있었다. U-Net의 학습 결과 손실 함수의 값이 더 이상 감소하지 않는 에포크 102까지 학습을 진행하였다. 최종 손실 함수의 값은 학습 데이터에서 0.254, 검증 데이터에서 0.141이고, 학습 정확도는 0.953으로 나타났고, 조화평균 정확도 개념인 Dice coefficient는 0.944로 전체 정확도와 근소하게 차이가 나는 것으로 분석되었다.



(a) Training loss according to epochs

FIGURE 31. Accuracy trend of U-Net by hyper-parameter (continue)



(b) Training accuracy according to epochs

FIGURE 31. Accuracy trend of U-Net by hyper-parameter

토지피복 분류에 대한 각 기법의 인공지능 모델의 학습 결과를 바탕으로 학습 지역에 대해 모델을 적용한 결과는 그림 32에 제시하였다. 그리고 벡터라이징을 통해 학습 데이터로 사용한 자료와 더불어 각 인공지능 모델의 예측 결과에 대해서 토지피복 면적 비율을 산출하여 표 9에 제시하였다. 학습 데이터로 사용된 그림 32(a)는 토지피복 면적 비율이 건물(11.63%), 차도(17.63%), 인도(9.48%), 수목(31.93%), 초지(21.28%), 나지(7.86%), 수역(0.20%)으로 산출되었다. 학습 지역의 토지피복 항목 간의 비율은 초지가 하천을 덮으면서 면적이 작은 수역과 자갈, 흙, 모래 등을 포함하는 나지가 분류 항목 중에서 가장 작은 비율을 차지하고 있고, 수목 및 초지와 같은 식생 항목이 가장 많은 비율을 차지하고 있다.




FIGURE 32. Results of land cover classification in training site

TABLE 9. Results of land cover classification area ratio for the training site

	Training data	OBIA-RF	OBIA-ANN	U-Net
Building	11.63%	11.52%	11.62%	11.65%
Car-road	17.63%	20.87%	19.96%	17.64%
Pedestrain	9.48%	8.59%	7.72%	9.40%
Tree	31.93%	31.74%	30.41%	31.70%
Grass	21.28%	22.50%	24.94%	21.23%
Bare Soil	7.86%	4.61%	5.18%	8.16%
Water	0.20%	0.17%	0.18%	0.19%

학습 지역에 대한 토지피복 분류 예측 결과를 살펴보면 건물 항목의 경우 면적 비율의 차이가 OBIA-RF 모델은 0.11%로 가장 많이 차이났고, OBIA-ANN은 0.01%로 가장 적게 차이났다. 화면 판독을 통해서 살펴보아도 모든 모델에서 건물에 대한 예측은 잘되는 것으로 나타났다. 수목 항목의 경우, 학습 데이터셋의 면적에 비해서 OBIA-ANN이 1.52%로 가장 많이 차이가 났고, U-Net이 0.23%의 차이로 다른 모델에 비해 가장 작게 차이났다. 면적 비율과 화면 판독을 통해 분류 결과를 살펴보면 수목 항목은 차도, 인도, 나지와 같은 항목에 비해서 정확하게 분류하는 것으로 나타났지만, 건물 항목보다는 정확도가 약간 떨어지는 것으로 나타났다. 이는 건물의 모서리가 명확하게 나타나는 것에 비해 수목은 잎사귀의 밀도에 따라 경계를 생성하면서 건물의 경계보다 수목의 경계선이 모호해 차이가 발생한 것으로 판단된다.


차도 항목은 학습 지역에서 면적 비율이 17.63%인데 OBIA-RF가 20.87%로 다른 모델에 비해서 가장 많은 오분류 경향이 나타났다. 화면 판독을 진행했을 때 나지를 인도와 차도로 오분류하면서 이러한

면적 비율에 차이가 발생하였다. 이에 따라 다른 모델에 비해 차도의 면적 비율이 높게 나타나고, 나지는 면적 비율이 매우 낮게 나타났다. 인도의 경우 학습 지역에서 면적 비율이 9.48%인데 OBIA-ANN이 7.72%로 가장 많은 오분류를 하는 것으로 나타났다. 화면 판독을 통해 살펴보았을 때 차도와 인도가 서로 오분류되는 경향이 발견되었다. 또한, OBIA-RF와 비슷하게 OBIA-ANN은 나지에서 오분류 경향이 많이 발생하였는데 나지를 초지로 분류하는 경향이 나타났다. 반면에 U-Net은 학습 데이터가 이미지를 사용하므로 주변을 포함하는 공간 정보와 함께 토지피복 분류를 진행한다. 이러한 특징으로 인해 분광적으로 유사한 특성을 가진 항목임에도 불구하고, 의미론적인 맥락까지 학습하기 때문에 벡터라이징 결과와 매우 비슷하게 분류하는 것으로 판단된다[179][180].

수역의 경우, 전체 면적 중 0.20%로 가장 적은 비율을 차지하였다. 이는 학습 지역의 특성상 수역이 상대적으로 적게 분포하고 있었기 때문이다. 하지만 OBIA-RF, OBIA-ANN, U-Net 모델의 분류 결과, 모든 모델에서 수역이 잘 분류되는 것으로 나타났다. 이는 데이터 특성 분석에서 나타났던 LST, NIR와 같은 적외선 영역의 영상들이 기여했을 것으로 판단된다. 또한, 학습 지역의 토지피복 분류에 있어서 건물, 차도, 인도, 수목, 초지, 나지, 수역 이외에도 다양한 토지피복이 존재할 수 있음을 고려하면, 이들에 대한 인식 능력 또한 모델의 성능을 평가하는 중요한 지표가 될 것이다. 더욱이, 실세계에서는 다양한 조건과 환경 아래에서의 토지피복 분류가 요구되므로, 이를 고려한 모델의 확장성과 범용성 또한 중요한 연구 과제가 될 수 있다.


2) 검증 지역에 대한 분류 정확도 비교

인공지능 모델이 학습된 후에 실제로 활용되기 위해서는 학습에 사용된 데이터가 아닌 데이터에 대해서도 일정한 성능이 발휘하는지에 대한 분석이 필요하다. 본 연구는 학습이 전혀 되지 않았지만, 공간적으로는 유사한 특성을 보이는 검증 지역에 대해 각 인공지능 모델을 적용하여 공간적 일반화 성능을 비교하였다. 학습 지역에서 학습된 OBIA-RF, OBIA-ANN, 그리고 U-Net 모델을 검증 지역에서 토지 피복 분류를 수행한 결과는 그림 33에 제시하였다. 검증 지역은 학습 지역과 유사한 특성을 보이지만 학습 지역에는 존재하지 않는 대운동장, 골프장 지역을 포함하고 있다.



(a) RGB Imagery of UAV

FIGURE 33. Results of land cover classification in validation site
(continue)



(b) OBIA-RF



(c) OBIA-ANN

FIGURE 33. Results of land cover classification in validation site (continue)




FIGURE 33. Results of land cover classification in validation site

각 인공지능 모델의 성능을 비교하기 위해서 검증 지역의 무작위 5,000개 검증 포인트를 활용하여 분류 정확도를 평가하였다. 토지피복 항목별로 검증 포인트 개수는 토지피복 면적에 영향을 받아 건물 640개, 차도 1192개, 인도 366개, 수목 1660개, 초지 1048개, 나지 101개, 수역 3개로 차이가 나타났다. 수역의 경우 검증 지역에 작은 분수대만 분포하여 수역의 면적이 매우 작아 포인트 개수에서 한계가 존재하였다. 하지만 앞서 분석된 결과에서 수역이 작은 면적임에도 불구하고, NIR과 LST 영상과 같은 적외선 파장 대역으로 인해 분류 정확도가 90%

이상으로 분석되었으며, 선행연구에서도 NIR 또는 식생지수 영상을 활용해 수역을 충분히 분류할 수 있는 것으로 나타났다[181]. 따라서 수역 항목의 작은 검증 포인트 개수로 인한 영향은 무시해도 될 것으로 판단된다.

검증 포인트를 기반으로 각 인공지능 모델에 대해 혼동행렬을 제작하여 부록의 표 A1-A3에 제시하였고, 본문에는 이를 종합 및 요약하여 표 10에 제시하였다. 각 토지피복 항목에 대해서 PA와 UA 지표를 이용하여 정확도와 신뢰도를 나타내었고, 전체 항목에 대해서는 OA와 Kappa를 통해 제시하였다.

TABLE 10. Accuracy of land cover classification in validation site

Land Cover	OBIA-RF		OBIA-ANN		U-Net	
	UA (%)	PA (%)	UA (%)	PA (%)	UA (%)	PA (%)
Building	95.6	95.8	95.8	96.1	96.7	96.1
Car road	86.9	67.3	81.9	73.8	89.4	92.5
Pedestrian	32.8	53.8	41.2	63.8	86.7	86.7
Tree	95.3	94.9	94.2	97.1	97.0	97.2
Grass	92.1	84.0	95.0	79.0	94.1	89.6
Bare soil	23.1	53.5	29.5	47.3	82.1	87.3
Water	100.0	100.0	100.0	18.8	0.0	0.0
OA (%)	82.3		82.9		93.0	
Kappa	0.773		0.782		0.911	

검증 포인트를 통해서 각 인공지능 모델의 OA는 OBIA-RF에서 82.3%, OBIA-ANN에서 82.9%, 그리고 U-Net에서 93.0%로 나타났다. 학습 지역에서 학습 정확도 결과와 검증 지역에 모델을 적용하였을 때, 분류 정확도는 모든 인공지능 모델에서 소폭 하락하는 경향이 나타났다. OBIA-ANN은 2.1% 정도 정확도가 감소하였고, U-Net은 2.3%, OBIA-RF는 6.4% 감소하였다. OBIA-ANN의 정확도 하락 폭이 가장 낮게 나타나는 것을 볼 수 있었지만, U-Net의 정확도가 OBIA-ANN보다 10.1% 더 높게 나타나, 전반적으로 토지피복 분류에는 U-Net이 더 유리한 것으로 판단된다.

토지피복 분류 항목별로 예측 정확도 결과를 살펴보면, 건물의 경우 모든 모델에서 분류 정확도가 95% 이상으로 산출되었으며, 수목의 경우 모든 모델에서 분류 정확도가 94% 이상으로 산출되었다. 이는 건물과 수목에 대한 분류는 모든 모델에서 공간적인 일반화 성능이 보장된 것을 의미하며, 인공지능 학습을 진행하면 비슷한 유형의 토지피복을 가진 지형에 대해서는 충분한 일반화 성능을 보일 수 있을 것으로 판단된다. 다만, 본 논문은 비슷한 토지피복 유형을 가진 지역에 대해서 시간적 변수를 제외하고 공간적인 변수를 통해 일반화 성능을 비교하였기 때문에 빌딩 밀집 지역, 주거지 밀집 지역 등 다른 토지피복 유형에 대한 추가적인 연구는 필요하다. 그리고 이미지를 학습 데이터로 사용하는 딥러닝 모델들은 일반적으로 성능이 우수하지만, 학습에 많은 시간이 필요하다. 본 연구에서 활용한 U-Net 모델은 학습 시간이 약 25시간이 소요된 것에 반해 OBIA-RF와 OBIA-ANN은 학습 시간이 1시간 이내로 완료되었다. 따라서 건물 또는 수목 항목의 분류는 많은 학습 시간이 소요되는 딥러닝 기법보다 객체 기반

영상 분석 기법의 사용이 적절할 것으로 판단된다.

인도, 초지, 나지 항목은 모든 인공지능 모델에서 PA가 90% 이하로 분석되었다. UA가 90% 이하인 분류 항목은 차도, 인도, 나지로 나타났다. 두 지표 모두 90% 이하로 나타난 분류 항목은 인도와 나지였다. 인도는 PA, 즉 정확도 측면에서 주로 차도와 초지로 오분류되는 경향을 확인하였다. 화면판독과 함께 분류 결과를 확인하면 OBIA-RF와 OBIA-ANN은 학습 지역에는 없지만 검증 지역에는 존재하는 토지피복 분류 항목에 대해서 오분류가 되는 경향이 나타났다. 검증 지역에는 초록색 망과 함께 구성되어 있는 골프장과 우레탄 및 인조잔디가 주로 분포하는 운동장 지역에서 주로 오분류되었다. U-Net은 OBIA-RF 및 -ANN에 비해 오분류 개수가 상대적으로 작았다. 다만, 차도와 인도의 경계 부근에 위치한 검증 포인트에서 서로 오분류되는 경우가 발생하였고, 학습 지역에는 존재하지 않았던 일부 하얀색 계열의 인도를 차도로 오분류하는 것을 확인하였다. UA 관점에서, 즉 신뢰도 측면에서 OBIA 기법은 주로 차도와 나지가 인도로 분류되면서 신뢰도가 낮아지는 현상을 보였으며, U-Net은 작은 비율이지만 차도의 경계 부분이 인도로 분류되면서 신뢰도가 낮아질 수 있는 것으로 나타났다.

나지는 정확도 측면에서 살펴보면 모든 인공지능 모델에서 나지를 차도, 인도, 그리고 초지로 오분류하는 것으로 나타났다. 화면판독을 통해 분류 결과를 살펴보면 흙과 자갈이 섞여 구성된 나지에서 차도와 인도로 오분류하는 경향이 OBIA-RF와 OBIA-ANN에서 나타났다. 신뢰도 측면에서 모델에 의해 분류된 나지가 차도와 인도를 포함하여 신뢰도가 낮아질 수 있는 것으로 분석되었다.

화면판독과 함께 분류 결과를 확인할 때, 학습 데이터의 양이 충분하지 않은 항목에 대해서는 분류 정확도가 떨어지는 경향을 확인하였다. 학습 데이터에 포함되지 않거나 양이 작았던 골프장, 운동장, 수역 지역이 다른 지역에 비해 상대적으로 분류 정확도가 떨어졌다. 예를 들어, U-Net은 분수대 지역의 수역 항목을 잘못 분류하였고, OBIA-RF 및 -ANN은 학습 지역에 포함되지 않은 골프장과 운동장 지역의 인공잔디를 차도, 초지 등의 항목으로 잘못 분류하는 경향이 존재하였다. 이를 극복하기 위해서는 충분한 학습 데이터의 확보가 필수적이며 추후 더 많은 지역에 대한 학습 데이터를 구축하여 학습을 진행해야 할 것으로 판단된다. 이는 딥러닝 기반 기법을 포함한 모든 인공지능 모델에서 공통적으로 요구되는 것으로 판단된다.

마지막으로, OBIA-RF 및 -ANN과 U-Net 간의 분류 정확도 차이가 나타나는 이유에 대한 분석이 필요할 것으로 판단된다. 모든 모델이 블랙박스 모형이므로 딥러닝과 객체 기반 영상 분석 기법에서 어떤 변수 혹은 특징이 정확도 차이를 만드는지 명확히 확인하는 것은 어렵다. 따라서, OBIA 기법과 U-Net의 세부적인 비교 분석을 통해 이를 밝혀내고자 하는 노력이 필요해 보인다. 이러한 과정을 통해 더욱 효과적인 토지피복 분류 기법을 도출하고, 이를 실제 현장에 적용하여 더욱 정확한 결과를 도출할 수 있을 것으로 기대된다.

V. 개별 수목 탐지 및 속성정보 추출

도시녹지는 공간적, 환경적, 그리고 생태적 가치를 지니고 있다. 특히, 수목은 도시의 미세먼지 및 이산화탄소 같은 대기오염 물질 감소, 도시열섬 현상 완화, 그리고 생태계 서비스 제공을 통해 도시 환경을 개선하는데 중요한 역할을 한다[14][182]. 하지만 수목 단위의 도시녹지는 기조 조사 방법인 현장 조사를 통해 정보를 구축하기에 한계가 있다.

본 장에서는 이러한 문제점을 해결하기 위해서 UAV 및 GeoAI를 적용하여 개별 수목 객체에 대해서 영역을 탐지하고, 속성 정보로서 수목의 구조 정보를 추출하였다. 밀집된 수목은 잎과 가지들이 서로 중첩되며 경계가 모호해진다. 이에 따라 육안 판독 및 벡터라이징을 통해 개별 수목의 영역을 구분하고 학습 데이터로 사용하는 것은 한계가 있다. 따라서 본 연구는 첫 번째로 학습 데이터를 생성하기 위해서 수목의 물리적 구조에 따라 경계를 나눌 수 있는 기법인 유역분할 기법을 적용하였다. 그리고 유역분할 기법을 적용하기 전에 대상지 내에서 수목의 영역을 추출하기 위해 토지피복의 수목 항목에 대한 분류 성능이 우수하고 학습 시간이 짧았던 객체 기반 영상 분석 기법을 적용하였다. 객체 기반 영상 분석과 유역 분할 기법을 통해 제작된 개별 수목 영역을 학습 데이터로 사용하여 딥러닝 기반 객체 분할 기법을 적용하여 UAV 영상에서 개별 수목 탐지 가능성을 실증하였다. 마지막으로 개별 수목에 대한 구조 특성을 산출 및 회귀모델을 통해 추정하여 결과를 제시하였다.

1. 수목의 형태 특성 활용 학습 데이터 구축

1) UAV 영상 및 기초 분석 데이터

가. UAV 영상 제작

회전의 UAV와 LiDAR 센서를 활용하여 포인트 클라우드와 RGB 이미지를 취득하였으며, 그림 34과 같이 데이터를 가공하여 영상을 제작하였다. 지면의 포인트 클라우드를 분류하여 DEM을 제작하고, 전체 포인트 클라우드로 DSM을 제작하였다. 또한 DEM과 DSM을 이용해서 nDSM을 제작하였다. 또한, RGB 정사영상을 제작하였으며, Red, Green, Blue 영상을 통해서 식생지수인 ExG 영상을 제작하였다.





FIGURE 34. Result of UAV-LiDAR flight for individual tree detection (continue)



(c) DSM



(d) RGB



(e) ExG

FIGURE 34. Result of UAV-LiDAR flight for individual tree detection


나. 영상분할 및 수목 영역 벡터라이징 결과

밀집된 구조의 수목들은 앞과 가지들의 영역이 중복되어 연결되기 때문에 우선 수목의 영역을 다른 피복들에서 분류한 다음에 개별 수목으로 분할해야 한다. 따라서 객체 기반 영상분석 기법을 통해 연구 대상지 내에 여러 토지피복으로부터 수목 영역을 분리하고자 그림 35에 제시한 것과 같이 화면판독 및 시행착오법을 통해서 영상분할을 진행하였다.

첫 번째로 분광 및 공간 세부 묘사의 값을 15로 설정하고 최소 객체 크기 값을 20으로 설정하였다. 이 조건에서는 수목과 다른 토지 피복 간에 경계를 잘 구분하는 것으로 나타났으나, 지붕이 있는 벤치 구역과 수목 간의 경계를 구분하지 못하였다. 분광 세부 묘사 20, 공간 세부 묘사 15, 최소 객체 크기 20 조건으로는 이러한 경계를 적절하게 구분지을 수 있는 것으로 나타났다. 그러나 분광 세부 묘사의 값이 높으면 평활화를 거의 진행하지 않으므로 소수의 픽셀만 모여 객체를 생성하면서 객체가 지나치게 작아지는 결과가 발생한다. 매우 작은 객체들은 고해상도 영상에서 발생하는 데이터 복잡성을 축소하기에 한계가 있어 노이즈로 작용할 수 있다. 따라서 최소 객체 크기 가중치를 조정해서 매우 작은 크기의 객체를 주위 객체로 병합시키는 과정을 진행하였다. 그 결과 최소 객체 크기 50까지는 경계를 유지하는 것으로 나타났으나, 100으로 설정하였을 때는 경계를 제대로 구분짓지 못하는 것으로 나타났다. 따라서 최종적으로 분광 세부 묘사 20, 공간 세부 묘사 15, 최소 객체 크기 50으로 가중치를 선정하여 영상분할을 진행하고, 수목 영역을 분류하는 작업을 진행하였다.



(a) spectral detail 15, spatial detail 15, minimum segment size 20 (b) spectral detail 20, spatial detail 15, minimum segment size 20



(c) spectral detail 20, spatial detail 15, minimum segment size 50 (d) spectral detail 20, spatial detail 15, minimum segment size 100

FIGURE 35. Segmentation for classification of tree area

수목 영역 분류에 대한 학습을 진행하기 위해 nDSM 영상과 ExG 영상을 참조하여 RGB 영상을 통해 수목 영역을 벡터라이징 한 결과는 그림 36에 제시하였다.





FIGURE 36. The result of tree crown area digitization


2) 객체 기반 영상 분석 및 구역 분할 기법 적용

영상분할 다음 단계로 수목 영역을 분류하기 위해 영상분할 결과와 UAV-LiDAR 영상을 바탕으로 OBIA-RF 학습을 진행하였다. 그리고 수목 영역 탐지에서 적절한 성능을 발휘하는 모델을 찾기 위해 n estimator와 max depth에 대한 하이퍼파라미터를 탐색하였다. 하이퍼파라미터 탐색 범위는 n estimator의 경우 10에서 300까지 설정하였으며, max depth의 경우 10에서 60까지 범위로 설정하여 비교하였고, 그 결과는 그림 37에 제시하였다.

먼저 n estimator를 살펴보면 10에서 50까지는 소폭 증가하는 경향이 나타난 후 50부터 정확도에서 거의 변화가 나타나지 않았으며, 학습 정확도가 0.965로 일정해지는 것으로 나타났다. 테스트 데이터도 학습 데이터와 비슷한 경향을 보이면서 0.948로 수렴하는 결과를 보였다. 그리고 그래프 내에서 표준편차로 신뢰 구간을 보여주는 파란 음영과 빨간 음영을 살펴보았을 때 모든 구간에서 학습 데이터에서는 0.001 이하이고, 테스트 데이터는 0.008이하로 n _estimator의 변화에 따라 큰 영향을 받지 않는 것으로 나타났다. max depth의 경우 10에서 학습 정확도가 0.965, 테스트 정확도는 0.948이었으나 20 증가할 때 학습 정확도는 0.968로 증가하였으나 테스트 정확도는 0.947로 소폭 감소하였다. 그 후부터는 학습 및 테스트 정확도의 증감은 발생하지 않았다. 신뢰구간을 살펴보았을 때 모든 구간에서 표준편차가 학습 데이터의 경우 0.001 이하이고, 테스트 데이터는 0.008 이하로 max depth의 변화에 따라 큰 영향을 받지 않는 것으로 나타났다. 그리고 최적의 파라미터는 max depth 10 및 n _estimator 300에서 학습 정확도가 0.965, 테스트 정확도가 0.948로 가장 높은 정확도를 나타냈다.



(a) Accuracy vs. n_estimators



(b) Accuracy vs. max_depth

FIGURE 37. Accuracy trend of OBIA-RF by hyper-parameter for tree classification

학습한 OBIA-RF 모델을 통해 수목 영역을 추출한 결과와 수목 영역에 대해서 백터라이징한 결과를 바탕으로 혼동행렬을 제작하였으며, 정확도를 비교한 결과는 표 11에 제시하였다. 수목의 분류 정확도는 96.3%로 나타났으며, 3장의 UAV 영상 기반 토지피복도 매핑 결과와 같이 수목의 분류 정확도에서 나타난바와 같이 높은 정확도를 나타냈다. 이는 식생의 특성을 잘 표현할 수 있는 ExG와 높이 속성을 잘 나타낼 수 있는 nDSM으로 인해 높은 정확도를 보이는 것으로 판단된다. ExG 영상은 식생 지역과 비식생 지역을 구분하는 데 유용한 지표로 사용될 수 있어 인공피복 지역과 식생 지역을 구분하는 데 기여할 수 있다. nDSM은 DSM과 DEM의 차 연산을 통해 생성되기 때문에 지면의 영향 없이 물체의 높이 정보를 알 수 있다. 이에 따라 식생 지역에서 풀, 관목, 수목을 구분하는 데 기여할 수 있다.

TABLE 11. Confusion matrix for Tree area classification based on UAV-LiDAR data

		Prediction	
		Others	Tree
True	Others	4670	266
	Tree	259	9081
Overall Accuracy		96.3%	

오분류 특징에 대해서 살펴보면 그림 38에 제시한 바와 같이 초지 위의 가로등과 같이 높이가 있는 구조물에서 나타났고, 농구장의 농구 골대에서 이러한 특징이 나타났다. 다중분광 센서가 아닌 RGB 센서를 통해 식생지수를 만들었기 때문에 분광해상도가 낮아 바닥에 있는 초록색의 우레탄 재질이 식생과 비슷한 분광 특성을 보였기 때문으로 판단된다.



FIGURE 38. Examples of misclassification for tree area classification

분류된 수목 영역을 개별 수목으로 분할하기 위해서 유역 분할 기법을 적용하여 수목 간의 경계를 생성하였다. 그러나 그림 39에 제시한 것과 같이 연구 대상지 내에 분포하고 있는 수목의 특성에 따라서 개별 수목 영역의 세분화가 다르게 나타났다. 메타세콰이어 수목처럼 형태가 원뿔형으로 뾰족한 수목은 하나의 영역으로 구분되었지만, 수목의 캐노피가 평평하고 여러 개의 봉우리가 존재하는 구조의 경우, 특히 활엽수에서는 하나의 수목에서도 유역 분할에 의해 세분화되면서 여러 영역으로 나누어지는 경향이 확인되었다.



FIGURE 39. Watershed segmentation feature based on tree shape

선행연구에서 적용된 유역 분할 기법은 수목의 꼭대기가 뽕족한 수목림에 대해서 주로 연구가 진행되었으며[155][183], 이러한 선행연구 결과들은 유역 분할 기법이 효과적인 것으로 보고하였다. 그러나 본 연구에서는 하나의 수종이 집중적으로 분포한 것과 달리 다양한 수종을 포함하며, 수목의 캐노피 형태가 원뿔형으로 뽕족한 것도 있지만 상대적으로 평평하면서 여러 개의 봉우리가 존재하는 활엽수도 함께 분포하는 지역이다. 이러한 지역에 유역 분할 기법을 적용하면 수목의 수관을 과도하게 세분화하는 결과가 나타났으며, 다양한 구조의 수목이 분포하는 지역에서 유역 분할 기법을 적용만으로 개별 수목을 분할하는 것은 한계점이 있는 것으로 판단된다[184]. 그리고 현장 조사와 함께 유역 분할의 결과를 살펴보았을 때 그림 40에 표현한 것과 같이 두 개의 수목의 하나의 영역으로 판독되는 경우가 존재하는 것을 확인하였다. 수목들이 매우 밀접하게 붙어있으면서 경계를 구분할 수 있는 높이 차가 발생하지 않는 경우 이러한 오류가 발생하였다.




FIGURE 40. Examples of misseparation of tree areas into individual trees using based on watershed segmentation

현장 조사 및 화면 판독을 통해서 유역 분할 기법에 의해 수목의 수관이 과도하게 세분화된 경우에는 병합을 진행하였다. 또한, 여러 수목의 하나의 영역으로 존재하는 경우 벡터라이징을 통해서 다시 여러 개의 수목 영역으로 분할하였다. 이와 같은 과정을 진행한 결과, 그림 41에 제시한 것과 같이 총 382개의 개별 수목 영역 데이터를 제작하였다.



FIGURE 41. Result of separating tree areas into individual tree areas using watershed segmentation based on UAV-LiDAR

본 연구는 객체 기반 영상 분석과 유역 분할 기법을 접목하여 도시 지역의 수목 영역을 추출한 뒤 개별 수목 영역을 분할하였다. 이러한 방법은 최종 결과물인 개별 수목 영역을 얻기 위해 많은 단계가 필요하며, 수목의 형태가 평평한 경우 수관을 하나의 영역으로 구분하기 어려운 한계점이 존재한다. 하지만 육안 판독을 통해서 모호한 경계를 가진 수목 경계를 구분하고 벡터라이징하는 것은 매우 어려운 일이므로 기존 현장 조사 및 육안 판독의 한계점은 해결할 수 있다. 그리고 이러한 과정을 통해 제작된 결과는 이미지 분석에서 우수한 성능을 보이는 딥러닝 기법의 학습 데이터 제작 기법으로 충분히 활용될 수 있을 것으로 판단된다.

2. 탐지 모델 학습 및 속성정보 추출

1) 딥러닝 기반 객체 분할 기법 모델 학습

앞서 분석한 결과에서 기술한 것과 같이 본 연구에서는 객체 기반 영상 분석과 유역 분할 기법을 접목하여 총 5단계에 걸쳐서 개별 수목 영역을 탐지하였다. 첫 번째로 객체 영상 분석 기법을 적용하기 위해 UAV-LiDAR 영상을 기반으로 영상분할을 진행하였다. 두 번째는 수목 영역을 학습하기 위해 학습 데이터를 구축하였다. 세 번째는 기계학습 알고리즘을 학습하고, 이를 기반으로 나무 영역을 분류하였다. 네 번째는 유역 분할 기법을 적용하여 수목 간의 경계를 구분하였다. 마지막으로 현장조사 및 화면판독을 통해서 잘못 세분화된 영역을 수정하는 과정을 진행하였다. 이러한 과정은 추후 모델이 구축 되더라도 개별 수목을 탐지하기 위해서 많은 단계를 반복해야 하는 한계점이 있다. 그러나 딥러닝 기반 객체 분할 기법은 학습 데이터 구축 후 모델 학습만을 통해 UAV 영상에서 바로 개별 수목으로 탐지할 수 있다. 또한, 일반적인 기계학습 알고리즘보다 높은 정확도를 보이고 있어 효과적인 방법이 될 수 있다. 따라서 본 연구에서는 객체 기반 영상 분석 및 유역 분할 기법의 조합을 통해 나온 결과를 학습 데이터로 사용하여 딥러닝을 통한 개별 수목 탐지를 시도하였다.

앞서 4장에서 사용한 U-Net 모델과 같은 딥러닝 기법은 의미론적 분할 기법으로 다른 객체임에도 수목으로만 분류하고 객체끼리의 구분은 하지 않는다. 반면에 객체 분할 기법은 동일한 항목의 객체끼리 서로 붙어있어도 개별 객체를 구분하여 영역을 추출한다. 본 연구에서는 딥러닝 기반 객체 분할 기법 중 하나인 Mask R-CNN을 개별

수목 탐지를 위해 적용하였고, 학습 결과는 그림 42에 제시하였다. 손실 함수의 값이 더 이상 감소하지 않는 에포크 58까지 학습을 진행하였다. 최종 학습 결과, 손실 함수의 값은 학습 데이터의 경우 0.608, 검증 데이터는 1.148로 나타났다.




FIGURE 42. Training and validation loss of Mask R-CNN for individual tree detection

Mask R-CNN 모델을 통해서 개별 수목을 탐지한 결과, 그림 43과 같이 학습 데이터로 사용한 382개의 수목보다 4개가 더 많은 386개의 수목을 탐지하였다. 화면 관독을 통해 수목의 밀도가 낮은 지역, 수목의 밀도가 높은 지역, 그리고 수목의 밀도가 높고 높이도 다양한 지역에 대한 탐지 결과를 그림 44에 제시하였다. 노란색 선으로 표현된 도형은 모델을 통해 예측한 개별 수목의 영역을 나타내고, 다양한 색상으로 표현된 도형은 학습 데이터로 사용한 개별 수목의 영역을 나타낸다.




FIGURE 43. Results of individual tree detection based on Mask R-CNN

그림 44 (a)에 제시한 것과 같이 개별 수목이 상대적으로 서로 떨어져 있어 수목 분포의 밀도가 낮은 지역은 대부분의 학습 데이터와 비슷하게 개별 수목 영역을 Mask R-CNN 모델이 잘 탐지하는 것으로 나타났다. 그러나 일부 영역에서는 모델이 학습 데이터에 없는 영역에서도 수목이 있는 것으로 판단하고 학습 데이터보다 더 넓은 영역을 수목의 영역으로 탐지하는 결과도 확인하였다.

그림 44 (b)에 제시한 것과 같이 수목의 밀도가 높은 지역은 개별 수목 간의 경계가 모호한 지역이다. 대부분의 수목들이 모델에 의해 잘 탐지되었지만, 침엽수가 밀집된 지역에서는 학습 데이터와 모델의 탐지 결과 사이에 차이점이 존재하였다. 그리고 밀집된 지역에서는 모델이 학습 데이터에 표시된 수보다 더 많은 수목을 탐지하였다. 이는 밀집된 수목들 사이의 경계는 상대적으로 더 구분하기 어려운 것을 의미한다.

그림 44(c)와 같이 다양한 높이를 가지고 있는 수목들이 밀집되어 있는 지역은 수목의 높이 차이로 인해 그림자나 빛의 변화가 발생하여, 모델이 탐지하기 어려운 경우가 있을 수 있는 지역이다. 대체적으로 모델은 학습 데이터와 비슷한 결과를 보여주고 있다. 또한, 일부 영역에서는 모델이 학습 데이터에 없는 영역에서도 수목이 있는 것으로 판단하고 학습 데이터보다 더 넓은 영역을 탐지하는 결과도 확인하였다. 화면 판독을 통해 탐지 결과를 살펴보았을 때, 대체적으로 수목의 탐지에서 좋은 성능을 보여주는 것으로 나타났다. 하지만 밀집된 지역이나 다양한 높이의 수목이 존재하는 지역에서는 정확도의 저하가 관찰되었다.



(a) Low density tree area



(b) High density tree area



(c) high density and multi-height tree area

FIGURE 44. Details of individual tree detection based on Mask R-CNN

Mask R-CNN 모델을 통해 개별 수목을 탐지한 결과를 바탕으로 정확도를 평가하였으며, 그 결과를 표 12에 제시하였다. IoU는 예측된 영역과 실제 영역 사이의 겹치는 영역을 측정하는 지표로 값이 높을수록 예측이 실제와 매우 가깝다는 것을 의미한다. IoU가 50%일 때 정밀도는 0.9534으로 나타났다. 이는 모델이 탐지한 수목 중 95.34%가 정답값과 50% 이상의 중복도를 보이며 올바르게 탐지된 것을 의미한다. 또한, 재현율은 0.9634로 나타났고, 이는 실제 수목 중에서 96.34%가 모델에 의해 올바르게 탐지된 것을 의미한다. IoU가 75%일 때는 50%일 때보다 약간 감소하였지만 정밀도와 재현율 모두 87% 이상의 정확도를 보이는 것으로 나타났다. 다만 95% IoU에서는 성능이 크게 저하된 것으로 나타났다. IoU 95%는 매우 엄격하게 정답값과 예측값의 일치 기준을 요구하는 것으로, 정답값과 정확하게 일치하는 탐지 결과가 매우 적었음을 나타낸다.

Mask R-CNN 모델을 개별 수목 탐지를 위해 적용한 결과, IoU 50% 및 75%에서 안정적인 성능을 보였으며, 개별 수목 탐지를 위해 사용될 수 있는 것으로 판단된다. 다만 본 연구에서는 일반화 성능에 대한 검토가 진행되지 않았다. 그러므로 시간 또는 공간의 차이에 따라 영상을 수집하고 Mask R-CNN 모델의 성능에 대한 평가가 필요할 것으로 판단된다.

TABLE 12. Results of accuracy for individual tree detection based on Mask R-CNN

IoU	Precision	Recall	F1 Score	AP
50%	0.9534	0.9634	0.9583	0.9419
75%	0.8756	0.8848	0.8802	0.7978
95%	0.0078	0.0079	0.0078	0.0001

2) 수목 형태 정보 산출 및 흉고직경 예측

개별 수목 탐지를 통해 수관의 영역 분석을 통해 수고와 수관면적의 산출이 가능하다. 그러나 수목의 생장 파악, 탄소 저장량 산정 등에 핵심적인 자료인 흉고직경은 개별 수목 영역에서는 산출이 안 되므로, 여러 변수를 이용해 추정해야 한다. 따라서 본 연구는 103개의 수목에 대해 수목의 위치, 흉고직경(DBH)을 현장에서 측정하고, 개별 수목 탐지 결과를 활용하여 수목의 수관면적(Crown area)과 수고(Height)를 산출하여 표 13에 제시하였다. 대상지에는 수관의 형태가 원뿔형으로 뾰족한 형태를 가지거나, 수관의 면적이 넓고 높이가 낮은 형태를 가지는 등 다양한 형태의 수목이 포함되어 있다. 이러한 특징은 수관면적과 수고만으로는 반영하기 어려우므로 포인트 클라우드 정보를 이용하여 수관 형태에 대한 특징을 나타낼 수 있도록 수관고 표준편차를 추가로 산출하여 활용하였다.

TABLE 13. Results of observed DBH and calculated tree information (continue)

(unit : m)

NO.	N	E	Height	Crown area	Height STD	DBH (cm)
1	3899965.2	472349.5	12.8	59.2	2.08	20.3
2	3899960.5	472355.3	12.1	41.3	1.74	19.9
3	3899958.8	472344.2	5.7	22.6	0.61	9.1
4	3899954.2	472348.7	6.5	28.4	0.57	12.2
5	3899951.7	472410.1	4.3	14.0	0.57	11.3
6	3899953.2	472417.0	2.7	2.5	0.36	8.5
7	3899950.6	472438.5	7.8	19.8	0.95	18
8	3899949.5	472403.2	7.9	56.9	0.89	18.2
9	3899951.1	472421.3	3.1	5.2	0.32	10.1
10	3899948.2	472353.5	5.4	14.2	0.54	8.9
11	3899948.9	472414.3	3.9	11.2	0.31	8
12	3899945.9	472429.9	4.7	6.0	0.42	10.2

TABLE 13. Results of observed DBH and calculated tree information (continue)

(unit : m)

NO.	N	E	Height	Crown area	Height STD	DBH (cm)
13	3899944.3	472450.3	7.5	11.3	1.35	15.9
14	3899944.8	472422.6	2.9	2.0	0.40	6.7
15	3899943.8	472433.9	4.4	11.1	0.44	8
16	3899941.1	472405.3	7.4	62.9	0.80	19.1
17	3899942.6	472358.6	7.1	17.2	0.58	9.4
18	3899942.4	472394.1	5.6	29.3	0.67	13.3
19	3899940.7	472431.4	3.8	3.6	0.49	8.7
20	3899941.1	472438.1	2.8	3.7	0.42	7.5
21	3899937.3	472384.8	14.3	18.6	2.58	12
22	3899935.2	472433.8	8.1	48.6	1.28	16.6
23	3899936.8	472411.0	9.1	33.7	1.19	13.2
24	3899935.8	472420.1	8.3	51.4	1.25	18.6
25	3899936.9	472363.3	7.1	15.5	1.09	8.7
26	3899936.3	472446.7	3.2	9.9	0.26	9
27	3899933.8	472451.3	3.6	9.1	0.34	7.9
28	3899931.9	472367.3	7.0	20.7	0.59	10
29	3899934.1	472440.2	4.6	12.8	0.57	8.1
30	3899934.4	472387.0	14.2	17.4	2.71	11.9
31	3899928.9	472423.2	6.2	26.1	0.86	7.9
32	3899931.2	472386.4	11.8	8.8	1.84	10.6
33	3899929.3	472449.0	2.6	4.6	0.21	7.6
34	3899926.6	472372.4	7.5	18.8	0.59	10.3
35	3899928.6	472460.6	2.8	4.0	0.24	7.8
36	3899928.9	472388.6	14.7	17.0	2.62	12.3
37	3899927.2	472453.0	2.7	3.9	0.32	7.3
38	3899926.0	472388.1	9.2	8.2	1.01	12.1
39	3899926.0	472464.6	3.1	4.8	0.41	7.2
40	3899924.1	472468.2	2.6	4.2	0.26	7
41	3899921.5	472377.2	7.2	33.2	0.77	10.2
42	3899923.0	472391.0	15.4	20.8	2.64	13.2

TABLE 13. Results of observed DBH and calculated tree information (continue)

(unit : m)


NO.	N	E	Height	Crown area	Height STD	DBH (cm)
43	3899924.5	472457.7	3.6	5.6	0.49	7.5
44	3899920.8	472385.4	8.1	18.0	0.90	15.2
45	3899918.6	472453.5	5.7	79.8	1.10	22.5
46	3899919.9	472394.3	13.5	23.8	2.02	11.9
47	3899914.5	472405.0	14.4	22.2	2.71	13.2
48	3899917.7	472398.6	12.1	22.9	2.23	13.7
49	3899916.2	472482.2	3.0	8.1	0.23	8.3
50	3899913.6	472486.0	4.1	8.2	0.43	8.2
51	3899908.8	472484.1	5.0	15.2	0.84	12.5
52	3899907.6	472421.3	12.1	25.4	1.99	11.1
53	3899908.3	472450.0	8.8	15.6	1.36	9.5
54	3899908.1	472494.5	3.1	6.8	0.36	7.6
55	3899908.9	472413.0	16.5	22.4	3.57	15.2
56	3899905.3	472390.3	6.4	25.8	0.54	9.6
57	3899905.9	472443.2	7.8	8.4	1.28	8.1
58	3899905.8	472453.4	13.2	21.5	2.42	14.1
59	3899906.5	472488.0	3.9	8.1	0.45	8.7
60	3899903.2	472447.9	6.5	6.6	1.32	6.7
61	3899903.5	472503.8	4.6	7.1	0.60	7.6
62	3899902.1	472406.3	5.6	7.8	0.72	6.2
63	3899905.1	472417.8	13.0	13.2	2.25	11
64	3899901.2	472432.8	8.1	14.9	1.01	7.5
65	3899902.6	472421.1	13.7	14.3	2.80	11.7
66	3899902.4	472444.3	4.6	7.2	0.34	6.5
67	3899902.3	472497.3	2.7	5.8	0.30	8.3
68	3899899.7	472395.4	5.1	14.4	0.52	9.2
69	3899901.7	472439.1	9.2	7.3	1.13	7.3
70	3899899.2	472500.8	3.7	9.7	0.39	9.1
71	3899896.6	472505.2	4.6	15.8	0.56	10.2
72	3899896.1	472516.2	3.0	6.2	0.24	7.1

TABLE 13. Results of observed DBH and calculated tree information

(unit : m)


NO.	N	E	Height	Crown area	Height STD	DBH (cm)
73	3899894.8	472400.2	5.9	16.1	0.70	8.2
74	3899892.0	472473.2	4.0	3.3	0.45	4.4
75	3899890.7	472525.5	3.5	8.5	0.35	7.9
76	3899892.7	472469.7	3.0	4.1	0.31	5.2
77	3899890.2	472480.5	5.5	24.6	0.76	7.4
78	3899891.9	472465.0	6.1	23.8	0.97	11.8
79	3899892.5	472496.0	6.8	8.0	1.03	5.3
80	3899891.9	472514.4	4.9	4.5	0.55	8.2
81	3899890.6	472492.4	11.3	22.0	1.79	11.2
82	3899889.1	472529.2	2.9	5.3	0.32	8.9
83	3899885.6	472523.3	3.7	16.0	0.33	10.2
84	3899888.3	472498.0	13.3	19.2	2.09	12.2
85	3899886.5	472484.1	7.4	41.8	1.16	14.3
86	3899887.6	472462.9	6.8	27.1	1.20	11.5
87	3899883.8	472527.0	2.6	3.2	0.27	6.8
88	3899880.7	472542.2	2.7	3.0	0.21	7.1
89	3899876.0	472520.9	5.3	9.3	1.02	6.4
90	3899875.9	472551.0	3.3	8.3	0.18	7.8
91	3899875.8	472539.7	4.1	9.6	0.53	8.1
92	3899874.1	472544.2	4.5	15.9	0.71	10.2
93	3899876.1	472524.8	10.5	17.5	2.16	9.4
94	3899873.5	472555.8	4.0	8.9	0.45	9.1
95	3899870.9	472559.0	4.6	13.5	0.47	12.3
96	3899871.2	472548.4	3.8	8.1	0.42	7.8
97	3899867.0	472516.9	6.7	21.2	1.13	7.3
98	3899867.1	472556.4	5.9	12.6	0.44	8.9
99	3899868.5	472530.4	6.7	12.0	1.14	6.1
100	3899863.9	472541.7	10.6	18.7	1.86	11.5
101	3899866.1	472537.5	13.0	27.0	3.00	13.5
102	3899856.5	472548.8	15.8	34.0	3.46	18.1
103	3899854.6	472538.6	5.0	13.7	0.76	9.4

흉고직경을 추정하기 위해 그림 45에 제시한 것과 같이 수관면적과 수고, 그리고 수관고 표준편차를 흉고직경 관측치와 산점도를 그리고 상관성을 분석하였다. 모든 항목에서 흉고직경과의 상관관계가 유의수준 $p < 0.01$ 에서 확인되었다. 특히, 수관면적이 흉고직경과 상관관계에서 가장 높은 적합도를 보였으며, 상관계수(R)은 0.83, 결정계수(R^2)은 0.68의 값을 나타냈다. 이어서 수고에서는 상관계수가 0.57, 결정계수가 0.32로 나타났고, 수관고 표준편차에서 상관계수는 0.52, 결정계수는 0.27의 값으로 나타났다. 수관면적, 수고, 그리고 수관고 표준편차는 통계적으로 유의수준을 만족하기 때문에 흉고직경을 추정하기 위해 사용할 수 있을 것으로 판단되며, 상관계수가 높게 나온 순서인 수관면적, 수고, 수관고 표준편차 순으로 흉고직경 예측에 중요도를 가질 것으로 판단된다.




(a) Crown area vs. DBH

FIGURE 45. The relationship between observed DBH and calculated tree information (continue)



(b) Height vs. DBH



(c) Height STD vs. DBH

FIGURE 45. The relationship between observed DBH and calculated tree information

선행연구들을 살펴보면 김성용 등 (2021)^[155]은 잣나무림의 163개의 수목에 대해서 현장 측정을 하였고, 수관면적과 흉고직경의 상관관계에서 유의수준 $p < 0.01$ 과 결정계수 0.7705를 보고하였다. 마지막으로 Iizuka et al. (2018)^[185]은 편백나무에 대해 수관면적과 흉고직경의 상관관계에서 유의수준 $p < 0.01$ 과 결정계수 0.7923을, 수고의 경우 결정계수 0.1784를 보고하였다. da Silva et al. (2021)^[186]은 유칼립투스 수목에 대한 현장 측정을 통해 수고와 흉고직경의 상관관계에서 상관계수를 0.83으로 보고하였다. 이근왕과 박준규 (2020)^[187]은 주택가의 작은 산림에 대해서 조사를 실시하였으며, 수고와 흉고직경의 결정계수가 0.1165로 나타났다. 본 연구는 수목들이 조경 관리를 받는 도시 지역인 점과 다양한 종을 포함하는 수목이 포함되어 있지만, 선행연구들은 모두 산림 지역에서 한 종의 수목림에 대해서 연구를 진행하였으므로 직접적인 비교는 어려울 수 있다. 하지만 수관면적과 수고는 선행연구의 연구결과의 범위와 유사한 것으로 나타났다. 또한, 본 연구와 선행연구들의 결과를 비교한 결과, 수목의 특성과 흉고직경 간의 상관관계는 종, 측정방법, 및 샘플 크기 등 다양한 변수에 따라 다르게 나타날 수 있음을 확인하였다.


흉고직경을 추정하기 위해 회귀 알고리즘을 학습하였다. 그리고 GridSearch CV를 통해 5 등분한 학습 데이터에서 차례로 사용된 검증 데이터에 대해서 예측을 수행하고, 정확도 지표로 RMSE와 결정계수를 표 14에 정리하고, 그림 46에 산점도를 제시하였다. 흉고직경을 추정하기 위해서 수관면적, 수고, 그리고 수관고 표준편차를 독립변수로 활용하였다. 그리고 Linear Regression, Random Forest Regression, k-NN Regression, 그리고 Support Vector Regression 모델을 학습하여

흉고직경을 추정하였다. Linear Regression 모델은 RSME가 1.94cm, 결정계수는 0.71로 산출되었다. Random Forest Regression은 RMSE가 2.42cm, 결정계수는 0.55였다. k-NN Regression은 RMSE가 2.26cm, 결정계수는 0.61로 나타났다. 마지막으로, Support Vector Regression의 결과는 RMSE가 1.86cm, 결정계수는 0.73으로 가장 높은 예측 성능을 보였다.


TABLE 14. DBH predictions results using regression models

Regression model	RMSE (cm)	R ²
Linear Regression	1.94	0.71
Random Forest Regression	2.42	0.55
k-Nearest Neighbors Resgression	2.26	0.61
Support Vector Regression	1.86	0.73

Corte et al. (2020)[188]의 연구에서는 UAV-LiDAR를 사용하여 370개의 유칼립투스 단일 수종에 대해 여러 기계학습 알고리즘을 사용해 흉고직경을 예측하였다. 본 연구에서는 수관면적이 독립 변수로 사용되었지만, 선행연구에서는 수목에 대한 다양한 높이 정보만을 독립 변수로 사용하였고, 수고와 수관고 표준편차가 사용된 점은 본 연구와 동일하게 적용되었다. 본 연구의 결과와 선행연구의 결과를 비교하였을 때, 본 연구에서 사용된 변수 및 기계학습 모델은 흉고직경을 예측 정확도를 향상시키는데 기여하였다. 특히, Support Vector Regression은 본 연구와 선행연구 모두 높은 예측 성능을 보였으며, 선행연구에서는 RMSE가 3.73 cm, R² 값이 0.40으로 본 연구의 결과가 더 나은 성능을 보였다. 이러한 결과는 수관면적과 같은 추가 변수의 도입이 흉고직경 예측 정확도 향상에 중요한 역할을 했음을 시사한다.




(a) Linear Regression




(b) Random Forest Resgression

FIGURE 46. Scatterplot for verification of DBH predictions based on UAV-LiDAR (continue)



(c) k-Nearest Neighbors (k-NN) Regression



(d) Support Vector Regression (SVR)

FIGURE 46. Scatterplot for verification of DBH predictions based on UAV-LiDAR

VI. 결 론

1. 결과 요약 및 결론

지역의 환경 정책 등 수립을 위해 환경공간정보를 제작하는 것은 현장조사, 정보 편집 등의 한계가 존재한다. 본 연구는 UAV와 GeoAI를 통해서 정밀 환경공간정보 제작 방안을 모색하였다. 토지피복과 수목 정보에 대한 사례연구를 기반으로 공간정보 재현 방식에 따른 UAV 데이터 수집과 GeoAI 적용 방안을 설계하고 분석 결과를 제시하였다.

UAV 데이터 수집과 GeoAI 기법 적용은 사례연구와 함께 두 가지 공간정보 재현 관점에서 환경공간정보 제작 방안을 검토하였다. 첫 번째는 대상지 내에서 빈 공간없이 모든 지점의 정보를 구축하는 연속적 필드 관점이다. 이는 복잡한 물리적 특성을 가진 여러 대상을 동질적인 그룹으로 분류하여 표현해야 하는 토지피복 정보를 대상으로 진행하였다. 두 번째는 특정 객체의 정보만 구축하고 그 외는 빈 공간으로 가정하는 이산적 객체 관점이다. 탄소 흡수·저장량 산정에 필요한 흉고직경, 수고 등의 정보를 구축하는 수목 정보를 대상으로 진행하였다.

토지피복 정보 수집은 다중분광, 열적외 카메라 등 UAV의 여러 탑재 센서를 통해서 토지피복의 다양한 물리적 특성을 표출하는 영상 데이터를 수집했다. 수목 정보 수집은 UAV 기반 LiDAR 센서를 통해 RGB 영상과 함께 수목의 형태 특성을 표출하는 3차원 위치 데이터를 수집했다. 그리고 고해상도 영상으로 인한 데이터 복잡성 문제를 처리하기 위해 GeoAI 기법인 객체 기반 영상 분석과 딥러닝 기법을 적용하였고, 분석한 결과는 아래와 같다.

토지피복의 여러 물리적 특성을 수집한 UAV 기반 분광 및 기하학적인 영상이 가지는 토지피복의 항목별 특성과 분류 기여도를 분석했다. 그 결과, nDSM, NDVI, SAVI, 그리고 LST 영상이 상위의 변수 중요도를 차지하였다. nDSM, NDVI와 SAVI 영상의 조합은 건물, 수목, 초지 분류에 기여하는 것으로 분석되었다. LST 영상은 차도와 인도, 나지 분류에 기여하였다. 또한, 피복에 따른 열용량 특성은 도시지역의 토지피복 분류의 기초 영상으로 고려될 수 있을 것으로 분석되었다.

다음으로 객체 기반 영상 분석(OBIA-RF, OBIA-ANN)과 딥러닝 기반 의미론적 분할(U-Net) 기법의 모델을 학습하고 분류 성능을 비교하였다. 그 결과, U-Net 모델이 전체 정확도 93.0%로 토지피복 분류에서 가장 높은 성능을 나타냈다. U-Net 모델의 입력 데이터는 2차원 이미지 형태로 내포된 공간적인 정보가 분광 정보와 함께 분류에 사용되기 때문에 사료된다. OBIA-RF 및 -ANN 모델은 U-Net 모델보다 전체 정확도에서 약 10% 정도 낮았으나 건물과 수목의 경우 정확도 및 신뢰도에서 모두 94% 이상으로 분석되었다. U-Net 모델은 25시간의 학습 시간이 소요되었고, OBIA-RF 및 -ANN 모델은 1시간 이내에 학습이 완료되었다. 건물 또는 수목 영역만 분류하는 경우 많은 학습 시간이 필요한 딥러닝 기법보다는 객체 기반 영상 분석 기법의 사용이 효율적일 것으로 판단된다.

수목 정보의 경우 딥러닝 기반 객체 분할 기법을 통해 개별 수목을 탐지하고 수관면적, 수고, 흉고직경을 속성 정보로 구축하였다. 딥러닝 기법 적용을 위해 먼저 객체 기반 영상 분석과 유역 분할 기법을 통해 개별 수목 탐지 학습 데이터 구축 방안을 제시하였다. 이는 개별 수목

탐지 방법으로만 고려할 때는 하나의 수목 영역이 여러 개로 세분화될 수 있는 한계점이 존재한다. 하지만 학습 데이터 제작 측면에서는 밀집된 수목의 중첩되고 모호한 경계로 인한 기존 현장 조사 및 벡터라이징의 한계점을 극복할 수 있을 것으로 판단된다. 이는 많은 학습 데이터가 필요한 딥러닝 기법을 적용하기 위한 연결고리 역할로서 기여할 수 있다.

제작된 개별 수목 영역을 학습 데이터로 사용해 딥러닝 기반 객체분할 기법인 Mask R-CNN 모델을 학습하였다. 그 결과, IoU 50% 및 75%에서 F1 점수가 0.9583, 0.8802로 안정적인 정확도로 분석되어 개별 수목 탐지에 활용될 수 있을 것으로 판단된다. 마지막으로 개별 수목 탐지 결과 및 UAV 영상을 통해 수목의 구조 정보인 수관면적, 수고 등을 산출하였다. 이를 독립변수로 활용해 흉고직경을 회귀 모델을 통해 예측한 결과, RMSE가 1.86cm, 결정계수가 0.73으로 나타났다. 수목의 탄소 흡수 및 저장량 산정을 위해 현장 조사보다는 정확도는 낮아질 수 있지만 UAV 영상을 통해 넓은 대상지에 대해 효율적인 개별 수목의 정보 구축에 사용할 수 있을 것으로 판단된다.

토지피복과 수목 정보에 대한 사례연구를 통해서 본 연구의 결과는 다양한 환경 데이터를 공간정보로 제작할 수 있는 방법론으로서 확장할 수 있다. 환경 관련 데이터를 수집할 수 있는 UAV와 필요한 공간정보를 추출하는 GeoAI를 접목하여 정밀 환경공간정보 구축의 자동화에 대한 방안 제시는 현지 조사 및 벡터라이징과 같은 인간의 작업을 최소화할 수 있다. 이를 기반으로 지속가능한 환경공간정보 모니터링 방안을 마련하는 것에도 기여할 수 있다.

2. 연구의 한계 및 향후 과제

본 연구는 UAV 및 GeoAI를 기반으로 환경공간정보 제작의 자동화 방안을 제시하고 실증하였다. 두 가지 공간정보 재현 관점에서 UAV 데이터 수집 방식과 GeoAI 모델 선택에 대한 방법론을 제시하였다는 점에서 의의가 있으나 다음과 같은 한계를 지닌다.

첫째, 본 연구는 한 지역을 대상으로 한 시기에 수집한 UAV 데이터를 기반으로 연구를 수행하였다. 지역의 변화는 토지이용 특성의 변화로 이어져 본 연구에서 분석한 물리적 특성들이 달라질 수 있다. 시간의 변화는 일사량의 변화로 반사되는 빛의 양이 달라져 그 특성들이 다르게 나타날 수 있다. 이로 인해 지역과 시간의 변화는 UAV 기반 수집 데이터의 특성을 다르게 할 수 있다. GeoAI 모델에서도 학습되지 않은 시·공간적 변화는 모델의 예측 성능에 대해서 일반화할 수 없는 한계점이 있다. 본 연구는 환경공간정보 구축 방법론 설계와 분석에 대해 의미가 있으나, 다양한 지역과 시간대를 대상으로 추가적인 연구가 이루어진다면, 본 연구 결과와 함께 환경공간정보 구축에 대해 보다 광범위한 일반화와 적용에 대한 더욱 풍부한 논의가 이루어질 수 있을 것이다.

둘째, 본 연구는 환경공간정보를 구축하기 위해 RF, ANN, U-Net, Mask R-CNN과 같은 GeoAI 모델을 사용하였다. 이러한 모델 구조는 블랙박스과 같이 어떤 과정에 의해 분류를 수행하는지 설명하기 어렵다. 예측 결과를 통해 과정을 해석할 수 있지만, 블랙박스 구조는 분류 정확도에 대해 명확히 설명할 수 없는 근본적인 불확실성과 신뢰성의 한계를 내포하고 있다. 본 연구는 UAV 데이터 특성 분석과 RF의

변수 중요도 분석을 통해 모델의 분류 결과에 대한 근거를 제시한 것에 대해 의미가 있다. 하지만 UAV 영상의 특성을 중심으로 모델 내부의 판단 과정을 간접적으로만 해석한 한계가 있다. 설명 가능한 인공지능(XAI, Explainable Artificial Intelligence) 연구와 같이 모델의 예측 과정을 설명하기 위한 추가적인 연구가 이루어진다면, 환경공간정보를 구축하기 위한 GeoAI 모델의 투명성과 신뢰성 강화에 기여할 수 있을 것이다.

본 연구의 결과는 효율적인 옥외환경 데이터 수집과 정밀 환경공간정보 제작 시스템 구축이 필요한 디지털트윈에 적용하는 향후 과제로 연결될 수 있다. 현재 스마트시티 개발에서는 실시간 도시 관제, 과학적 도시운영, 도시문제 예측 등의 요소가 중요시되고 있다. 디지털 트윈 기술의 발전은 스마트시티의 핵심적인 기능을 담당할 수 있다. 또한, 정밀한 환경공간정보의 제작 및 활용은 문제 예측과 해결에서 의사결정에 대한 신뢰성을 높이는 데 기여할 수 있다. 도시지역에서 본 연구는 특히, 열 환경과 대기질 문제에 적용될 수 있다. 토지피복에 따라 변화하는 보행공간의 열적 스트레스나 수목의 그늘 형성을 통한 스트레스 완화는 중요한 연구 주제이다. 또한, 토지피복과 수목의 배치는 바람의 흐름에 영향을 주어 미세먼지 확산에 중대한 영향을 미칠 수 있다. 열 환경 및 대기질 연구에 있어 토지피복 분류 항목의 증가, 엽면적지수와 같은 추가적인 연구가 필요하며, 식생의 층위 구조를 확인할 수 있는 연구도 중요하다. 이는 환경공간정보의 적용 범위를 확장하고, 보다 정확하고 신뢰할 수 있는 데이터 제공을 통해 환경 관리 및 정책 결정에 기여할 수 있을 것이다.

부 록

TABLE A1. Confusion Matrix of OBIA-RF prediction result for land cover in validation site

Classification	Reference data							Total
	Building	Car-road	Pedestrian	Tree	Grass	Bare soil	Water	
Building	613	5	2	20	0	1	0	641
Car road	3	802	56	4	39	19	0	923
Pedestrian	14	322	197	6	43	18	0	600
Tree	9	0	3	1566	65	1	0	1644
Grass	1	9	5	52	880	8	0	955
Bare soil	0	54	103	2	21	54	0	234
Water	0	0	0	0	0	0	3	3
Total	640	1192	366	1650	1048	101	3	5000
PA (%)	95.8%	67.3%	53.8%	94.9%	84.0%	53.5%	100.0%	
UA (%)	95.60%	86.90%	32.80%	95.30%	92.10%	23.10%	100.00%	
OA (%)	82.3%						Kappa	0.728

TABLE A2. Confusion Matrix of OBIA-ANN prediction result for land cover in validation site

Classification	Reference data							Total
	Building	Car-road	Pedestrian	Tree	Grass	Bare soil	Water	
Building	614	4	4	13	6	0	0	641
Car road	4	756	95	4	41	23	0	923
Pedestrian	11	201	247	5	79	48	9	600
Tree	7	2	1	1548	85	1	0	1644
Grass	2	8	6	23	907	5	4	955
Bare soil	1	53	34	2	75	69	0	234
Water	0	0	0	0	0	0	3	3
Total	639	1024	387	1595	1193	146	16	5000
PA (%)	96.1%	73.8%	63.8%	97.1%	76.0%	47.3%	18.8%	
UA (%)	95.8%	81.9%	41.2%	94.2%	95.0%	29.5%	100.0%	
OA (%)			82.9%	Kappa			0.782	

TABLE A3. Confusion Matrix of U-Net prediction result for land cover in validation site

Classification	Reference data							Total
	Building	Car-road	Pedestrian	Tree	Grass	Bare soil	Water	
Building	620	4	6	6	5	0	0	641
Car road	6	825	60	3	14	15	0	923
Pedestrian	12	36	520	3	25	4	0	600
Tree	3	1	2	1594	44	0	0	1644
Grass	2	6	8	33	899	7	0	955
Bare soil	1	20	4	1	16	192	0	234
Water	1	0	0	0	0	2	0	3
Total	645	892	600	1640	1003	220	0	5000
PA (%)	96.1%	92.5%	86.7%	97.2%	89.6%	87.3%	0.0%	
UA (%)	96.7%	89.4%	86.7%	97.0%	94.1%	82.1%	0.0%	
OA (%)			93.0%	Kappa			0.911	

참고문헌

- [1] 국토교통부. 2023. 제7차 국가공간정보정책 기본계획 (2023~2027).
- [2] 대한민국정부. 2019. 제5차 국토종합계획 (2020-2040).
- [3] 한국환경정책·평가연구원. 2016. ICT 발전트렌드에 대응하는 공간정보의 환경이슈 적용 체계 구축.
- [4] 전정배, 이길재, 정구하, 유은진. 2020. UAV 영상 정보를 활용한 국토현황조사 정보 구축. 한국농공학회지 62(1):77-84.
- [5] 전정배, 이길재, 유은진, 임거배. 2021. 농촌형 디지털 뉴딜을 위한 공간정보의 구축 및 활용. 한국농공학회지 63(2):7-12.
- [6] 이명진, 김경희, 박진형. 2014. 환경공간정보를 활용한 국가환경지도시스템 구축 및 활용 방안. 환경정책연구 13(4):51-78.
- [7] 박수정, 안종욱, 이미숙. 2021. 스마트도시 정보 관리를 위한 도시 데이터 분류체계 정립 및 적용에 관한 연구. 대한공간정보학회지 29(1):33-41.
- [8] 김수향, 박선환, 탁종석, 하종식, 주현수, 이내현. 2022. 환경영향평가에서의 대기질 확산모델 적용방법 개선 연구(I) - AERMOD 기상 전처리를 중심으로 -. 환경영향평가 31(5):271-285.
- [9] 정종석, 정광욱, 강수만, 현경학. 2018. SWMM-LID 모델을 이용한 토지투척연구원의 물순환 개선효과 평가. 한국물환경학회지 34(3):308-315
- [10] 한국환경정책·평가연구원. 2018. 우리나라 국토환경 지리정보의 활용성 제고 방안.
- [11] 낙동강수계관리위원회. 2020. 낙동강 중·하류 오염우심 하천 토지이용 변화에 따른 물환경 영향 조사.
- [12] 박건웅. 2019. UAV와 지상 LiDAR를 활용한 농업 비점오염원 탐색 기법 개발 - 야적퇴비를 중심으로- 창원대학교 대학원 석사학위 논문.

- [13] 이소영, 최지연, 김이형. 2015. 현장조사 결과를 이용한 인공습지 적정 설계 및 유지관리 방안 도출. 한국습지학회 17(4):428-435.
- [14] 박은진, 강규이. 2010. 경기도 도시가로수의 탄소저장량과 연간 이산화탄소 흡수량 산정. 한국환경생태학회지 24(5):591-600.
- [15] 홍성곤, 김남춘, 김은범. 2016. 도시 가로녹지의 생태적 건전성 평가 연구 - 경기도 광고 신도시를 중심으로 -. 한국조경학회 춘계학술대회 논문집. 59-60쪽,
- [16] 박민호, 박정일. 2016. 지자체 공간정보체계구축의 경제적 타당성 분석 연구. 한국지적정보학회지 18(3):101-116.
- [17] 조기환, 정종철. 2018. 토지피복 공간정보를 활용한 자동 혼련지역 선택 기법. 지적과 국토정보 48(2):171-183.
- [18] 대한공간정보학회, 대한국토·도시계획학회. 2023. 공간정보의 이해와 활용. (주)푸른길. 16-19쪽.
- [19] 최운수, 강영옥, 엄정섭, 차득기, 서동조, 주용진, 김재명. 2016. 공간정보학. (주)푸른길. 56-111쪽.
- [20] 정종석, 정광욱, 강수만, 현경학. 2018. SWMM-LID 모델을 이용한 토지주택연구원의 물순환 개선효과 평가. 한국물환경학회지 34(3):308-315.
- [21] 이정우, 김남원, 이정은. 2016. SWAT 모형의 지표유출해석 알고리즘 개선. 대한토목학회논문집 36(3):417-426.
- [22] 송봉근, 박경훈. 2019. 토지피복유형 특성과 도시 온도의 관계 분석 - 김해시를 대상으로 -. 한국지리정보학회지 22(2):65-81.
- [23] 김수향, 박선환, 탁종석, 하종식, 주현수, 이내현. 2022. 환경영향평가에서의 대기질 확산모델 적용방법 개선 연구(Ⅰ) - AERMOD 기상 전처리 를 중심으로 -. 환경영향평가 31(5):271-285.
- [24] 전성우, 김재욱, 정휘철. 2013. 생태계 서비스 가치평가를 위한 산림 유형 분류 방안 - 임상도와 토지피복지도 활용을 중심으로 -. 한국환경복

원기술학회지 16(3):31-39.

- [25] 김한수, 김연미, 김세한. 2020. 광역 바이오툼지도 작성기준에 관한 연구. 경기연구원.
- [26] Jo, H.-K., Kim, J.-Y., Park, H.-M. 2020. Carbon and PM2.5 Reduction and Design Guidelines for Street Trees in Korea. Sustainability 12:10414.
- [27] 환경부. 2023. 기후변화영향평가 방법 등에 관한 안내서. 8-12쪽.
- [28] Zhu, Z., Zhou, Y., Seto, K.C., Stokes, E.C., Deng, C., Pickett, S.T.A., Taubenböck, H. 2019. Understanding an urbanizing planet: Strategic directions for remote sensing. Remote Sensing of Environment 228:164-182.
- [29] Wang, L., Jia, M., Yin, D., Tian, J. 2019. A review of remote sensing for mangrove forests: 1956 - 2018. Remote Sensing of Environment 231:111223.
- [30] Tsouros, D.C., Bibi, S., Sarigiannidis, P.G. 2019. A Review on UAV-Based Applications for Precision Agriculture. Information 10:349. ISPRS Journal of Photogrammetry and Remote Sensing 152:166-177.
- [31] Ma, L., Liu, Y., Zhang, X., Ye, Y., Yin, G., Johnson, B.A. 2019. Deep learning in remote sensing applications: A meta-analysis and review.
- [32] Omar, W., Oh, Y., Chung, J., Lee, I. 2021. Aerial Dataset Integration For Vehicle Detection Based on YOLOv4. Korean Journal of Remote Sensing 37(4):747-761.
- [33] 손승우, 유재진, 전형진, 임성하, 강영은, 윤정호. 2017. UAS 기반 대형 폐기물 발생량 측정 가능성 모색. 대한원격탐사학회지 33(5-3):809-820.
- [34] 이근상, 이종조. 2016. UAV 기반 열적외선 카메라를 이용한 태양광 모듈 고장진단 실험. 한국지리정보학회지 19(4):106-117.

- [35] 정광민. 2021. 고해상도 정사영상을 이용한 딥러닝 기반의 산림수종 분류에 관한 연구. 한국지리정보학회지 24(3):1-9.
- [36] Khaliq, A., Comba, L., Biglia, A., Ricauda Aimonino, D., Chiaberge, M., Gay, P. 2019. Comparison of Satellite and UAV-Based Multispectral Imagery for Vineyard Variability Assessment. Remote Sens. 11:436.
- [37] 김계림, 유주형. 2020. UAV 자료와 객체기반영상분석을 활용한 대축척 갯벌 표층 퇴적상 분류도 작성. 대한원격탐사학회지 36(2-2):277-292.
- [38] 김형우, 김민호, 이양원. 2022. 딥러닝을 이용한 원격탐사 영상분석 연구 동향. 대한원격탐사학회지 38(5-3):819-834.
- [39] 강영욱. 2023. GeoAI 활용 분야와 연구 동향. 대한지리학회지 58(4):395-418.
- [40] Zhang, L., Huang, X., Huang, B., and Li, P. 2006. A pixel shape index coupled with spectral information for classification of high spatial resolution remotely sensed imagery. IEEE Trans. Geosci. Remote Sens. 44:2950 - 2961.
- [41] Timm, B.C., McGarigal, K. 2012. Fine-scale remotely-sensed cover mapping of coastal dune and salt marsh ecosystems at Cape Cod National Seashore using Random Forests. Remote Sens. Environ. 127:106 - 117.
- [42] Hayes, M.M., Miller, S.N., Murphy, M.A. 2014. High-resolution landcover classification using Random Forest. Remote Sens. Lett. 5:112 - 121.
- [43] Tamouridou, A., Alexandridis, T., Pantazi, X., Lagopodi, A., Kashefi, J., Moshou, D. 2017. Evaluation of UAV imagery for mapping *Silybum marianum* weed patches. Int. J. Remote Sens. 38: 2246 - 2259.
- [44] Duro, D.C., S.E. Franklin, and M.G. Dubé. 2012. A comparison of

- pixel-based and object-based image analysis with selected machine learning algorithms for the classification of agricultural landscapes using SPOT-5 HRG imagery. *Remote Sensing of Environment* 118:259-272.
- [45] Zhang, L., Zhang, L., Du, B. 2016. Deep learning for remote sensing data: a technical tutorial on the state of the art. *IEEE Geoscience and Remote Sensing Magazine* 4:22 - 40.
- [46] Zhang, H., Li, J., Wang, T., Lin, H., Zheng, Z., Li, Y., Lu, Y. 2018. A manifold learning approach to urban land cover classification with optical and radar data. *Landsc. Urban Plan.* 172:11 - 24.
- [47] Jo, H.K., Kim, J.Y., Park, H.M. 2020. Carbon and PM2.5 Reduction and Design Guidelines for Street Trees in Korea. *Sustainability* 12:10414.
- [48] 낙동강수계관리위원회. 2021. 낙동강 중·하류 오염우심 하천 토지이용 변화에 따른 물환경 영향 조사. 1-233쪽.
- [49] Mozgeris G. 2009. The continuous field view of representing forest geographically: from cartographic representation towards improved management planning. *S.A.P.I.E.N.S* [Online], 2.2.
- [50] Pajares, G. 2015. Overview and current status of remote sensing applications based on unmanned aerial vehicles (UAVs). *Photogramm. Eng. Remote Sens.* 81:281 - 329.
- [51] Eisenbeiss, H. 2009. UAV Photogrammetry. Doctoral thesis, ETH Zurich, Zürich, Switzerland. 1-13pp.
- [52] Uysal, M., Toprak, A.S., Polat, N. 2015. DEM generation with UAV Photogrammetry and accuracy analysis in Sahitler hill. *Measurement* 73:539-543.
- [53] Song, B., Park, K. 2020. Verification of Accuracy of Unmanned Aerial Vehicle (UAV) Land Surface Temperature Images Using

In-Situ Data. *Remote Sens.* 12:288.

- [54] Ferrer-González, E., Agüera-Vega, F., Carvajal-Ramírez, F., Martínez-Carricondo, P. 2020. UAV Photogrammetry Accuracy Assessment for Corridor Mapping Based on the Number and Distribution of Ground Control Points. *Remote Sens.* 12:2447.
- [55] Zhang, Q., Qin, R., Huang, X., Fang, Y., Liu, L. 2015. Classification of ultra-high resolution orthophotos combined with DSM using a dual morphological top hat profile. *Remote Sens.* 7:16422 - 16440.
- [56] 김혜진, 김지영, 김용일. 2019. UAV 영상을 이용한 객체기반 건물 추출에 관한 연구. *대한공간정보학회지* 27(4):21-28.
- [57] Zhang, L., Huang, X., Huang, B., and Li, P. 2006. A pixel shape index coupled with spectral information for classification of high spatial resolution remotely sensed imagery. *IEEE Trans. Geosci. Remote Sens.* 44:2950 - 2961.
- [58] Timm, B.C., McGarigal, K. 2012. Fine-scale remotely-sensed cover mapping of coastal dune and salt marsh ecosystems at Cape Cod National Seashore using Random Forests. *Remote Sens. Environ.* 127:106 - 117.
- [59] Hayes, M.M., Miller, S.N., Murphy, M.A. 2014. High-resolution landcover classification using Random Forest. *Remote Sens. Lett.* 5:112 - 121.
- [60] Tamouridou, A., Alexandridis, T., Pantazi, X., Lagopodi, A., Kashefi, J., Moshou, D. 2017. Evaluation of UAV imagery for mapping *Silybum marianum* weed patches. *Int. J. Remote Sens.* 38: 2246 - 2259.
- [61] Yao, H., Qin, R., and Chen, X. 2019. Unmanned Aerial Vehicle for Remote Sensing Applications-A Review. *Remote Sens.* 11:1443.
- [62] 김태우, 홍순현, 최현, 이광호. 2018. UAV를 활용한 효율적인 도로 급사

- 면 단면추출. 한국지형공간정보학회지 26(1):69-75.
- [63] 이성재, 최요순. 2015. 고정익 무인항공기(드론)를 이용한 노천광산 지형 측량 기술의 현장실증. 터널과지하공간 25(6):527-533.
- [64] 이성재, 최요순. 2016. 고정익 무인항공기(드론)와 보급형 회전익 무인항공기를 이용한 지형측량 결과의 비교. 터널과지하공간 26(1):24-31.
- [65] Chen, J., Li, K., Chang, K., Sofia, G., and Tarolli, P. 2015. Open-pit mining geomorphic feature characterization. Int. J. Appl. Earth Obs. 42:76 - 86.
- [66] 김준석, 홍일영. 2021. YOLO 신경망 기반의 UAV 영상을 이용한 건물 객체 탐지 분석. 한국측량학회지 39(6):381-392.
- [67] 최경아. 2021. 드론 및 AI를 이용한 해안쓰레기 모니터링 체계: 제주도 사례 중심으로. 대한공간정보학회지 29(4):127-138.
- [68] 김연준, 유영걸. 2020. 드론 사진측량과 공간정보를 이용한 하천변화 분석. 대한공간정보학회지 28(3):29-37.
- [69] 김휘영, 최경아, 이임평. 2018. 드론 영상 기반 시설물 점검 - 기준 영상을 활용한 자동 처리 중심으로. 한국지형공간정보학회지 26(2):21-32.
- [70] 이준형, 윤병만, 김서준. 2021. 드론 정사영상을 이용한 무참조점 표면유속 산정 기법 개발. 응용생태공학회 8(1):22-31.
- [71] 박준규, 정갑용. 2018. 드론을 활용한 산림공간정보 조사 및 분석. 한국산학기술학회논문지 19(2):602-607.
- [72] 서준표, 우충식, 이창우, 김동엽. 2018. 무인기를 활용한 산지 땅밀림 피해지점 탐지 및 모니터링 방안 연구. 한국산학기술학회논문지 19(11):481-487.
- [73] 임예슬, 어양담, 전민철, 이미희, 편무욱. 2016. 월별 드론 영상을 이용한 밴드 조합에 따른 수목 개체 및 수관폭 추출 실험. 한국지형공간정보학회지 24(4):67-74.

- [74] Chang, A., Jung, J., Maeda, M.M. and Landivar, J. 2017. Crop height monitoring with digital imagery from Unmanned Aerial System (UAS). *Comput. Electron. Agric.* 141:232 - 237.
- [75] Bendig, J., Bolten, A., Bennertz, S., Broscheit, J., Eichfuss, S., and Bareth, G. 2014. Estimating Biomass of Barley Using Crop Surface Models (CSMs) Derived from UAV-Based RGB Imaging. *Remote Sens.* 6:10395-10412.
- [76] Huang, H., Deng, J., Lan, Y., Yang, A., Deng, X., and Zhang, L. 2018. A fully convolutional network for weed mapping of unmanned aerial vehicle (UAV) imagery. *PLoS ONE* 13:1 - 19.
- [77] 김재학, 이동하. 2020. UAV 영상을 활용한 3D 건물 객체 데이터 갱신 및 관리 시스템 개발. *대한공간정보학회지* 28(3):77-83.
- [78] Hugenholtz, C.H., Walker, J., Brown, O., and Myshak, S. 2015. Earthwork volumetrics with an unmanned aerial vehicle and softcopy photogrammetry. *J. Surv. Eng.* 141(1):06014003.
- [79] Yang, B., Zhu, Y., and Zhou, S. 2021. Accurate Wheat Lodging Extraction from Multi-Channel UAV Images Using a Lightweight Network Model. *Sensors* 21:6826.
- [80] Saravia, D., Salazar, W., Valqui-Valqui, L., Quille-Mamani, J., Porras-Jorge, R., Corredor, F.-A., Barboza, E., Vásquez, H.V., Casas Diaz, A.V., and Arbizu, C.I. 2022. Yield Predictions of Four Hybrids of Maize (*Zea mays*) Using Multispectral Images Obtained from UAV in the Coast of Peru. *Agronomy* 12:2630.
- [81] Lambert, J., Hicks, H., Childs, D., and Freckleton, R. 2018. Evaluating the potential of Unmanned Aerial Systems for mapping weeds at field scales: A case study with *Alopecurus myosuroides*. *Weed Res.* 58:35 - 45.
- [82] Näsi, R., Viljanen, N., Kaivosoja, J., Alhonoja, K., Hakala, T.,

- Markelin, L., and Honkavaara, E. 2018. Estimating Biomass and Nitrogen Amount of Barley and Grass Using UAV and Aircraft Based Spectral and Photogrammetric 3D Features. *Remote Sens.* 10:1082.
- [83] Liu, Y., Liu, S., Li, J., Guo, X., Wang, S., and Lu J. 2019. Estimating biomass of winter oilseed rape using vegetation indices and texture metrics derived from UAV multispectral images. *Comput. Electron. Agric.* 166:105026.
- [84] 나상일, 박찬원, 소규호, 안호용, 이경도. 2018. 국내 작황 모니터링을 위한 무인항공기 적용방안. *대한원격탐사학회지* 34(5):829-846.
- [85] 김성현, 문병현, 송봉근, 박경훈. 2019. 농업지역 소하천의 수질 특성 파악을 위한 UAV 영상 활용 가능성 분석. *한국지리정보학회* 22(3):10-20.
- [86] 최은영, 정경미, 윤종수, 장정희, 김미정, 이호중. 2021. 하천 녹조 모니터링을 위한 드론 다중분광영상의 분광지수 적용성 평가. *대한원격탐사학회* 37(3):419-430.
- [87] Song, B., and Park, K. 2020. Detection of Aquatic Plants Using Multispectral UAV Imagery and Vegetation Index. *Remote Sens.* 12:387.
- [88] 서춘옥, 임재형, 김형매, 윤희천. 2018. 다중분광 카메라 탑재 드론 영상 기반 토지피복도 제작 및 활용성 평가. *한국측량학회지* 36(6):589-599.
- [89] 이근상, 최연웅, 임승현, 조기성. 2022. 드론 영상 기반 식생지수를 이용한 농경지 토지이용 분류. *한국측량학회지* 40(6):475-486.
- [90] 이화선, 서원우, 우충식, 이규성. 2019. 산림 식생 모니터링을 위한 무인기 다중분광영상의 반사율 산출 및 평가. *대한원격탐사학회* 35(6):1149-1160.
- [91] 신정일, 서원우, 김태정, 우충식, 박주원. 2019. 산불 피해강도 분류를 위한 고해상도 위성 및 무인기 다중분광영상의 활용 가능성 분석. *대한원격탐사학회* 35(6-2):1095-1106.

- [92] 정운영, 김상욱. 2020. 소나무재선충병 피해목 탐지를 위한 UAV기반의 식생지수 비교 연구. *지적과 국토정보* 50(1):201-214.
- [93] Wang, Y.W., Reder, N.P., Kang, S., Glaser, A.K., and Liu, J.T.C. 2017. Multiplexed Optical Imaging of Tumor-Directed Nanoparticles: A Review of Imaging Systems and Approaches. *Nanotheranostics* 1(4):369-388.
- [94] Suomalainen, J., Anders, N., Iqbal, S., Roerink, G., Franke, J., Wenting, P., Hünninger, D., Bartholomeus, H., Becker, R., and Kooistra, L. 2014. A lightweight hyperspectral mapping system and photogrammetric processing chain for unmanned aerial vehicles. *Remote Sens.* 6:11013 - 11030.
- [95] Burkart, A., Cogliati, S., Schickling, A., and Rascher, U. 2014. A novel UAV-based ultra-light weight spectrometer for field spectroscopy. *IEEE Sens. J.* 14:62 - 67.
- [96] Lucieer, A., Malenovský, Z., Veness, T., Wallace, L. 2014. HyperUAS –Imaging spectroscopy from a multirotor unmanned aircraft system. *J. Field Robot.* 31:571 - 590.
- [97] Zhang, X., Han, L., Dong, Y., Shi, Y., Huang, W., Han, L., González-Moreno, P., Ma, H., Ye, H., and Sobeih, T. 2019. A Deep Learning-Based Approach for Automated Yellow Rust Disease Detection from High-Resolution Hyperspectral UAV Images. *Remote Sens.* 11:1554.
- [98] Sankey, T., Donager, J., McVay, J., and Sankey, J.B. 2017. UAV lidar and hyperspectral fusion for forest monitoring in the southwestern USA. *Remote. Sens. Environ.* 195:30-43.
- [99] Ishida, T., Kurihara, J., Viray, F.A., Namuco, S.B., Paringit, E.C., Perez, G.J., Takahashi, Y., and Marciano J.J. 2018. A novel approach for vegetation classification using UAV-based hyperspectral imaging. *Comput. Electron. Agric.* 144:80-85.

- [100] Yu, R., Luo, Y., Zhou, Q., Zhang, X., Wu, D., and Ren, L. 2021. A machine learning algorithm to detect pine wilt disease using UAV-based hyperspectral imagery and LiDAR data at the tree level. *Int. J. Appl. Earth. Obs. Geoinf.* 101:102363.
- [101] Natesan, S., Armenakis, C., Benari, G., and Lee, R. 2018. Use of UAV-Borne Spectrometer for Land Cover Classification. *Drones* 2:16.
- [102] 장원진, 김진욱, 김진휘, 박용은, 김성준. 2020. 초분광영상을 활용한 농업용 담수호 수질 예측 소개. *한국수자원학회* 53(11):110-119.
- [103] 유준호, 김동수, 신형섭. 2020. 초분광 스펙트로미터를 활용한 분광특성 기반의 수심 측정 기법 적용성 검토. *대한원격탐사학회* 36(2-1):103-119.
- [104] Song, B., and Park, K. 2020. Verification of Accuracy of Unmanned Aerial Vehicle (UAV) Land Surface Temperature Images Using In-Situ Data. *Remote Sens.* 12:288.
- [105] Liu, T., Li, R., Zhong, X., Jiang, M., Jin, X., Zhou, P., Liu, S., Sun, C., and Guo, W. 2018. Estimates of rice lodging using indices derived from UAV visible and thermal infrared images. *Agr. Forest Meteorol.* 252:144 - 154.
- [106] Rudol, P., and Doherty, P. 2008. Human body detection and geolocalization for UAV search and rescue missions using color and thermal imagery. In *Proceedings of the IEEE Aerospace Conference, Big Sky, MT, USA*, 1 - 8; pp. 1 - 8.
- [107] Giitsidis, T., Karakasis, E.G., Gasteratos A., and Sirakoulis, G.C. 2015. Human and Fire Detection from High Altitude UAV Images. 2015 23rd Euromicro International Conference on Parallel, Distributed, and Network-Based Processing, Turku, Finland, pp. 309-315.

- [108] 나상일, 안호용, 박찬원, 홍석영, 소규호, 이경도. 2020. 봄배추 생육이상 평가를 위한 드론 열적외 영상 기반 작물 수분 스트레스 지수(CWSI) 분포도 작성. 대한원격탐사학회지 36(5-1):667-677.
- [109] Hossain, K., Villebro, F., and Forchhammer S. 2020. UAV image analysis for leakage detection in district heating systems using machine learning. Pattern Recognition Letters 140:158-164.
- [110] 김성현, 박경훈, 이수아, 송봉근. 2022. UAV와 ENVI-met을 활용한 공간 유형별 열환경 특성 분석. 한국지리정보학회 25(1):28-43.
- [111] Smith, P., Sarricolea, P., Peralta, O., Aguila, J.P., and Thomas, F. 2021. Study of the urban microclimate using thermal UAV. The case of the mid-sized cities of Arica (arid) and Curicó (Mediterranean), Chile. Building and Environment 206:108372.
- [112] Salach A, Bakula K, Pilarska M., Ostrowski, W., Górski, K., Kurczyński, Z. 2018. Accuracy assessment of point clouds from LiDAR and dense image matching acquired using the UAV platform for DTM creation. Isprs Int J Geo-inf 7(9):342 - 357.
- [113] Wallace, L., Lucieer, A., Watson, C., Turner, D. 2012. Development of a UAV-LiDAR System with Application to Forest Inventory. Remote Sens. 4: 1519-1543.
- [114] Getzin, S., Nuske, R.S., Wiegand, K. 2014. Using Unmanned Aerial Vehicles (UAV) to Quantify Spatial Gap Patterns in Forests. Remote Sens. 6:6988-7004.
- [115] Liu, K., Shen, X., Cao, L., Wang, G., Cao, F. 2018. Estimating forest structural attributes using UAV-LiDAR data in Ginkgo plantations. ISPRS Journal of Photogrammetry and Remote Sensing 146:465-482.
- [116] 최미경, 김주철, 신지혜, 펠릭스 마이카, 이승수, 정관수. 2021. UAV를 활용한 홍수모니터링 기술. 대한토목학회지 69(1):30-39.
- [117] Lin, Y.C., Cheng, Y.T., Zhou, T., Ravi, R., Hasheminasab, S.M.,

- Flatt, J.E., Troy, C., Habib, A. 2019. Evaluation of UAV LiDAR for Mapping Coastal Environments. *Remote Sens.* 11:2893.
- [118] Karan, E.P., Sivakumar, R., Irizarry, J., Guhathakurta, S. 2014. Digital modeling of construction site terrain using remotely sensed data and geographic information systems analyses. *J. Constr. Eng. Manag.* 140: 04013067.
- [119] Ismail, A., Ahmad Safuan, A.R., Sa'ari, R., Wahid Rasib, A., Mustaffar, M., Asnida Abdullah, R., Kassim, A., Mohd Yusof, N., Abd Rahaman, N., Kalatehjari, R. 2022. Application of combined terrestrial laser scanning and unmanned aerial vehicle digital photogrammetry method in high rock slope stability analysis: A case study. *Meas. J. Int. Meas. Confed.* 195: 111161.
- [120] Jia Yi, T. and Ahmad, A.B. 2023. QUALITY ASSESSMENTS OF UNMANNED AERIAL VEHICLE (UAV) AND TERRESTRIAL LASER SCANNING (TLS) METHODS IN ROAD CRACKS MAPPING, *Int. Arch. Photogramm. Remote Sens. Spatial Inf. Sci.*, XLVIII-4/W6-2022:183 - 193.
- [121] Teng, G.E., Zhou, M., Li, C.R., Wu, H.H., Li, W., Meng, F.R., Zhou, C. C., and Ma, L. 2017. MINI-UAV LIDAR FOR POWER LINE INSPECTION, *Int. Arch. Photogramm. Remote Sens. Spatial Inf. Sci.*, XLII-2/W7:297 - 300.
- [122] Roca, D., Armesto, J., Lagüela, S., and Díaz-Vilariño, L. 2014. Lidar-equipped uav for building information modelling, *Int. Arch. Photogramm. Remote Sens. Spatial Inf. Sci.*, XL-5:523 - 527.
- [123] Mead, R.A and M.P. Meyer. 1977. LANDSAT Digital Data Application to Forest Vegetation and Land Use Classification in Minnesota. 1977 Machine Processing of Remotely Sensed Data Symposium p.270-279.
- [124] Joyce, A.T. 1978. Procedures for Gathering Ground Truth

Information for a Supervised Approach to a Computer-Implemented Land Cover Classification of Landsat-Acquired Multispectral Scanner Data. NASA.

- [125] Thanh Noi, P., Kappas, M. 2018. Comparison of Random Forest, k-Nearest Neighbor, and Support Vector Machine Classifiers for Land Cover Classification Using Sentinel-2 Imagery. *Sensors* 18:18.
- [126] Tehrany, M.S., Pradhan, B., Jebuv, M.N., 2014. A comparative assessment between object and pixel-based classification approaches for land use/land cover mapping using SPOT 5 imagery. *Geocarto Int.* 29:351 - 369.
- [127] Blaschke, T., Lang, S., Hay, G.J. (Eds.). 2008. Object-based image analysis: spatial concepts for knowledge-driven remote sensing applications. Springer Science & Business Media
- [128] Su, T., Zhang, S. 2017. Local and global evaluation for remote sensing image segmentation. *ISPRS J. Photogramm. Remote Sens.* 130, 256 - 276.
- [129] Feng, X., Jiang, Y., Yang, X., Du, M., Li, X. 2019. Computer vision algorithms and hardware implementations: A survey. *Integration, the VLSI Journal* 69:309-320.
- [130] Herold, M., Gardner, M., Hadley, B. and Roberts, D. 2002. The Spectral Dimension in Urban Land Cover Mapping from High-Resolution Optical Remote Sensing Data. *Proceedings of the 3rd Symposium on Remote Sensing of Urban Areas*, June 2002, Istanbul.
- [131] 송봉근. 2014. 도시지역의 기후변화 및 열섬효과 완화를 위한 환경계획 기법의 개발. 창원대학교 박사학위논문 9-18쪽, 36-42쪽.
- [132] 김참. 2011. 도시공원의 탄소저감 효과에 관한 연구 - 판교 나들이공원을 대상으로- 경원대학교 산업·환경대학원 석사학위논문 57-58쪽.

- [133] Vega, C., St-Onge, B. 2009. Mapping site index and age by linking a time series of canopy height models with growth curves. *Journal of the Forest Ecology and Management* 257(3):951-959.
- [134] 장안진, 김용민, 김용일, 이병길, 어양담. 2012. KOMPSAT-2 위성영상을 이용한 산림의 수관 밀도 추정. *한국지형공간정보학회지* 20(1):83-91.
- [135] 장안진, 유기윤, 김용일, 이병길. 2006. 컬러항공사진과 LiDAR 데이터를 이용한 수목 개체 및 수고 추정. *대한원격탐사학회지* 22(6): 543-551.
- [136] 이현직, 유지호. 2012. 산림바이오매스 산정을 위한 LiDAR 자료와 고해상도 위성영상 활용. *한국지형공간정보학회지* 20(1): 53-63.
- [137] 임예슬. 2017. 드론 영상에 의한 수목 구조 특성 추출 연구. *건국대학교 석사학위논문* 35-36쪽.
- [138] USGS. 2022. Landsat Soil Adjusted Vegetation Index. <https://www.usgs.gov/landsat-missions/landsat-soil-adjusted-vegetation-index>. (Accessed October 19, 2022)
- [139] Immitzer, M., Vuolo, F., and Atzberger, C. 2016. First experience with Sentinel-2 data for crop and tree species classifications in central Europe. *Remote Sens.* 8:166.
- [140] De Luca, G., J.M. N. Silva, S. Cerasoli, J. Araújo, J. Campos, S. Di Fazio, and G. Modica. 2019. Object-Based Land Cover Classification of Cork Oak Woodlands using UAV Imagery and Orfeo ToolBox. *Remote Sensing* 11:1238.
- [141] Myint, S.W., P. Gober, A. Brazel, S. Grossman -Clarke, and Q. Weng. 2011. Per-pixel vs. object-based classification of urban land cover extraction using high spatial resolution imagery. *Remote Sensing of Environment* 115:1145-1161.
- [142] 김배성, 박미성, 송성환, 민병길. 2010. 인공위성을 이용한 벼 재배면적

조사 시범연구. 한국농촌경제연구원.

- [143] Qin, R., Huang, X., Gruen, A., and Schmitt, G. 2015. Object-Based 3-D Building Change Detection on Multitemporal Stereo Images. *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing* 8:2125-2137.
- [144] Cooner, A.J., Shao, Y., Campbell, J.B. 2016. Detection of Urban Damage Using Remote Sensing and Machine Learning Algorithms: Revisiting the 2010 Haiti Earthquake. *Remote Sens.* 8:868.
- [145] Thanh Noi, P., Kappas, M. 2018. Comparison of Random Forest, k-Nearest Neighbor, and Support Vector Machine Classifiers for Land Cover Classification Using Sentinel-2 Imagery. *Sensors* 18:18.
- [146] 송아람, 김용일. 2017. 딥러닝 기반의 초분광영상 분류를 사용한 환경 공간정보시스템 활용. *대한원격탐사학회지* 33(6):1061-1073.
- [147] 서기환, 오창화, 김다윗, 이민영. 2019. 지속가능한 국토발전을 위한 토지이용변화 모니터링 방안 연구: 딥러닝 알고리즘 활용을 중심으로. 국토연구원.
- [148] Kuhn, M., and Johnson K. 2017. *Applied Predictive modeling*. Springer.
- [149] 조현길, 안태원. 2000. 자연생태계 수목의 생장에 따른 탄소저장 및 흡수량 지표. *한국환경생태학회지* 14(3):175-182.
- [150] 손영모, 이경학, 김래현, 서정호. 2006. 생장모니터링을 통한 임분변화예측 및 탄소흡수·저장량 평가. *임산에너지* 25(2):42-48.
- [151] 이경학, 손영모, 서정호, 김래현. 2007. 산림부문 온실가스 흡수원 배출원 인벤토리 평가. 국립산림과학원 5-11쪽.
- [152] 손영모, 이경학, 박영규, 김래현, 권순덕. 2008. 산림부문 온실가스 흡수·배출계수 관리 방안. 국립산림과학원 9-17쪽.
- [153] 조현길, 안태원. 2001. 도시 침엽수에 의한 연한 CO₂ 흡수 및 대기정화

-소나무와 잣나무를 대상으로- 한국환경생태학회지 15(2):118-124.

- [154] Kanda, F., Kubo M., and Muramoto, K. 2004. Watershed segmentation and classification of tree species using high resolution forest imagery. 2004 IEEE International Geoscience and Remote Sensing Symposium, Anchorage, AK, USA, 2004, vol.6, pp. 3822-3825.
- [155] 김성용, 정재현, 이선주, 권춘근. 2021. 무인기 기술을 이용한 경부 봉화 지역 잣나무림의 수고 및 흉고직경 추정. 농업생명과학연구 55(2):25-32.
- [156] Kornilov, A., Safonov, I., Yakimchuk, I. 2022. A Review of Watershed Implementations for Segmentation of Volumetric Images. J Imaging 8(5):127.
- [157] Santos, A.A., Marcato Junior, J., Araújo, M.S., Di Martini, D.R., Tetila, E.C., Siqueira, H.L., Aoki, C., Eltner, A., Matsubara, E.T., Pistori, H., et al. 2019. Assessment of CNN-based methods for individual tree detection on images captured by RGB cameras attached to UAVS. Sensors 19:3595.
- [158] Nezami, S., Khoramshahi, E., Nevalainen, O., and Honkavaara, E. 2020. Tree species classification of drone hyperspectral and RGB imagery with Deep Learning Convolutional Neural Networks. Remote Sens. 12:1070.
- [159] He, K., Gkioxari, G., Doll'ar, P., and Girshick, R. 2017. Mask R-CNN. In Proceedings of the 2017 IEEE International Conference on Computer Vision (ICCV), Venice, Italy, 22 - 29 October 2017: pp. 2961 - 2969.
- [160] Yang, M., Mou, Y., Liu, S., Meng, Y., Liu, Z., Li, P., Xiang, W., Zhou, X., and Peng, C. 2022. Detecting and mapping tree crowns based on convolutional neural network and Google Earth images. Int. J. Appl. Earth Obs. Geoinf. 108:102764.

- [161] Ocer, N.E., Kaplan, G., Erdem, F., Kucuk Matci, D., and Avdan, U. 2020. Tree extraction from multi-scale UAV images using Mask R-CNN with FPN. *Remote Sens. Lett.* 11:847 - 856.
- [162] Yang, M., Zhou, X., Liu, Z., Li, P., Tang, J., Xie, B., and Peng, C. 2022. A Review of General Methods for Quantifying and Estimating Urban Trees and Biomass. *Forests* 13:616.
- [163] Zhao, W., Du, S., and Emery, W.J. 2017. Object-based convolutional neural network for high-resolution imagery classification. *IEEE J. Sel. Top. Appl. Earth Obs. Remote Sens.* 10:3386 - 3396.
- [164] 전성우, 김재욱, 정휘철. 2013. 생태계 서비스 가치평가를 위한 산림 유형 분류 방안 - 임상도와 토지피복지도 활용을 중심으로 -. *한국환경복원기술학회지* 16(3):31-39.
- [165] 김수향, 박선환, 탁종석, 하중식, 주현수, 이내현. 2022. 환경영향평가에서의 대기질 확산모델 적용방법 개선 연구(I) - AERMOD 기상 전처리를 중심으로 -. *환경영향평가* 31(5):271-285.
- [166] 송봉근, 박경훈. 2019. 토지피복유형 특성과 도시 온도의 관계 분석 - 김해시를 대상으로 -. *한국지리정보학회지* 22(2):65-81.
- [167] Kim, E.J., J. Won, and J. Kim. 2019. Is Seoul Walkable? Assessing a Walkability Score and Examining Its Relationship with Pedestrian Satisfaction in Seoul, Korea. *Sustainability* 11:6915.
- [168] 정종석, 정광욱, 강수만, 현경학. 2018. SWMM-LID 모델을 이용한 토지주택연구원의 물순환 개선효과 평가. *한국물환경학회지* 34(3):308-315
- [169] Lv, Z., Shi, W., Benediktsson, J.A. and Ning, X. 2016. Novel Object-based filter for improving land-cover classification of aerial imagery with very high spatial resolution. *Remote Sens.* 8:1023.
- [170] Geipel, J., Link, J., and Claupein, W. 2014. Combined spectral and spatial modeling of corn yield based on aerial images and crop

- surface models acquired with an unmanned aircraft system. *Remote Sens.* 6:10335 - 10355.
- [171] Lu, D.S., Mausel, P., Batistella, M., Moran, E. 2004. Comparison of land-cover classification methods in the Brazilian Amazon Basin. *Photogramm. Eng. Remote Sens.* 70:723 - 731.
- [172] Gage, E.A., and Cooper, D.J. 2017. Urban forest structure and land cover composition effects on land surface temperature in a semi-arid suburban area. *Urban Forestry & Urban Greening* 28:28-35.
- [173] Hiscock, O.H., Back, Y., Kleidorfer, M., and Urich, C. 2021. A GIS-based Land Cover Classification Approach Suitable for Fine scale Urban Water Management. *Water Resour. Manage.* 35:1339-1352.
- [174] Hai-yang, Y.U., Gang, C., Xiao-san, G.E., and Xiao-ping L.U. 2011. Object oriented land cover classification using ALS and GeoEye imagery over mining area. *Transactions of Nonferrous Metals Society of China* 21(3):s733-737.
- [175] Vanhuysse, S., Grippa, T., Lennert, M., Wolff, E., and Idrissa, M. 2017. Contribution of nDSM derived from VHR stereo imagery to urban land-cover mapping in Sub-Saharan Africa. 2017 Joint Urban Remote Sensing Event (JURSE), 2017, 1-4.
- [176] Deng R.R., He Y.Q., Qin, Y., Chen, Q.D., and Chen, L. 2012. Measuring pure water absorption coefficient in the near-infrared spectrum (900–2500 nm). *Journal of Remote Sensing*, 16(1): 192 - 206.
- [177] Shahtahmassebi, A., Yang, N., Wang, K., Moore, N., and Shen, Z. 2013. Review of shadow detection and de-shadowing methods in remote sensing. *Chin. Geograph. Sci.* 23:403 - 420.
- [178] Milas, A.S., Arend, K., Mayer, C., Simonson, M.A., and Machey, S.

2017. Different colours of shadows: Classification of UAV images. *Int. J. Remote Sens.* 38:3084 - 3100.
- [179] 신형섭, 송석호, 이동호, 박종화. 2021. 무인기 영상 기반 옥수수 재배필지 추출을 위한 Attention U-NET 적용 및 평가. *응용생태공학회* 8(4):253-265.
- [180] 유수홍, 이지상, 배준수, 손홍규. 2020. Residual U-Net을 이용한 토지 피복지도 자동 제작 연구. *대한토목학회논문집* 40(5):535-546.
- [181] Song, B., Park, K. 2020. Detection of Aquatic Plants Using Multispectral UAV Imagery and Vegetation Index. *Remote Sens.* 12:387.
- [182] Jo, H.-K., Kim, J.-Y., Park, H.-M. 2020. Carbon and PM2.5 Reduction and Design Guidelines for Street Trees in Korea. *Sustainability* 12:10414.
- [183] Yang, J., Kang, Z., Cheng, S., Yang, Z., and Akwensi, P.H. 2020. An Individual Tree Segmentation Method Based on Watershed Algorithm and Three-Dimensional Spatial Distribution Analysis From Airborne LiDAR Point Clouds. *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing* 13:1055-1067.
- [184] Qin, H., Zhou, W., Yao, Y., Wang W. 2022. Individual tree segmentation and tree species classification in subtropical broadleaf forests using UAV-based LiDAR, hyperspectral, and ultrahigh-resolution RGB data. *Remote Sensing of Environment* 280:113143.
- [185] Iizuka, K., Yonehara, T., Itoh, M., Kosugi, Y. 2018. Estimating Tree Height and Diameter at Breast Height (DBH) from Digital Surface Models and Orthophotos Obtained with an Unmanned Aerial System for a Japanese Cypress (*Chamaecyparis obtusa*) Forest. *Remote Sens.* 10:13.

- [186] da Silva, A.K.V., Borges, M.V.V., Batista, T.S., da Silva Junior, C.A., Furuya, D.E.G., Prado Osco, L., Teodoro, L.P.R., Baio, F.H.R., Ramos, A.P.M., Gonçalves, W.N., et al. 2021. Predicting Eucalyptus Diameter at Breast Height and Total Height with UAV-Based Spectral Indices and Machine Learning. *Forests* 12:582.
- [187] 이근왕, 박준규. 2020. 포인트클라우드 데이터를 이용한 수목관리정보 구축 방안. *디지털융복합연구* 18(11):427-432.
- [188] Corte A.P.D., Souza D.V., Rex F.E., Sanquetta C.R., Mohan M., Silva C.A., Zambrano A.M.A., et al. 2020. Forest inventory with high-density UAV-Lidar: Machine learning approaches for predicting individual tree attributes. *Computers and Electronics in Agriculture* 179:105815.

ABSTRACT

Construction of Precision Environmental Spatial Information Based on Geospatial Artificial Intelligence and Unmanned Aerial Vehicle Imagery

Park Geonung
Dept. of Smart Environmental
Energy Engineering,
Changwon National University

The creation of environmental spatial information is critical for the development of local environmental policies, yet it is challenged by limitations in field surveys and spatial data editing. This study aimed to explore methodologies for the production of precise environmental spatial information using UAVs and GeoAI. Focusing on case studies of land cover and individual tree information, methodologies for UAV data collection and GeoAI application were designed and analyzed, considering two different spatial information representation approaches.

The first approach was a continuous field view, which represent the variability of a certain attribute for every location within the target area without gaps. This was applied to land cover information, which requires classifying and representing diverse targets with complex physical characteristics as homogeneous groups. The second approach was a discrete object view, focusing on constructing information for specific objects and considering other areas as empty space. This was applied to

individual tree information targeting the construction of data such as Diameter at Breast Height (DBH), crown area, and tree height, essential for estimating carbon absorption and storage capacities.

Land cover information was collected using various sensors mounted on UAVs, including multispectral and thermal infrared cameras. These sensors facilitated the acquisition of image data that reveals the physical characteristics of the land cover. Tree information was obtained using UAV-based LiDAR sensors, capturing 3D positional data that illustrate the morphological characteristics of trees, along with RGB images. To address the complexities arising from high-resolution images, object-based image analysis and deep learning techniques, as part of GeoAI methods, were applied, yielding the following analysis results:

The UAV-based spectral and geometric imagery collected were analyzed for their characteristics and classification contributions of each land cover category. nDSM, NDVI, SAVI, and LST images were identified as having significant importance in variable analysis. The combination of nDSM, NDVI, and SAVI was found to be effective in classifying buildings, trees, and grass. LST were crucial for classifying car roads, pedestrian paths, and bare soil. Additionally, the thermal capacity characteristics based on the cover can be considered as potential foundational images for urban land cover classification.

Further, the performance of models for object-based image analysis (OBIA-RF, OBIA-ANN) and deep learning-based semantic segmentation (U-Net) was compared. The U-Net model demonstrated superior performance in land cover classification with an overall accuracy of

93.0%. The effectiveness of the U-Net model was attributed to its use of 2D images as input data that incorporate spatial information alongside spectral data. Although the OBIA-RF and -ANN models showed slightly lower overall accuracy than the U-Net model, they exhibited over 94% accuracy and reliability in classifying buildings and trees. The U-Net model required a substantial training duration of 25 hours, whereas the OBIA-RF and -ANN models completed training within an hour. For classifications focusing solely on buildings or tree areas, object-based image analysis techniques were deemed more efficient than deep learning methods, which necessitate extensive training time.

Regarding individual tree information, individual tree areas were identified using a deep learning-based object segmentation technique, with attributes such as crown area, height, and DBH subsequently established. To facilitate the application of the deep learning model, a method for constructing training data for individual tree detection was proposed, utilizing object-based image analysis and watershed segmentation techniques. Despite limitations in individual tree detection methods potentially leading to the subdivision of a single tree area, this approach was anticipated to overcome the boundaries posed by traditional field surveys and vectorizing, especially in densely forested areas. Consequently, this strategy could be likely to serve as an essential link for the application of deep learning techniques that require extensive training data.

The Mask R-CNN model, a deep learning-based object segmentation technique, was trained with the individual tree areas that had been prepared as training data. The results demonstrated stable accuracy in

individual tree detection, achieving F1 scores of 0.9583 at an IoU threshold of 50% and 0.8802 at 75%. Subsequently, structural information of trees, such as crown area and height, was calculated using individual tree detection results and UAV images. These were utilized as independent variables in a regression model, which predicted DBH with an RMSE of 1.86cm and a coefficient of determination of 0.73. Although UAV images may offer slightly reduced accuracy compared to field surveys, their use was considered effective for efficiently constructing individual tree information across extensive areas for the estimation of carbon absorption and storage.

In conclusion, the case study involving land cover and individual trees demonstrated that its findings could be extended as a methodology for transforming various environmental data into spatial information. Through integrating UAVs for data collection and GeoAI for information extraction, the study proposed an automated approach for constructing precise environmental spatial information, thereby reducing the need for extensive human involvement in tasks like field surveys and vectorizing. This has the potential to contribute significantly to the development of sustainable methods for monitoring environmental spatial information.

KEYWORDS

Remote Sensing, UAV, GeoAI, Deep Learning, OBIA, Land Cover Classification, Individual Tree detection